Auditoria do Padrão Ouro

O que os 28 gaps viraram, e o que ainda separa a esteira de uma geração confiável

Gerador de Missões Unooria — terceira leitura em quatro dias, revisada à tarde

Data: 23 de setembro de 2026 | **Versão:** 2 (tarde) | **Referência:** Rubrica v1.19 | **HEAD:** `80e1bbb`

Corpus: 104 agentes na árvore · 48 de LLM · 69 prompts · 34 referências · 71 testes · 22 gates no dossiê · 14 sessões do bucket

---

1 Veredito

A resposta curta, na versão da tarde

Ainda não é padrão ouro — e agora a distância é de natureza diferente da de manhã. De manhã faltavam coisas no código: uma dimensão de acessibilidade no lugar errado, três gates fora do dossiê, um catálogo que desligava o gate de semelhança. Isso foi corrigido em cinco commits, e ao corrigir apareceram mais cinco defeitos que nenhum dos três relatórios anteriores tinha visto — todos corrigidos também.

O que sobra são **quatro pontos, e só um deles é código**:

1. **Um ticket de design pode sumir sem aviso** (A-15, novo): o QA manda achado para um dono que o despacho não sabe rotear, e o despacho o descarta em silêncio. É o único defeito de código aberto que viola a regra que sustenta tudo o resto — *nada some sem deixar rastro.*
2. **Os juízes leem um gabarito de plataforma de 16/09** (A-05): a plataforma ganhou a exp-05 "Quem Mandou Isso?", com 18 rotas e a porta 5184, e as cópias que os agentes de dev consultam não sabem disso. As cópias foram sincronizadas por acidente e **descartadas por decisão**; o item fica aberto conscientemente.
3. **O índice de missões de produção tem 1 entrada** (A-02, dado): o código que o alimenta foi corrigido e o índice certo, com 14 fichas úteis, está pronto — mas escrevê-lo no bucket depende de autorização.
4. **Nenhuma missão atravessou a esteira com o formato de hoje** (A-09): é o teste que nenhum outro substitui.

Em uma frase: **tudo que se sabe medir está medido e aparece; falta provar que funciona junto, e fechar um único ralo por onde um ticket ainda escorre.**

2 O que mudou desde a versão da manhã

A versão 1 deste relatório foi publicada às 12h06 (`bea95c5`). Depois dela, cinco commits:

Commit	O que corrigiu
`a3c3a30`	Acessibilidade conferida em toda missão (D4a), não só nas que têm camada CAA (A-01).
`00b0a9a`	Lint do protótipo e brief de escopo no dossiê; o lint volta a rodar depois do retrabalho (A-03, A-10); brief ausente sai **amarelo**, não verde (A-13).
`744a96f`	Extrator do catálogo lê a coluna pelo nome; ambiente novo não sai vazio; aviso de índice cego chega ao micro-gate e ao dossiê, e vê o caso de produção (A-02, A-11, A-12).
`a2542c0`	Todo o rastro do Google Drive removido; trava contra instrução de ferramenta que o agente não tem (A-07).
`80e1bbb`	`sincronizar_plataforma.py` lê argumentos antes de gravar: `--help` executava a sincronização inteira (A-14).

Uma correção ao que a versão da manhã afirmou

A versão 1 disse que as 20 depreciações restantes do ADK "vêm do SDK e do Python 3.14, não do nosso código". **Estava errado.** Quinze das vinte vêm do nosso código: cada `SequentialAgent`, `LoopAgent` e `ParallelAgent` que a esteira monta — que o ADK depreciou em favor do motor de grafo `Workflow`. E o risco não está na depreciação, está na dependência sem teto (`google-adk>=2.8.0`): os 71 testes rodam na 2.8.0, e a revisão ativa do Cloud Run, de 22/09, muito provavelmente roda a 2.9.2. O item foi **adiado por decisão** (seção 5.3).

3 Método

Três leituras anteriores foram cruzadas: o relatório de imersão de 20/09 (102 achados), a reavaliação de 22/09 e o relatório dos 28 gaps sistêmicos de 22/09. Contra elas, o repositório no `HEAD 80e1bbb`: os 104 agentes da árvore real, os 69 prompts com `include` resolvido, as 34 referências, os validadores de `tools/` e os 71 testes. Cada gap foi verificado **no código, por linha**, não pelo commit que diz tê-lo corrigido.

Na tarde, três cruzamentos foram automatizados e dois viraram teste: (i) todo `status_key` gravado por um agente aparece no dossiê; (ii) nenhum prompt instrui a usar ferramenta que o agente não recebe; (iii) todo dono citado num prompt de gate tem rota no despacho — este último revelou o A-15 e **ainda não é teste**. As 14 sessões do bucket foram recomputadas duas vezes, em cópia local: **o bucket foi lido e nunca escrito**.

O que este relatório não afirma

Não afirma que as missões geradas são boas. A esteira verifica que a missão *declara* o que precisa declarar, de forma conferível; ela não sabe se a criança aprende. Com o protocolo de observação em sala removido por decisão, essa fronteira é permanente: **padrão ouro aqui significa que tudo que é verificável sobre o artefato está verificado, e o que não é está marcado como tal**.

4 Confronto: os 28 gaps, um a um

Gap	Título	Estado	Evidência verificada hoje
Frente I — Execução, fail-safe e robustez			
GAP-01	Fail-open nos gates de design e dev	fechado	`treat_indefinido_as_blocked` só sobrevive no comentário que explica por que saiu

Gap	Título	Estado	Evidência verificada hoje
GAP-02	Status vazio aceito na adequação	fechado	`SaidaDeLoopAgent`: chave ausente conta como reprovada
GAP-03	Teste principal quebrado em runtime	fechado	descoberta automática; 71 testes verdes
GAP-04	Sem persistência nem contagem de tokens	fechado	custo e tokens por agente no dossiê
GAP-05	Sem retry nem backoff	fechado	`HttpRetryOptions` em todos os agentes
GAP-06	118 avisos de depreciação do ADK	decisão	20 hoje, 15 do nosso código; dependência sem teto. Adiado por decisão
GAP-07	Governança de deploy	decisão	segredos fora da imagem; app de geração pública por decisão de produto
Frente II — Produto e pipeline pedagógico			
GAP-08	Beco sem saída pedagógico	fechado	`adequacao_report` chega ao gate final, à spec e ao PRD
GAP-09	Brief de escopo esvaziado no loop	fechado	separado antes do revisor; **e desde a tarde, ausente sai amarelo**
GAP-10	Sem guardrail de spoiler a jusante	fechado	dimensão D3b sobre o que vai à tela
GAP-11	Evidência inventada tarde pelo 16b	fechado	matriz nasce na spec e é conferida
GAP-12	Eixo BNCC incompatível no EM	fechado	referência explícita
GAP-13	Sem reexecução parcial de produto	aberto	`ETAPAS` sem `produto`
GAP-14	Réguas temporais conflitantes	fechado	T1/T2/T3 unificadas
GAP-15	Gate cego à própria rodada	fechado	rodada interpolada
Frente III — Design, imersão e experiência			
GAP-16	Retrabalho por tickets fantasma	parcial	despacho existe e roda — **mas descarta em silêncio ticket de dono sem rota** (A-15)
GAP-17	Inversão de dependência no retrabalho	fechado	ordem conferida sem alterar
GAP-18	Protótipo auto-aprovado	fechado	lint no dossiê, com arquivo, e **relintado depois de todo retrabalho**
GAP-19	Notação Mermaid ambígua	fechado	`stateDiagram-v2` fixado
GAP-20	Severidade do pico emocional	fechado	`c10e98b`
GAP-21	Sem critérios de acessibilidade	fechado	D4a roda sempre: contraste, alvo, foco, nada-só-por-cor
GAP-22	2–4 por aparelho descartado	fechado	exceção que não se corta
GAP-23	Falsa dependência de ferramenta inativa	fechado	Stitch condicional tratado; Drive removido
Frente IV — Governança e contratos			
GAP-24	Catálogo incompleto trava o V5	parcial	código corrigido: 14 fichas cegas → 0 na reconstrução. **Índice de produção ainda com 1 entrada**
GAP-25	Enum de status desalinhado	fechado	15 valores com teste
GAP-26	Validação cega a pendências	fechado	validador vazio bloqueia em todos os nós
GAP-27	Drift das cópias da plataforma	decisão	sincronizadas por acidente e **descartadas por decisão**; seguem em `29afc8f`
GAP-28	Banca consolidada por LLM	fechado	consolidação determinística, 22 bloqueantes, DES-14 incluído

Estado	Manhã (v1)	Tarde (v2)
Fechado com evidência de código	21	**22**
Parcial	4	2
Aberto	2	1
Decisão de negócio ou adiamento consciente	1	3

O GAP-16 *regrediu* de fechado para parcial: não porque algo quebrou, mas porque a verificação da tarde olhou mais fundo e achou o ralo.

5 Os achados, com o estado de cada um

5.1 Corrigidos hoje

Da lista da manhã

A-01 — Acessibilidade atrás da porta da CAA. As quatro contagens (contraste ≥ 4,5:1, alvo ≥ 64×64, ordem de foco, nada-só-por-cor) viviam na D8b, que só roda com CAA `concluido`; 4 das 14 missões saíram sem nenhuma verificação. Agora vivem na D4a, que roda sempre; a D8b cobra os mesmos mínimos também na rota não-leitora. `a3c3a30`.

A-03 — Gates fora do dossiê. O lint do protótipo e o brief de escopo entraram; o relatório do lint vira arquivo. Um teste cruza todo status gravado com o dossiê, para gate novo não nascer invisível. `00b0a9a`.

A-07 — Instrução para o Google Drive. Removida inteira — prompt, envelope, configuração, `.env.example`, README, pré-visualização no app. Trava nova impede instrução de Drive em qualquer prompt. `a2542c0`.

Achados novos da tarde, já corrigidos

A-10 — O lint do protótipo ficava velho. No retrabalho de design o protótipo era reconstruído e o lint não rodava de novo: o QA da rodada 2 lia o lint da rodada 1, sobre o HTML antigo, com a instrução de tratá-lo como fato. O lint entrou no pós-fixo do retrabalho. `00b0a9a`.

A-11 — O extrator do catálogo lia por posição. A causa real do GAP-24, mais funda que dado velho. O extrator esperava o slug na primeira coluna da linha que o agente 51 propõe; o modelo escreve a linha começando por `Ano`, sem slug. A linha era descartada em toda execução e `tipo_decisao` saía vazio — **mesmo reconstruído das sessões, o índice saía 14 de 14 cego**, e o registro automático repetia isso a cada missão nova. Agora a coluna é lida pelo nome, e o ambiente vem do campo `secao_ds` da spec. Reconstrução em cópia: **14 cegas → 0**. `744a96f`.

A-12 — O aviso de índice cego não chegava a ninguém, e era cego ao caso de produção. Ele só aparecia no relatório do catálogo, que roda depois do dossiê, e só contava linhas furadas — o bucket tinha 14 sessões e 1 missão indexada, zero linhas furadas, nenhum aviso. Agora compara sessões gravadas com o índice, vai antes da tabela que o micro-gate julga, e o dossiê mostra a base do V5 como gate. `744a96f`.

A-13 — Brief ausente saía verde. Quando o brief de escopo não vinha, o separador escrevia **aviso** no log e gravava o status do envelope do one-pager: `aprovado`. Pôr isso no dossiê seria exibir um verde que mente; agora sai **amarelo** com achado `secao-ausente`. `00b0a9a`.

A-14 — `--help` executava a sincronização. O script não tinha parser: qualquer argumento era ignorado e ele começava apagando todos os `.md` do destino. Foi assim que as 47 cópias foram reescritas por acidente nesta auditoria. Agora `--help` mostra o uso e argumento desconhecido falha, sem gravar. `80e1bbb`.

5.2 Aberto no código

A-15 — Ticket de design com dono sem rota é descartado em silêncio (novo)

O QA de design endereça cada ticket a um dono. Na dimensão D7, a regra é: *"não-negociável sem marca é ticket com dono `brief-oficio`"*. O despacho de design sabe rotear sete donos (`ambiente-simulado`, `caa`, `copy-ptbr-revisao`, `fecha-lacunas`, `fluxo`, `jornada`, `telas`) e tem um externo (`gate-estrutural`). **`brief-oficio` não está em nenhum dos dois.**
O laço do despacho (`DespachoTicketsAgent`) trata dois casos — dono externo e dono no mapa — e não tem o terceiro. O ticket é descartado: não reexecuta ninguém, não vira pendência, não aparece na mensagem. O QA reprova de novo na rodada seguinte, e o **vermelho** continua no dossiê — então o defeito não é invisível no veredito, mas o *ticket* nunca chega a quem o fecharia e o motivo não fica escrito.
Correção: (a) dono sem rota vira pendência nomeada na mensagem e no relatório, nunca descarte; (b) decidir se `brief-oficio` ganha instância de retrabalho ou vira externo; (c) o cruzamento dono × rota que revelou isto passa a ser teste. Meia hora.

5.3 Abertos por decisão, ou fora do código

O que fica, e por quê

A-02 — Índice de produção com 1 entrada. O índice certo — 14 fichas das sessões do bucket, todas úteis ao V5 — está pronto em cópia local. Escrevê-lo no bucket depende de autorização. Até lá, uma geração no Cloud Run compara a missão nova contra uma só, mas o dossiê agora diz isso em **amarelo**. Localmente o índice foi mesclado: **28 fichas, 21 úteis** (eram 4). As 7 restantes são missões reais do catálogo oficial (Rastro do Boato, Manifesto IA, O Eco no Grupo…) cujas fichas nunca tiveram descoberta ou tipo de decisão escritos — preenchimento humano.

A-05 — Cópias da plataforma em `29afc8f` (16/09), plataforma em `71b4dbb` (18/09). A diferença é a exp-05 "Quem Mandou Isso?": 18 rotas, a porta 5184, o módulo novo. Com as cópias velhas, uma missão nova do 5º ano pode pedir a mesma porta ou propor rota que já existe. Sincronizadas por acidente, descartadas por decisão. Fechar é `python3 scripts/sincronizar_plataforma.py`, agora sem risco de disparar por engano.

A-06 — ADK sem teto de versão. Ver o quadro de correção na seção 2. Migrar para `Workflow` é reescrita de dias (21 construções, loops por aresta, 63 asserções de forma de árvore), com ganho funcional zero hoje. Adiado por decisão.

A-04 — Correção parcial sem etapa de produto e **A-08 — nota "v1.18" em `criterios-experiencia.md:5`**: não impedem uma geração confiável.

5.4 O que só uma execução responde

A-09 — O formato novo nunca rodou

Sete estruturas entraram entre 22/09 à noite e hoje à tarde: matriz de evidência, tabela de medidas com grau, sub-bloco 9f, juiz das perguntas, KPI em modo estrito cruzado com a spec, D4a, e o índice de missões que de fato alimenta o V5. A última execução completa (22/09, 1777 s, 44 chamadas, 5,8 M tokens) viu só as três primeiras. **Nenhum gate novo viu uma missão real.**
E há um limite do instrumento: o harness que recomputa os gates sobre o bucket ainda não

cobre os gates da tarde — 9f, juiz, lint, brief, base do V5 aparecem como "—" nas 14 sessões, porque elas são anteriores a eles. A recontagem de hoje à tarde deu **os mesmos 272 achados da manhã, sem nenhuma mudança de veredito** — o que é esperado (as correções da tarde não mexem nos validadores que ele recomputa) e é, justamente, a prova de que ele sozinho não mede o que mudou.

6 A medição sobre as 14 sessões

Mudança de veredito (gravado em 22/09 → recomputado)	Sessões	Leitura
telemetria: amarelo → aprovado	5	erro de grafia deixou de virar erro de arquitetura
rastro de lacunas: bloqueado → amarelo ou aprovado	5	dono corrigido; placar deixou de ser pendência
PRD: bloqueado → amarelo	1	marcador de dono externo é compatível com **amarelo**
telemetria e PRD: passaram a acusar achado real	2	o que antes passava
evidência e KPI: — → bloqueado	14	gates que não existiam em 22/09

Seis bloqueios falsos deixaram de existir; dois achados verdadeiros passaram a aparecer. Os achados determinísticos somam 272, manhã e tarde. Os mais frequentes são formato novo (`gabarito-nao-declarado`, 14 de 14) e decisão humana (`lacuna:aberto:humano`, 14 de 14); os que medem qualidade de produto são reais e estão logo abaixo: `baseline-zero` em 9 sessões, `leitura-sem-leitor`, `tarefa-nao-atomica` e `numero-sem-origem` em 7 cada.

7 Onde a esteira está pronta

7.1 A fronteira que sustenta tudo

O que se confere contra lista, formato ou outro trecho do documento é determinístico; julgar o que o autor quis dizer fica com o LLM (`tools/bncc.py:11-13`). Das 53 verificações determinísticas medidas, **37 são fato e acertam 37/37**; as 16 de julgamento produziam 100% dos bloqueios falsos, e as 12 piores foram para juiz estruturado — o determinístico acha os candidatos, o juiz rebaixa ou troca o dono, nunca cria bloqueio sem citação.

7.2 O que a tarde acrescentou como princípio

Três das cinco correções da tarde são a mesma lição, e vale registrá-la: **ler por posição é o erro que mais se repete nesta esteira**. A §2 dos PRDs saiu em oito cabeçalhos diferentes; a linha de catálogo do agente 51 sai numa ordem que o prompt não pede. O que o modelo escreve deriva; o nome da coluna, não. `tools/kpis.py` e agora `tools/catalogo.py` leem pelo nome normalizado.

A outra lição: **todo cruzamento que achou defeito virou teste**. Status gravado × dossiê, instrução × ferramenta, argumento × escrita. O único cruzamento que achou defeito e ainda não é teste é o que revelou o A-15.

8 Os marcos do plano, medidos

M	Marco	22/09	23/09 manhã	23/09 tarde	Estado
M2	bloqueios por dono classificado errado	6	0	0	fechado
M3	`websocket-mencao` falso	8 de 14	0	0	fechado
M4	achados de campo órfão	68	0	0	fechado
M5	banca cobrando o que o PRD entrega	24	0	0	fechado
M6	gates que aprovam com a chave vazia	8	0	0	fechado
M7	gates invisíveis no dossiê	4	3	0*	fechado
M8	juízes sem regra de decisão	3	0	0	fechado
M9	juízes sem exigência de citação	3	0	0	fechado
M10	bloqueantes invisíveis ao consolidador	1	0	0	fechado
M11	fichas do catálogo que não sustentam o V5	10 de 10	10 de 15	7 de 28 local; produção: 1 entrada	parcial
M12	critérios de acessibilidade contáveis e sempre aplicados	0	4, só com CAA	4, sempre	fechado
M13	custo por missão	—	no dossiê	no dossiê	fechado
M14	suíte de testes	quebrada	64	71	fechado
M15	segredo fora da imagem	aberto	fechado	fechado	fechado

* Fora do dossiê por construção, e registrados como tal no código: o status do registro no catálogo (roda depois do diagnóstico) e o do próprio diagnóstico.

9 O que fazer antes da próxima geração

1. **Fechar o A-15** — o ticket sem rota. Meia hora. É o único defeito de código aberto que deixa algo sumir.
2. **Decidir o índice de produção** (A-02) — subir as 14 fichas ao bucket, ou gerar localmente, onde o índice já está certo.
3. **Decidir as cópias da plataforma** (A-05) — se a próxima missão for do 5º ano, a porta 5184 e as rotas da exp-05 importam.
4. **Rodar uma missão de ponta a ponta** (A-09) e ler com olho humano o 9f, a tabela de KPIs, a D4a e o aviso do V5.

10 Conclusão

Atingimos o padrão ouro?

No código, quase: falta um ralo. Tudo que é verificável sobre o artefato tem gate, aparece no dossiê e não aprova sem resposta — com a única exceção do ticket de design cujo dono o despacho não conhece, que ainda escorre sem deixar rastro.
Como sistema, ainda não, por três coisas que não são código e que foram, cada uma, escolhas conscientes ou dependem de uma: o gabarito da plataforma de 16/09, o índice de produção com uma entrada, e — a principal — a ausência de uma execução real com o formato de hoje. Em quatro dias a esteira saiu de *"os gates existem mas não reprovam"* para *"os gates reprovam, o que reprovam é conferível, e o que não conseguem ver eles dizem"*. O próximo passo não é mais auditoria: é gerar uma missão e ver.

Anexo — como reproduzir

```
python3 test_pipeline.py                      # 71 testes estruturais
python3 scripts/conferir_referencias.py       # fonte única x prompts
python3 scripts/catalogo.py listar            # estado do índice de missões
python3 scripts/reavaliar_gates.py --todas \
    gs://entre-redes-dev-adk-artifacts        # recomputa os gates (só lê)
python3 scripts/sincronizar_plataforma.py --help   # agora só mostra o uso
```