Auditoria do Padrão Ouro

O que os 28 gaps viraram, e o que ainda separa a esteira de uma geração confiável

Gerador de Missões Unooria — terceira leitura em quatro dias, revisada cinco vezes

Data: 23 de setembro de 2026 | **Versão:** 6 (noite) | **Referência:** Rubrica v1.19 | **HEAD:** `8ed2b61`

Corpus: 105 agentes na árvore · 49 de LLM · 69 prompts · 34 referências · 85 testes · 27 gates no dossiê · 14 sessões do bucket

---

1 Veredito

A resposta curta, na versão 6

A v5 disse "no código, sim". A auditoria de qualidade desta noite mostrou que a pergunta estava incompleta. As cinco versões anteriores perguntavam se cada gate *existe, roda e aparece*; a v6 perguntou se ele *aprova o que é falso* ou *reprova o que é certo*. Achou as duas coisas.

Três classes de alucinação passavam por gates verdes, todas medidas nas 14 sessões do bucket: um código BNCC apresentado com eixo e texto inventados (a exp06ef1b atribuiu a EF06CO07 um texto de letramento que a BNCC não tem); 22 rotas inexistentes ou com verbo errado em módulos da plataforma, a maioria ensinada pelos próprios prompts; e 66 de 206 componentes "do DS" que o DS não tem. **Quatro regras reprovavam o que estava certo**: o lint lia "todo" como rascunho, o SAEB acusava o "N/A" que ele mesmo manda escrever, o gate de telemetria cobrava um leitor que nenhum documento nomeava, e o detector de WebSocket acusava a frase que proíbe WebSocket. As sete estão corrigidas, com teste; a última, por um juiz de LLM que só retira um achado citando o trecho, conferido com o modelo real em 9 casos — 7 das sessões, 2 plantados — com 9 acertos.

A primeira execução com o formato de hoje também rodou (exp02ef1b, 39 min): dos 11 impedimentos, **9 eram defeito da esteira**, e estão corrigidos. Os outros 2 são o teto de tempo, que continua bloqueando por desenho — mas a conta estava errada: somava os 45 minutos da aula como tempo de tela.

Como sistema, ainda não, pelo que não é código:

1. **nenhuma execução rodou depois das correções desta noite** — a próxima é a que confirma que os 9 impedimentos falsos não voltam;
2. **a precisão dos juízes de LLM não tem medida contínua**: o juiz de achados foi conferido em 9 casos, os juízes de produto e da banca em nenhum;
3. **o índice de missões de produção segue com 1 entrada**, e as cópias da plataforma além do OpenAPI seguem em 16/09, por decisão.

2 O que mudou desde a versão da manhã

A versão 1 deste relatório foi publicada às 12h06 (`bea95c5`), a versão 2 à tarde (`97a07bd`), a versão 3 no fim da tarde (`5d7ecda`), a versão 4 à noite (`9677b02`), a versão 5 depois (`8238b8c`). Depois da v1, vinte commits:

Commit	O que corrigiu
`a3c3a30`	Acessibilidade conferida em toda missão (D4a), não só nas que têm camada CAA (A-01).
`00b0a9a`	Lint do protótipo e brief de escopo no dossiê; o lint volta a rodar depois do retrabalho (A-03, A-10); brief ausente sai **amarelo**, não verde (A-13).
`744a96f`	Extrator do catálogo lê a coluna pelo nome; ambiente novo não sai vazio; aviso de índice cego chega ao micro-gate e ao dossiê, e vê o caso de produção (A-02, A-11, A-12).
`a2542c0`	Todo o rastro do Google Drive removido; trava contra instrução de ferramenta que o agente não tem (A-07).
`80e1bbb`	`sincronizar_plataforma.py` lê argumentos antes de gravar: `--help` executava a sincronização inteira (A-14).
`0b186a1`	**Depois da v2.** Despacho traduz o nome do dono pela fonte única; ticket sem rota vira pendência humana no dossiê; a consolidação da banca volta a entregar dono e id ao despacho; `brief-oficio` ganha rota e lê o ticket (A-15, A-15b).
`5427dbf`	**Depois da v3.** O brief de assets lê o ticket da banca (A-16); o revisor do one-pager recebe a avaliação pedagógica e a experiência do estudante (A-17). As duas perguntas que os acharam viram teste.
`3d7639c`	**Depois da v4.** A correção parcial apaga tudo que a etapa regrava — seis gates novos tinham ficado fora, e o contador do juiz das perguntas sobrevivia (A-20); o critério de experiência declara a versão da rubrica no título (A-08).
`d53cf06`	O material anexado é guardado inteiro e chega à spec, à avaliação pedagógica e ao resumido (A-19); a correção ganha a etapa de produto, e a triagem a escolhe pelo lugar onde a decisão mora (A-04); os dois trechos inalcançáveis do A-18 saem.
`3124c86`	**Depois da v5: a auditoria de qualidade.** O lint do protótipo deixa de ler português como rascunho (A-21).
`50b18b3`	SAEB: verde onde não se aplica, **amarelo** onde o descritor falta ou sobra; a série vem do
`e22fe52`	slug (A-22).
`21e168b`	O leitor de evento de produto é o painel (PostHog), e o gate de KPI e o do PRD aceitam os mesmos leitores (A-23).
`b464cad`	Os três juízes de produto leem o briefing; o teto de tempo conta o tempo em tela (A-24, A-25).
`7122dbe`	O gate BNCC confere eixo e texto da habilidade, não só o código (A-26).
`559f918`	Rota citada num módulo da plataforma tem de existir nela; OpenAPI regenerado do roteador (A-27).
`4761366`	O inventário do DS chega às telas, e o lint confere os nomes (A-28).
`c68d680`	Juiz de LLM para as menções que o regex não sabe ler: afirma ou cita para descartar (A-29).
`c87f6c0`	Gabarito no bundle, dito no handoff, também bloqueia — achado pelo teste de mutação
`8ed2b61`	(A-32).

Uma correção ao que a versão da manhã afirmou

A versão 1 disse que as 20 depreciações restantes do ADK "vêm do SDK e do Python 3.14, não do nosso código". **Estava errado.** Quinze das vinte vêm do nosso código: cada `SequentialAgent`, `LoopAgent` e `ParallelAgent` que a esteira monta — que o ADK depreciou em favor do motor de grafo `Workflow`. E o risco não está na depreciação, está na dependência sem teto (`google-adk>=2.8.0`): os testes rodam na 2.8.0, e a revisão ativa do Cloud Run, de 22/09, muito provavelmente roda a 2.9.2. O item foi **adiado por decisão** (seção 5.4).

Uma correção ao que as versões 1 a 5 afirmaram: o M3

A tabela de marcos dizia `websocket-mencao` falso: **0**, desde a manhã. **Estava errado.** A regra de 22/09 deixou de acusar a frase que o gabarito manda escrever ("nunca WebSocket"), e o harness contou zero porque recomputava só os documentos em que essa frase aparecia. Lida a frase de cada handoff, três documentos reais seguiam acusados por descartar o WebSocket

com outras palavras: “NÃO é suportada” (exp04), “sem necessidade” (exp05) e “Nenhum protocolo” (a execução de teste de hoje). Nenhuma lista de negações fecha isso — a próxima redação escapa dela. A correção é o A-29: a regra acha o candidato, e um juiz de LLM decide se a frase afirma o uso ou cita para descartar.

3 Método

Três leituras anteriores foram cruzadas: o relatório de imersão de 20/09 (102 achados), a reavaliação de 22/09 e o relatório dos 28 gaps sistêmicos de 22/09. Contra elas, o repositório no `HEAD d53cf06`: os 105 agentes da árvore real, os 69 prompts com `include` resolvido, as 34 referências, os validadores de `tools/` e os 79 testes (na v6, `8ed2b61` e 85 testes). Cada gap foi verificado **no código, por linha**, não pelo commit que diz tê-lo corrigido.

Na tarde, três cruzamentos foram automatizados, e os três viraram teste: (i) todo `status_key` gravado por um agente aparece no dossiê; (ii) nenhum prompt instrui a usar ferramenta que o agente não recebe; (iii) todo dono citado num prompt de gate tem rota no despacho — revelou o A-15. Na v3, mais três perguntas sobre a árvore inteira: (iv) todo agente que um despacho reexecuta lê o ticket? (v) dentro de cada loop, o autor recebe o relatório de cada gate que o reprova? (vi) documento escrito por mais de um agente, em que o segundo apague o primeiro? As duas primeiras acharam o A-16 e o A-17; a terceira está limpa. Na v4, mais uma pergunta e uma medição: (vii) todo insumo que um prompt lê já foi escrito quando o agente roda — percorrendo a árvore na ordem de execução, separando o que chega de propósito só na rodada de correção; (viii) quanto contexto cada agente recebe, com os insumos reais da última execução completa. A (vii) voltou limpa. Na v5, ao fechar o GAP-13: (ix) toda chave que um agente da etapa grava é apagada quando a correção recomeça dali? — achou o A-20; (x) todo agente que cita o material anexado como fonte o recebe? — achou o A-19. Os dois viraram teste, e os dois foram vistos acusar o defeito no commit anterior. Na v6 a pergunta mudou de lado: (xi) o gate aprova algo que a fonte desmente? — cada afirmação conferível das 14 specs, PRDs e telas (código BNCC com eixo e texto, rota, componente) foi comparada à fonte oficial; (xii) o gate reprova algo certo? — cada impedimento da execução de teste foi lido à mão; (xiii) um teste de mutação: 14 defeitos plantados nos documentos de uma sessão aprovada, e quantos a esteira pega — 10 de 14 antes das correções, 13 de 14 depois. A primeira versão do harness usava de base a exp06 (justamente a spec alucinada, já bloqueada no BNCC) e comparava conjuntos de código, o que escondia defeito repetido; foi refeita sobre a exp04, contando ocorrências. As 14 sessões do bucket foram recomputadas duas vezes, em cópia local: **o bucket foi lido e nunca escrito**.

O que este relatório não afirma

Não afirma que as missões geradas são boas. A esteira verifica que a missão *declara* o que precisa declarar, de forma conferível; ela não sabe se a criança aprende. Com o protocolo de observação em sala removido por decisão, essa fronteira é permanente: **padrão ouro aqui significa que tudo que é verificável sobre o artefato está verificado, e o que não é está marcado como tal**.

4 Confronto: os 28 gaps, um a um

Gap	Título	Estado	Evidência verificada hoje
Frente I — Execução, fail-safe e robustez			

Gap	Título	Estado	Evidência verificada hoje
GAP-01	Fail-open nos gates de design e dev	fechado	`treat_indefinido_as_blocked` só sobrevive no comentário que explica por que saiu
GAP-02	Status vazio aceito na adequação	fechado	`SaidaDeLoopAgent`: chave ausente conta como reprovada
GAP-03	Teste principal quebrado em runtime	fechado	descoberta automática; 79 testes verdes
GAP-04	Sem persistência nem contagem de tokens	fechado	custo e tokens por agente no dossiê
GAP-05	Sem retry nem backoff	fechado	`HttpRetryOptions` em todos os agentes
GAP-06	118 avisos de depreciação do ADK	decisão	20 hoje, 15 do nosso código; dependência sem teto. Adiado por decisão
GAP-07	Governança de deploy	decisão	segredos fora da imagem; app de geração pública por decisão de produto
Frente II — Produto e pipeline pedagógico			
GAP-08	Beco sem saída pedagógico	fechado	`adequacao_report` chega ao gate final, à spec e ao PRD
GAP-09	Brief de escopo esvaziado no loop	fechado	separado antes do revisor; **e desde a tarde, ausente sai amarelo**
GAP-10	Sem guardrail de spoiler a jusante	fechado	dimensão D3b sobre o que vai à tela
GAP-11	Evidência inventada tarde pelo 16b	fechado	matriz nasce na spec e é conferida
GAP-12	Eixo BNCC incompatível no EM	fechado	referência explícita
GAP-13	Sem reexecução parcial de produto	fechado	etapa `produto` na correção, com o material da origem; a triagem a escolhe (A-04)
GAP-14	Réguas temporais conflitantes	fechado	T1/T2/T3 unificadas
GAP-15	Gate cego à própria rodada	fechado	rodada interpolada
Frente III — Design, imersão e experiência			
GAP-16	Retrabalho por tickets fantasma	fechado	dono traduzido pela fonte única; ticket sem rota vira pendência humana; banca volta a entregar o dono (A-15, A-15b)
GAP-17	Inversão de dependência no retrabalho	fechado	ordem conferida sem alterar
GAP-18	Protótipo auto-aprovado	fechado	lint no dossiê, com arquivo, e **relintado depois de todo retrabalho**
GAP-19	Notação Mermaid ambígua	fechado	`stateDiagram-v2` fixado
GAP-20	Severidade do pico emocional	fechado	`c10e98b`
GAP-21	Sem critérios de acessibilidade	fechado	D4a roda sempre: contraste, alvo, foco, nada-só-por-cor
GAP-22	2–4 por aparelho descartado	fechado	exceção que não se corta
GAP-23	Falsa dependência de ferramenta inativa	fechado	Stitch condicional tratado; Drive removido
Frente IV — Governança e contratos			
GAP-24	Catálogo incompleto trava o V5	parcial	código corrigido: 14 fichas cegas → 0 na reconstrução. **Índice de produção ainda com 1 entrada**
GAP-25	Enum de status desalinhado	fechado	15 valores com teste
GAP-26	Validação cega a pendências	fechado	validador vazio bloqueia em todos os nós
GAP-27	Drift das cópias da plataforma	decisão	sincronizadas por acidente e **descartadas por decisão**; seguem em `29afc8f`
GAP-28	Banca consolidada por LLM	fechado	consolidação determinística, 22 bloqueantes, DES-14 incluído

Estado	v1	v2	v3–v4	v5
Fechado com evidência de código	21	22	23	**24**
Parcial	4	2	1	1
Aberto	2	1	1	**0**
Decisão de negócio ou adiamento consciente	1	3	3	3

O GAP-16 passou de fechado (v1) a parcial (v2) e de volta a fechado (v3): a verificação da tarde olhou mais fundo, achou o ralo, e fechá-lo expôs um defeito maior no mesmo lugar. O GAP-13 fechou na v5, e fechá-lo foi o que expôs o A-19. O único parcial que resta é o GAP-24, pelo índice de produção — que é dado, não código.

5 Os achados, com o estado de cada um

5.1 Corrigidos hoje

Da lista da manhã

A-01 — Acessibilidade atrás da porta da CAA. As quatro contagens (contraste ≥ 4,5:1, alvo ≥ 64×64, ordem de foco, nada-só-por-cor) viviam na D8b, que só roda com CAA `concluido`; 4 das 14 missões saíram sem nenhuma verificação. Agora vivem na D4a, que roda sempre; a D8b cobra os mesmos mínimos também na rota não-leitora. `a3c3a30`.

A-03 — Gates fora do dossiê. O lint do protótipo e o brief de escopo entraram; o relatório do lint vira arquivo. Um teste cruza todo status gravado com o dossiê, para gate novo não nascer invisível. `00b0a9a`.

A-07 — Instrução para o Google Drive. Removida inteira — prompt, envelope, configuração, `.env.example`, README, pré-visualização no app. Trava nova impede instrução de Drive em qualquer prompt. `a2542c0`.

Achados novos da tarde, já corrigidos (v2 e v3)

A-10 — O lint do protótipo ficava velho. No retrabalho de design o protótipo era reconstruído e o lint não rodava de novo: o QA da rodada 2 lia o lint da rodada 1, sobre o HTML antigo, com a instrução de tratá-lo como fato. O lint entrou no pós-fixo do retrabalho. `00b0a9a`.

A-11 — O extrator do catálogo lia por posição. A causa real do GAP-24, mais funda que dado velho. O extrator esperava o slug na primeira coluna da linha que o agente 51 propõe; o modelo escreve a linha começando por `Ano`, sem slug. A linha era descartada em toda execução e `tipo_decisao` saía vazio — **mesmo reconstruído das sessões, o índice saía 14 de 14 cego**, e o registro automático repetia isso a cada missão nova. Agora a coluna é lida pelo nome, e o ambiente vem do campo `secao_ds` da spec. Reconstrução em cópia: **14 cegas → 0**. `744a96f`.

A-12 — O aviso de índice cego não chegava a ninguém, e era cego ao caso de produção. Ele só aparecia no relatório do catálogo, que roda depois do dossiê, e só contava linhas furadas — o bucket tinha 14 sessões e 1 missão indexada, zero linhas furadas, nenhum aviso. Agora compara sessões gravadas com o índice, vai antes da tabela que o micro-gate julga, e o dossiê mostra a base do V5 como gate. `744a96f`.

A-13 — Brief ausente saía verde. Quando o brief de escopo não vinha, o separador escrevia **aviso** no log e gravava o status do envelope do one-pager: `aprovado`. Pôr isso no dossiê seria exibir um verde que mente; agora sai **amarelo** com achado `secao-ausente`. `00b0a9a`.

A-14 — `--help` executava a sincronização. O script não tinha parser: qualquer argumento era ignorado e ele começava apagando todos os `.md` do destino. Foi assim que as 47 cópias foram reescritas por acidente nesta auditoria. Agora `--help` mostra o uso e argumento desconhecido falha, sem gravar. `80e1bbb`.

A-15 — Ticket de design com dono sem rota era descartado em silêncio (achado na v2). O despacho casava só o nome literal do dono, e três casos sumiam sem aviso: ticket sem dono, dono que nenhum agente atende, mapa apontando para agente ausente. A tabela que traduz os nomes que os gates de fato escrevem — a banca escreveu `wireframes` 16 vezes, `spec` 15, `copy` 2 — existia na fonte única e nenhum código a lia; agora é lida. O que continua sem rota vai à mensagem e ao dossiê como pendência humana, com id, dono e motivo. `brief-oficio`, que a D7 do QA exige e que não estava nem na lista do próprio envelope do QA, ganhou rota antes da jornada e o prompt passou a ler o ticket. `0b186a1`.

A-15b — O retrabalho da banca não consertava nada desde 22/09 (achado ao corrigir o A-15, e o mais grave do dia). A consolidação determinística da banca, escrita em 22/09, montava o envelope que o despacho lê só com código, severidade, dimensão, classe e resumo — **descartava o `agente_responsavel` e o `id`**. Todo ticket da banca chegava sem dono e era jogado fora: a banca reprovava, o despacho respondia "nenhum ticket com dono executável", e a rodada seguinte julgava o mesmo documento. Agora o dono atravessa a consolidação, e o envelope da banca tem o campo obrigatório, com a lista fechada de onze donos. `0b186a1`.

5.2 No código: nenhum defeito aberto

Fechados na v4

Os dois que a v3 deixou abertos foram fechados em `5427dbf`:

A-16 — O brief de assets era reexecutado pela banca às cegas. Dos seis agentes que a banca reexecuta, era o único que não lia nem o ticket nem o relatório. Ganhou a rodada de correção com `{tickets_retrabalho?}`, no molde dos outros cinco.

A-17 — O revisor do one-pager não recebia a avaliação pedagógica. O loop das avaliações repete quando ela reprova, e quem reescreve não a lia. Recebe agora a avaliação pedagógica e a experiência do estudante, e aplica os "vermelho obrigatórios — correção pronta" de cada uma como aplica o complemento do gate.

As regras que acharam os dois viraram teste, e foi conferido que elas **pegam** os dois defeitos quando rodadas contra os prompts do commit anterior — um teste que nunca falha não prova nada.

Corrigidos na v5

A-19 — O material anexado nunca chegava a quem o usa como fonte (novo na v5, e o mais visível ao PO). O conteúdo dos anexos existia só na mensagem, que só o núcleo narrativo lê; a sessão guardava os nomes dos arquivos. A spec, a avaliação pedagógica e o one-pager resumido são instruídos a usar o material do Entre Redes como fonte primária de código BNCC e de componente curricular, e nenhum dos três o via. Medido nas 14 sessões: **das 7 que anexaram o material do Entre Redes, 5 entregaram um resumido dizendo "material do bimestre não anexado"**. Agora o texto integral de cada anexo — PDF inclusive, pelo texto extraído — é guardado com a sessão, sem limite de tamanho, sai como artefato (`produto/00-material-anexado.md`) e chega aos três. `d53cf06`.

A-04 — Uma correção de mecânica pulava todos os gates de produto (era o GAP-13,

e era pior que conveniência). A triagem mandava para `spec` os pedidos de mecânica, etapas e narrativa, e a correção a partir da spec não refaz o one-pager nem passa pelo gate estrutural, pela avaliação pedagógica ou pelo gate final. A spec mudava, o one-pager do PO ficava como estava, e a regra nova não era avaliada por ninguém. A correção ganha a etapa `produto`, que refaz a missão desde o núcleo, com o material da geração original remontado na mensagem, e a triagem passa a decidir pelo lugar onde a decisão mora. Sessão antiga sem material guardado usa o que o pedido anexar; sem nenhum dos dois, a correção é **recusada antes de tocar a sessão**, com a lista dos arquivos a anexar de novo. `d53cf06`.

A-20 — A correção parcial não apagava o que os gates novos gravam (achado ao preparar o A-04, e introduzido nesta própria auditoria). Seis gates criados em 22–23/09 tinham ficado fora das listas do que a correção apaga antes de refazer uma etapa. O que doía era o contador de rodadas do juiz das perguntas: uma correção a partir da spec começava com as rodadas já esgotadas, e não havia rodada de correção. O teste novo percorre cada etapa e exige que toda chave gravada esteja na lista. `3d7639c`.

A-08 — A versão da rubrica no critério de experiência (descrição corrigida). A v4 descrevia a nota "v1.18" como defeito; ela é histórico legítimo e ficou. O defeito era outro: os outros três critérios de produto declaram *Rubrica v1.19* no título, e este não — quem o lia via duas notas de versão e nenhuma dizendo qual vale. Um teste exige que os quatro declarem a mesma. `3d7639c`.

A-18 — Duas rodadas de correção que o fluxo não alcançava: removidas na v5

A pergunta (vii) da v4 achou dois trechos de prompt que liam um insumo que nunca chega: a experiência do estudante lendo o relatório do gate final "quando já houve uma passada", e a adequação pedagógica lendo o ambiente simulado "quando já decidido". A v4 afirmou que os dois ficariam vivos com a correção de produto. **Não ficam**: a correção de produto apaga justamente esses relatórios antes de refazer, porque refazer produto é refazê-lo sobre o mesmo pedido e o mesmo material, não sobre o veredito anterior. Mantê-los seria o caso do Google Drive outra vez — instrução que nunca se exerce. Saíram em `d53cf06`.

R-01 — Risco medido: o contexto dos dois agentes que escrevem as entregas

Com os insumos reais da última execução completa (exp06ef1b, 22/09), o contexto de cada agente de LLM:

Agente	Total	Prompt	Insumos
Redator do PRD	784 KB	393 KB	391 KB
Handoff de dev	668 KB	303 KB	365 KB
Banca — técnica e arquitetura	597 KB	336 KB	260 KB
Banca — dados e LGPD	553 KB	293 KB	260 KB
Banca — pedagogia e BNCC	407 KB	147 KB	260 KB
Mediana dos 33 agentes	189 KB		

Cabe no modelo — são cerca de 200 mil tokens, bem abaixo do limite. O risco é outro: **regra no meio de um prompt muito longo sendo ignorada**. Há um caso documentado: o commit `fd68d9b` existiu porque o redator do PRD não seguia a regra do KPI no lugar onde ela estava escrita, e ela teve de ir para onde ele "de fato olha". Não é verificável sem rodar. *O que fazer:* na primeira execução, conferir se o PRD segue as regras 8 e as de consistência interna; se não seguir, o corte é nas referências da plataforma (393 KB fixos), não nos insumos da missão.

Na v5 o risco cresceu, por decisão. O material anexado vai inteiro, sem limite, a três agentes — spec, avaliação pedagógica e resumido. Quanto isso soma não dá para medir antes: as 14 sessões guardaram só os nomes dos anexos, e cinco delas anexaram de 42 a 45 documentos de uma geração anterior. A primeira execução com material mede.

5.3 Corrigidos na v6: o que o gate aprovava falso, e o que reprovava certo

Alucinações que passavam por gate verde

A-26 — A habilidade BNCC com eixo e texto inventados (a mais grave). A spec da exp06ef1b apresentou EF06CO07 como Cultura Digital e letramento digital, foco primário da missão, com um texto atribuído a uma "Matriz Curricular Entre Redes" que não tinha sido anexada. Na BNCC ele é Mundo Digital, sobre transmissão de dados. O gate aprovou: o código existia e era do ano, e um EF06CO09 citado entre parênteses contou como a habilidade de letramento. Agora o gate confere, contra a fonte, o eixo declarado na linha do código, o texto apresentado como a habilidade (contra o texto oficial ou o material anexado, quando vem dele), e só conta como letramento o código declarado com momento em tela. Nas 15 specs reais, só a exp06ef1b muda; das 32 citações de texto, 31 são iguais ao oficial. `7122dbe`.

A-27 — Rotas que a plataforma não tem. 22 afirmações de rota inexistente ou com verbo errado em módulos que já existem — `DELETE /turmas/:id` apagaria uma turma inteira a partir de uma missão. A maioria vinha dos prompts: três deles mandavam "instanciar o padrão de Atividade (`POST /atividades...`), nunca rota de preparo nova". A plataforma faz o contrário: `/atividades` é o motor da exp-01, e cada missão tem o preparo no próprio módulo. Os prompts passam a descrever o que existe, e `tools/rotas_plataforma.py` confere no PRD e no handoff toda rota citada num módulo da plataforma — inexistente e verbo errado bloqueiam. A fonte é a URL do OpenAPI quando a api o expuser (hoje o `/docs` de dev fica numa porta interna com senha); até lá, a lista gerada do roteador de verdade no commit `71b4dbb`, com 268 operações. `559f918`.

A-28 — Componentes "do DS" que o DS não tem. 66 de 206 (32%): `LikeButton` numa missão InstaNooria, `MessageBubble` — do WhatsApp — numa de ChatGPT. O prompt de telas dizia ao agente "você não tem como conferir o catálogo". Agora tem: `scripts/sincronizar_design_system.py` lê a API pública de cada marca do `storybook-unooria` (273 componentes em 6 marcas), os prompts de telas e ambiente recebem o inventário, e o lint do protótipo bloqueia nome inexistente em seção existente, com o mais parecido sugerido (`MessageBubble` → `ChatBubble`). `4761366`.

Falsos bloqueios, e o que a execução de teste mostrou

A-21 — O lint lia português como rascunho. Na execução de teste, bloqueou o protótipo por "você aprendeu que *todo* enquadramento conta uma história". TODO, FIXME e XXX contam só em maiúsculas; marcador entre colchetes conta em qualquer caixa; comentário de código não é lido. `3124c86`.

A-22 — SAEB. Dois dos três achados das 14 sessões eram o "N/A — ano não avaliado" que a regra manda escrever. Agora, como pedido: ano não avaliado com N/A é verde; descritor citado nesse ano, ou ano avaliado (2º, 5º, 9º do Fundamental, 3ª série do Médio) sem descritor, é **amarelo** com a indicação. A série vem do slug, não do texto — "anos iniciais" no começo de um one-pager fazia o 2º ano virar 1º ao 5º. `50b18b3`.

A-23 — Pub/Sub, seis dos onze impedimentos. O gate estava certo — Pub/Sub é

transporte —, mas nenhum documento dizia quem lê um evento que só alimenta KPI de produto, e o gate do PRD não aceitava PostHog. O redator não tinha resposta certa e não "corrigiu" em duas rodadas. São dois leitores: a tabela do módulo, para o que a professora vê; o painel de produto (PostHog), para o que só responde a uma pergunta de produto. Os dois gates aceitam os mesmos. `21e168b`.

A-24 — A missão reprovada por obedecer ao PO. O briefing proibia áudio, o critério 6.1 exige áudio no 1º–2º ano, e nenhum dos três juízes de produto recebia o briefing. Recebem agora, com a regra: restrição explícita do PO que contradiz a rubrica é decisão humana citando os dois lados — no gate final, **amarelo**, nunca **vermelho**. `b464cad`.

A-25 — O teto de tempo somava a aula inteira. O teto continua bloqueando, por desenho: a experiência nunca dura a aula toda. Mas o one-pager escreveu "sessão de 45 minutos em tela" para a aula, com mediação oral e fechamento dentro, e o juiz somou tudo. A seção 10 passa a ter duas colunas — em tela e fora da tela —, e o critério 6.2 define tempo-aluno como o tempo em tela. `b464cad`.

A-29 — WebSocket, estado no cliente e as famílias "propõe ou cita para proibir". Nove padrões que o regex acha e não sabe ler passam por um juiz de LLM em três gates (contrato do one-pager, evidência, telemetria). A assimetria é proposital: o juiz **só retira** um achado, e só com citação literal que existe no documento, uma por linha marcada; resposta inválida, citação inventada ou "afirma uso" mantêm o achado. Conferido com o modelo real em seis casos das sessões: os três descartes (exp04, exp05, execução de teste) saíram; os três usos reais (WebSocket com fallback e `localStorage` na exp07, IndexedDB offline na exp01) ficaram. `c68d680`.

A-32 — Gabarito no bundle, dito no handoff, passava. Achado pelo teste de mutação: o evidencia-check confere a ficha `gabarito_servidor` da spec, mas quem descreve a implementação é o handoff, e nada o lia. A regra passou a valer também no handoff, com o mesmo juiz. Nos 15 handoffs reais ela acusa um só — "Cegueira total de gabarito no bundle do cliente", da exp05, que nega —, e o juiz real o retirou; a mutação, ele manteve. `c87f6c0`.

O que o teste de mutação ainda não pega. Das 14 mutações, 12 são acusadas pela regra e 1 pela regra com o juiz (WebSocket afirmado num handoff que já o citava para descartar: o juiz retira o descarte e mantém a afirmação — conferido com o modelo real). A que escapa é uma habilidade com eixo e texto inventados *fora* da seção 11 da spec, que é onde o gate lê as habilidades; na seção 11, no formato real, eixo e texto trocados são acusados.

5.4 Abertos por decisão, ou fora do código

O que fica, e por quê

A-02 — Índice de produção com 1 entrada. O índice certo — 14 fichas das sessões do bucket, todas úteis ao V5 — está pronto em cópia local. Escrevê-lo no bucket depende de autorização. Até lá, uma geração no Cloud Run compara a missão nova contra uma só, mas o dossiê agora diz isso em **amarelo**. Localmente o índice foi mesclado: **28 fichas, 21 úteis** (eram 4). As 7 restantes são missões reais do catálogo oficial (Rastro do Boato, Manifesto IA, O Eco no Grupo…) cujas fichas nunca tiveram descoberta ou tipo de decisão escritos — preenchimento humano.

A-05 — Cópias da plataforma em `29afc8f` (16/09), plataforma em `71b4dbb` (18/09). A diferença é a exp-05 "Quem Mandou Isso?": 18 rotas, a porta 5184, o módulo novo. Com as cópias velhas, uma missão nova do 5º ano pode pedir a mesma porta ou propor rota que já existe.

Sincronizadas por acidente, descartadas por decisão. **Na v6, só o OpenAPI foi atualizado**, com aprovação: o índice e a lista de rotas vêm agora de `71b4dbb` (244 caminhos, 268 operações), e a exp-05 está neles; as demais cópias seguem em 16/09. `sincronizar_plataforma.py --openapi` atualiza só isso.

A-06 — ADK sem teto de versão. Ver o quadro de correção na seção 2. Migrar para `Workflow` é reescrita de dias (21 construções, loops por aresta, 63 asserções de forma de árvore), com ganho funcional zero hoje. Adiado por decisão.

A-30 — A precisão dos juízes de LLM não é medida. Os gates determinísticos têm teste de mutação; os juízes, não. O juiz de achados foi conferido em nove casos, uma vez. Os juízes de produto e da banca — que decidem 6.1, 6.2, os vetos pedagógicos, os 22 bloqueantes — não têm conjunto de casos conhecidos contra o qual rodar. Sem isso, uma troca de modelo ou de prompt pode afrouxar um juiz sem que nada acuse.

A-31 — As duas fontes "direto da URL" ainda não existem do lado da plataforma. O gerador já lê `PLATAFORMA_OPENAPI_URL` e `DS_COMPONENTES_URL` primeiro, como pedido; hoje as duas caem na cópia local, porque o `/docs` da api de dev fica numa porta interna com senha e o storybook de dev serve só a página padrão do Cloud Run. Publicar os dois é trabalho do repositório da plataforma.

5.5 O que só uma execução responde

A-09 — O formato novo rodou uma vez, antes das correções da v6

A execução de teste (exp02ef1b, 23/09, 39 min, 70 chamadas, 7,4 M tokens de entrada, sem escrever no bucket) foi a primeira a atravessar a esteira com o 9f, o juiz das perguntas, os KPIs em modo estrito, a D4a e o material inteiro. Confirmou o que foi desenhado: o material do Entre Redes chegou à spec (A-19); o 9f saiu com 5 perguntas, cada uma com evento que mede; o cruzamento KPI × pergunta rodou; nenhum ticket sumiu. E o R-01 não se materializou: o PRD seguiu as regras do meio do prompt.
O veredito foi **vermelho**, com 11 impedimentos — e ler cada um à mão foi o que abriu a auditoria de qualidade: **9 eram defeito da esteira** (seis do leitor Pub/Sub, dois do briefing que os juízes não liam, um do lint), hoje corrigidos; 2 eram o teto de tempo, com a conta errada. **Nenhuma execução rodou depois das correções.**

6 A medição sobre as 14 sessões

Mudança de veredito (gravado em 22/09 → recomputado)	Sessões	Leitura
telemetria: amarelo → aprovado	5	erro de grafia deixou de virar erro de arquitetura
rastro de lacunas: bloqueado → amarelo ou aprovado	5	dono corrigido; placar deixou de ser pendência
PRD: bloqueado → amarelo	1	marcador de dono externo é compatível com **amarelo**
telemetria e PRD: passaram a acusar achado real	2	o que antes passava
evidência e KPI: — → bloqueado	14	gates que não existiam em 22/09

Seis bloqueios falsos deixaram de existir; dois achados verdadeiros passaram a aparecer. Os achados determinísticos somam 272, manhã e tarde. Os mais frequentes são formato novo (`gabarito-nao-declarado`, 14 de 14) e decisão humana (`lacuna:aberto:humano`, 14 de 14); os que medem qualidade de produto são reais e estão logo abaixo: `baseline-zero` em 9 sessões, `leitura-sem-leitor`, `tarefa-nao-atomica` e `numero-sem-origem` em 7 cada.

7 Onde a esteira está pronta

7.1 A fronteira que sustenta tudo

O que se confere contra lista, formato ou outro trecho do documento é determinístico; julgar o que o autor quis dizer fica com o LLM (`tools/bncc.py:11-13`). Das 53 verificações determinísticas medidas, **37 são fato e acertam 37/37**; as 16 de julgamento produziam 100% dos bloqueios falsos, e as 12 piores foram para juiz estruturado — o determinístico acha os candidatos, o juiz rebaixa ou troca o dono, nunca cria bloqueio sem citação.

7.2 O que a tarde acrescentou como princípio

Três das cinco correções da tarde são a mesma lição, e vale registrá-la: **ler por posição é o erro que mais se repete nesta esteira**. A §2 dos PRDs saiu em oito cabeçalhos diferentes; a linha de catálogo do agente 51 sai numa ordem que o prompt não pede. O que o modelo escreve deriva; o nome da coluna, não. `tools/kpis.py` e agora `tools/catalogo.py` leem pelo nome normalizado.

A outra lição: **cruzamento que acha defeito vira teste**. Status gravado × dossiê, instrução × ferramenta, argumento × escrita, dono × rota, agente reexecutado × ticket lido, autor × relatório do gate, chave gravada × chave apagada na correção, citação do material × material recebido. Todos são teste.

8 Os marcos do plano, medidos

M	Marco	22/09	23/09 manhã	23/09 v6	Estado
M2	bloqueios por dono classificado errado	6	0	0	fechado
M3	`websocket-mencao` falso	8 de 14	3, não 0 (ver seção 2)	0 em 6 casos reais, pelo juiz	fechado
M4	achados de campo órfão	68	0	0	fechado
M5	banca cobrando o que o PRD entrega	24	0	0	fechado
M6	gates que aprovam com a chave vazia	8	0	0	fechado
M7	gates invisíveis no dossiê	4	3	0*	fechado
M8	juízes sem regra de decisão	3	0	0	fechado
M9	juízes sem exigência de citação	3	0	0	fechado
M10	bloqueantes invisíveis ao consolidador	1	0	0	fechado
M11	fichas do catálogo que não sustentam o V5	10 de 10	10 de 15	7 de 28 local; produção: 1 entrada	parcial
M12	critérios de acessibilidade contáveis e sempre aplicados	0	4, só com CAA	4, sempre	fechado
M13	custo por missão	—	no dossiê	no dossiê	fechado
M14	suíte de testes	quebrada	64	85	fechado
M15	segredo fora da imagem	aberto	fechado	fechado	fechado

M	Marco	22/09	23/09 manhã	23/09 v6	Estado
M16	tickets que somem sem rastro	não medido	não medido	0	**fechado**
M17	agentes que reescrevem sem ler o pedido do gate	não medido	não medido	0	**fechado**
M18	agentes que citam o material anexado como fonte sem recebê-lo	não medido	não medido	0 (eram 3)	**fechado**
M19	gates de produto que uma correção de mecânica pula	não medido	não medido	0 (eram todos)	**fechado**
M20	código BNCC com eixo ou texto diferente do oficial, aprovado	não medido	não medido	0 (era 1 spec, 3 afirmações)	**fechado**
M21	rota inexistente ou com verbo errado num módulo da plataforma, aprovada	não medido	não medido	0 (eram 22)	**fechado**
M22	componente "do DS" que o DS não tem, aprovado	não medido	não medido	0 (eram 66 de 206)	**fechado**
M23	impedimentos falsos na execução de teste	—	—	9 de 11 com causa corrigida; não reexecutado	**parcial**
M24	defeitos plantados que a esteira pega (mutação)	não medido	não medido	13 de 14 (eram 10)	**fechado**
M25	juízes de LLM com precisão medida	não medido	não medido	1 de 7, em 9 casos	**aberto**

* Fora do dossiê por construção, e registrados como tal no código: o status do registro no catálogo (roda depois do diagnóstico) e o do próprio diagnóstico.

9 O que fazer antes da próxima geração

1. **Rodar de novo a mesma missão** (exp02ef1b, sem escrever no bucket) e conferir que os 9 impedimentos falsos não voltam, que o 6.2 é julgado pela coluna "em tela", e que o juiz de achados não retira nenhum achado verdadeiro. É o que fecha o M23.
2. **Montar os casos conhecidos dos juízes** (A-30): para cada juiz de LLM, uns poucos documentos das sessões com o veredito certo escrito à mão, e um script que os roda. É o que torna medível o que hoje é confiança.
3. **Decidir o índice de produção** (A-02) e **pedir à plataforma as duas URLs** (A-31): o OpenAPI acessível à esteira e o inventário do DS publicado — a partir daí o gerador lê sempre o atual, sem cópia.

10 Conclusão

Atingimos o padrão ouro?

Mais perto do que na v5, e por um motivo diferente do que a v5 dava. A v5 disse que tudo que é verificável tinha gate. A v6 mostrou que ter gate não bastava: três gates aprovavam o que a fonte desmente e quatro reprovavam o que estava certo — e a maior parte da alucinação que passava vinha da própria esteira, de prompts que ensinavam rota errada ou diziam ao agente que ele não tinha como conferir o DS. Hoje o código BNCC, a rota e o componente são conferidos contra a fonte; os falsos bloqueios da execução de teste têm causa corrigida; e onde o regex não sabe ler, um juiz decide, sem poder inventar.
Como sistema, ainda não: nenhuma execução rodou depois das correções, e a precisão dos juízes de LLM é confiança, não medida.

Sobre o processo: as cinco versões anteriores perguntaram se cada gate existe, roda e aparece. A pergunta que achou mais defeito foi outra — **o gate diz a verdade?** —, e ela só pôde ser feita porque houve uma execução real para ler à mão e uma fonte oficial para comparar. A lição da v5 continua valendo, com um complemento: a pergunta certa ainda acha defeito, e **a mais produtiva é a que confronta o veredito com a fonte**.

Anexo — como reproduzir

```
python3 test_pipeline.py                       # 85 testes estruturais
python3 scripts/conferir_referencias.py        # fonte única x prompts
python3 scripts/catalogo.py listar             # estado do índice de missões
python3 scripts/reavaliar_gates.py --todas \
    gs://entre-redes-dev-adk-artifacts         # recomputa os gates (só lê)
python3 scripts/sincronizar_plataforma.py --help   # agora só mostra o uso
python3 scripts/sincronizar_plataforma.py --openapi openapi.json
                                               # só o OpenAPI e a lista de rotas
python3 scripts/sincronizar_design_system.py   # inventário do DS (273 comp.)
```