Auditoria do Padrão Ouro

O que os 28 gaps viraram, e o que ainda separa a esteira de uma geração confiável

Gerador de Missões Unooria — terceira leitura em quatro dias, revisada duas vezes

Data: 23 de setembro de 2026 | **Versão:** 3 (fim da tarde) | **Referência:** Rubrica v1.19 | **HEAD:** `0b186a1`

Corpus: 105 agentes na árvore · 49 de LLM · 69 prompts · 34 referências · 74 testes · 22 gates no dossiê · 14 sessões do bucket

---

1 Veredito

A resposta curta, na versão 3

Ainda não é padrão ouro, e o que falta no código agora cabe em dez minutos. A versão 2 terminou com um defeito de código aberto: o ticket de design cujo dono o despacho não conhecia (A-15). Corrigi-lo revelou que o problema era maior e mais grave — **desde 22/09 o retrabalho da banca não consertava nada** (A-15b), por um defeito introduzido na própria consolidação determinística da banca. Os dois estão fechados, com teste.

Uma verificação nova, feita pela primeira vez sobre a árvore inteira — *todo agente que pode ser reexecutado lê o que o gate pediu?* — achou mais dois casos da mesma família:

1. **A-16 — o brief de assets é reexecutado pela banca às cegas**: não lê o ticket nem o relatório. Real, raro (2 tickets nas 14 sessões). Cinco minutos.
2. **A-17 — latente**: no loop das avaliações, o revisor do one-pager não recebe a avaliação pedagógica. Só se manifesta com `AVALIACOES_MAX_RODADAS` > 1, que não é o caso em produção. Cinco minutos.

Fora do código, nada mudou desde a versão 2: **as cópias da plataforma seguem em 16/09** (por decisão), **o índice de missões de produção segue com 1 entrada** (espera autorização) e **nenhuma missão atravessou a esteira com o formato de hoje**.

Em uma frase: **falta fechar dois agentes que reescrevem sem ler o pedido, e depois provar que funciona.**

2 O que mudou desde a versão da manhã (v1) e desde a v2

A versão 1 deste relatório foi publicada às 12h06 (`bea95c5`), a versão 2 à tarde (`97a07bd`). Depois da v1, seis commits:

Commit	O que corrigiu
`a3c3a30`	Acessibilidade conferida em toda missão (D4a), não só nas que têm camada CAA (A-01).
`00b0a9a`	Lint do protótipo e brief de escopo no dossiê; o lint volta a rodar depois do retrabalho (A-03, A-10); brief ausente sai **amarelo**, não verde (A-13).
`744a96f`	Extrator do catálogo lê a coluna pelo nome; ambiente novo não sai vazio; aviso de índice cego chega ao micro-gate e ao dossiê, e vê o caso de produção (A-02, A-11, A-12).
`a2542c0`	Todo o rastro do Google Drive removido; trava contra instrução de ferramenta que o agente não tem (A-07).
`80e1bbb`	`sincronizar_plataforma.py` lê argumentos antes de gravar: `--help` executava a sincronização inteira (A-14).
`0b186a1`	**Depois da v2.** Despacho traduz o nome do dono pela fonte única; ticket sem rota vira pendência humana no dossiê; a consolidação da banca volta a entregar dono e id ao despacho; `brief-oficio` ganha rota e lê o ticket (A-15, A-15b).

Uma correção ao que a versão da manhã afirmou

A versão 1 disse que as 20 depreciações restantes do ADK "vêm do SDK e do Python 3.14, não do nosso código". **Estava errado.** Quinze das vinte vêm do nosso código: cada `SequentialAgent`, `LoopAgent` e `ParallelAgent` que a esteira monta — que o ADK depreciou em favor do motor de grafo `Workflow`. E o risco não está na depreciação, está na dependência sem teto (`google-adk>=2.8.0`): os testes rodam na 2.8.0, e a revisão ativa do Cloud Run, de 22/09, muito provavelmente roda a 2.9.2. O item foi **adiado por decisão** (seção 5.3).

3 Método

Três leituras anteriores foram cruzadas: o relatório de imersão de 20/09 (102 achados), a reavaliação de 22/09 e o relatório dos 28 gaps sistêmicos de 22/09. Contra elas, o repositório no `HEAD 0b186a1`: os 105 agentes da árvore real, os 69 prompts com `include` resolvido, as 34 referências, os validadores de `tools/` e os 74 testes. Cada gap foi verificado **no código, por linha**, não pelo commit que diz tê-lo corrigido.

Na tarde, três cruzamentos foram automatizados, e os três viraram teste: (i) todo `status_key` gravado por um agente aparece no dossiê; (ii) nenhum prompt instrui a usar ferramenta que o agente não recebe; (iii) todo dono citado num prompt de gate tem rota no despacho — revelou o A-15. Na v3, mais três perguntas sobre a árvore inteira: (iv) todo agente que um despacho reexecuta lê o ticket? (v) dentro de cada loop, o autor recebe o relatório de cada gate que o reprova? (vi) documento escrito por mais de um agente, em que o segundo apague o primeiro? As duas primeiras acharam o A-16 e o A-17; a terceira está limpa. As 14 sessões do bucket foram recomputadas duas vezes, em cópia local: **o bucket foi lido e nunca escrito**.

O que este relatório não afirma

Não afirma que as missões geradas são boas. A esteira verifica que a missão *declara* o que precisa declarar, de forma conferível; ela não sabe se a criança aprende. Com o protocolo de observação em sala removido por decisão, essa fronteira é permanente: **padrão ouro aqui significa que tudo que é verificável sobre o artefato está verificado, e o que não é está marcado como tal**.

4 Confronto: os 28 gaps, um a um

Gap	Título	Estado	Evidência verificada hoje
Frente I — Execução, fail-safe e robustez			
GAP-01	Fail-open nos gates de design e dev	fechado	`treat_indefinido_as_blocked` só sobrevive no comentário que explica por que saiu
GAP-02	Status vazio aceito na adequação	fechado	`SaidaDeLoopAgent`: chave ausente conta como reprovada
GAP-03	Teste principal quebrado em runtime	fechado	descoberta automática; 74 testes verdes
GAP-04	Sem persistência nem contagem de tokens	fechado	custo e tokens por agente no dossiê
GAP-05	Sem retry nem backoff	fechado	`HttpRetryOptions` em todos os agentes
GAP-06	118 avisos de depreciação do ADK	decisão	20 hoje, 15 do nosso código; dependência sem teto. Adiado por decisão
GAP-07	Governança de deploy	decisão	segredos fora da imagem; app de geração pública por decisão de produto
Frente II — Produto e pipeline pedagógico			
GAP-08	Beco sem saída pedagógico	fechado	`adequacao_report` chega ao gate final, à spec e ao PRD
GAP-09	Brief de escopo esvaziado no loop	fechado	separado antes do revisor; **e desde a tarde, ausente sai** amarelo
GAP-10	Sem guardrail de spoiler a jusante	fechado	dimensão D3b sobre o que vai à tela
GAP-11	Evidência inventada tarde pelo 16b	fechado	matriz nasce na spec e é conferida
GAP-12	Eixo BNCC incompatível no EM	fechado	referência explícita
GAP-13	Sem reexecução parcial de produto	aberto	`ETAPAS` sem `produto`
GAP-14	Réguas temporais conflitantes	fechado	T1/T2/T3 unificadas
GAP-15	Gate cego à própria rodada	fechado	rodada interpolada
Frente III — Design, imersão e experiência			
GAP-16	Retrabalho por tickets fantasma	fechado	dono traduzido pela fonte única; ticket sem rota vira pendência humana; banca volta a entregar o dono (A-15, A-15b)
GAP-17	Inversão de dependência no retrabalho	fechado	ordem conferida sem alterar
GAP-18	Protótipo auto-aprovado	fechado	lint no dossiê, com arquivo, e **relintado depois de todo retrabalho**
GAP-19	Notação Mermaid ambígua	fechado	`stateDiagram-v2` fixado
GAP-20	Severidade do pico emocional	fechado	`c10e98b`
GAP-21	Sem critérios de acessibilidade	fechado	D4a roda sempre: contraste, alvo, foco, nada-só-por-cor
GAP-22	2–4 por aparelho descartado	fechado	exceção que não se corta
GAP-23	Falsa dependência de ferramenta inativa	fechado	Stitch condicional tratado; Drive removido
Frente IV — Governança e contratos			
GAP-24	Catálogo incompleto trava o V5	parcial	código corrigido: 14 fichas cegas → 0 na reconstrução. **Índice de produção ainda com 1 entrada**
GAP-25	Enum de status desalinhado	fechado	15 valores com teste
GAP-26	Validação cega a pendências	fechado	validador vazio bloqueia em todos os nós
GAP-27	Drift das cópias da plataforma	decisão	sincronizadas por acidente e **descartadas por decisão**; seguem em `29afc8f`
GAP-28	Banca consolidada por LLM	fechado	consolidação determinística, 22 bloqueantes, DES-14 incluído

Estado	Manhã (v1)	Tarde (v2)	Fim da tarde (v3)
Fechado com evidência de código	21	22	**23**
Parcial	4	2	1
Aberto	2	1	1
Decisão de negócio ou adiamento consciente	1	3	3

O GAP-16 passou de fechado (v1) a parcial (v2) e de volta a fechado (v3): a verificação da tarde olhou mais fundo, achou o ralo, e fechá-lo expôs um defeito maior no mesmo lugar. O único parcial que resta é o GAP-24, pelo índice de produção.

5 Os achados, com o estado de cada um

5.1 Corrigidos hoje

Da lista da manhã

A-01 — Acessibilidade atrás da porta da CAA. As quatro contagens (contraste ≥ 4,5:1, alvo ≥ 64×64, ordem de foco, nada-só-por-cor) viviam na D8b, que só roda com CAA `concluido`; 4 das 14 missões saíram sem nenhuma verificação. Agora vivem na D4a, que roda sempre; a D8b cobra os mesmos mínimos também na rota não-leitora. `a3c3a30`.

A-03 — Gates fora do dossiê. O lint do protótipo e o brief de escopo entraram; o relatório do lint vira arquivo. Um teste cruza todo status gravado com o dossiê, para gate novo não nascer invisível. `00b0a9a`.

A-07 — Instrução para o Google Drive. Removida inteira — prompt, envelope, configuração, `.env.example`, README, pré-visualização no app. Trava nova impede instrução de Drive em qualquer prompt. `a2542c0`.

Achados novos da tarde, já corrigidos (v2 e v3)

A-10 — O lint do protótipo ficava velho. No retrabalho de design o protótipo era reconstruído e o lint não rodava de novo: o QA da rodada 2 lia o lint da rodada 1, sobre o HTML antigo, com a instrução de tratá-lo como fato. O lint entrou no pós-fixo do retrabalho. `00b0a9a`.

A-11 — O extrator do catálogo lia por posição. A causa real do GAP-24, mais funda que dado velho. O extrator esperava o slug na primeira coluna da linha que o agente 51 propõe; o modelo escreve a linha começando por `Ano`, sem slug. A linha era descartada em toda execução e `tipo_decisao` saía vazio — **mesmo reconstruído das sessões, o índice saía 14 de 14 cego**, e o registro automático repetia isso a cada missão nova. Agora a coluna é lida pelo nome, e o ambiente vem do campo `secao_ds` da spec. Reconstrução em cópia: **14 cegas → 0**. `744a96f`.

A-12 — O aviso de índice cego não chegava a ninguém, e era cego ao caso de produção. Ele só aparecia no relatório do catálogo, que roda depois do dossiê, e só contava linhas furadas — o bucket tinha 14 sessões e 1 missão indexada, zero linhas furadas, nenhum aviso. Agora compara sessões gravadas com o índice, vai antes da tabela que o micro-gate julga, e o dossiê mostra a base do V5 como gate. `744a96f`.

A-13 — Brief ausente saía verde. Quando o brief de escopo não vinha, o separador escrevia **aviso** no log e gravava o status do envelope do one-pager: `aprovado`. Pôr isso no dossiê seria exibir um verde que mente; agora sai **amarelo** com achado `secao-ausente`. `00b0a9a`.

A-14 — `--help` executava a sincronização. O script não tinha parser: qualquer argumento

era ignorado e ele começava apagando todos os `.md` do destino. Foi assim que as 47 cópias foram reescritas por acidente nesta auditoria. Agora `--help` mostra o uso e argumento desconhecido falha, sem gravar. `80e1bbb`.

A-15 — Ticket de design com dono sem rota era descartado em silêncio (achado na v2). O despacho casava só o nome literal do dono, e três casos sumiam sem aviso: ticket sem dono, dono que nenhum agente atende, mapa apontando para agente ausente. A tabela que traduz os nomes que os gates de fato escrevem — a banca escreveu `wireframes` 16 vezes, `spec` 15, `copy` 2 — existia na fonte única e nenhum código a lia; agora é lida. O que continua sem rota vai à mensagem e ao dossiê como pendência humana, com id, dono e motivo. `brief-oficio`, que a D7 do QA exige e que não estava nem na lista do próprio envelope do QA, ganhou rota antes da jornada e o prompt passou a ler o ticket. `0b186a1`.

A-15b — O retrabalho da banca não consertava nada desde 22/09 (achado ao corrigir o A-15, e o mais grave do dia). A consolidação determinística da banca, escrita em 22/09, montava o envelope que o despacho lê só com código, severidade, dimensão, classe e resumo — **descartava o `agente_responsavel` e o `id`**. Todo ticket da banca chegava sem dono e era jogado fora: a banca reprovava, o despacho respondia "nenhum ticket com dono executável", e a rodada seguinte julgava o mesmo documento. Agora o dono atravessa a consolidação, e o envelope da banca tem o campo obrigatório, com a lista fechada de onze donos. `0b186a1`.

5.2 Aberto no código

A-16 — O brief de assets é reexecutado pela banca às cegas (novo na v3)

O despacho da banca pode reexecutar seis agentes. Cinco deles leem o que a banca pediu: quatro de design leem o ticket (`{tickets_retrabalho?}`), e o handoff de dev tem uma rodada de correção explícita com o relatório consolidado da banca. **O brief de assets não lê nem um nem outro.** Quando a banca aponta um defeito de asset, ele é reexecutado, reescreve o documento sem saber o que corrigir, e a rodada seguinte julga algo parecido com o anterior.
Real e raro: nas 14 sessões a banca endereçou `brief-assets` duas vezes. *Correção:* o bloco "Rodada de correção" com `{tickets_retrabalho?}`, no molde dos outros cinco. Cinco minutos.

A-17 — Latente: o revisor do one-pager não recebe a avaliação pedagógica (novo na v3)

No loop das avaliações, a saída repete o loop quando a avaliação pedagógica reprova (`avaliacao_status` está entre as chaves que ela olha). Quem reescreve na rodada seguinte é o revisor do one-pager — e o prompt dele recebe o gate estrutural, o contrato de produto e a adequação, **não a avaliação pedagógica nem a experiência do estudante**. O loop repetiria por um motivo que o autor não leu.
Latente porque o loop roda uma vez só por padrão (`AVALIACOES_MAX_RODADAS=1`, sem sobrescrita na revisão ativa) e o revisor só entra da segunda em diante. Mas é o tipo de defeito que aparece no dia em que alguém aumenta as rodadas para melhorar a qualidade. *Correção:* os dois relatórios no prompt do revisor. Cinco minutos.

5.3 Abertos por decisão, ou fora do código

O que fica, e por quê

A-02 — Índice de produção com 1 entrada. O índice certo — 14 fichas das sessões do bucket, todas úteis ao V5 — está pronto em cópia local. Escrevê-lo no bucket depende de autorização. Até lá, uma geração no Cloud Run compara a missão nova contra uma só, mas o dossiê agora diz isso em **amarelo**. Localmente o índice foi mesclado: **28 fichas, 21 úteis** (eram 4). As 7 restantes são missões reais do catálogo oficial (Rastro do Boato, Manifesto IA, O Eco no Grupo…) cujas fichas nunca tiveram descoberta ou tipo de decisão escritos — preenchimento humano.

A-05 — Cópias da plataforma em `29afc8f` (16/09), plataforma em `71b4dbb` (18/09). A diferença é a exp-05 "Quem Mandou Isso?": 18 rotas, a porta 5184, o módulo novo. Com as cópias velhas, uma missão nova do 5º ano pode pedir a mesma porta ou propor rota que já existe. Sincronizadas por acidente, descartadas por decisão. Fechar é `python3 scripts/sincronizar_plataforma.py`, agora sem risco de disparar por engano.

A-06 — ADK sem teto de versão. Ver o quadro de correção na seção 2. Migrar para `Workflow` é reescrita de dias (21 construções, loops por aresta, 63 asserções de forma de árvore), com ganho funcional zero hoje. Adiado por decisão.

A-04 — Correção parcial sem etapa de produto e **A-08 — nota "v1.18" em `criterios-experiencia.md:5`**: não impedem uma geração confiável.

5.4 O que só uma execução responde

A-09 — O formato novo nunca rodou

Sete estruturas entraram entre 22/09 à noite e hoje à tarde: matriz de evidência, tabela de medidas com grau, sub-bloco 9f, juiz das perguntas, KPI em modo estrito cruzado com a spec, D4a, e o índice de missões que de fato alimenta o V5. A última execução completa (22/09, 1777 s, 44 chamadas, 5,8 M tokens) viu só as três primeiras. **Nenhum gate novo viu uma missão real.**

E há um limite do instrumento: o harness que recomputa os gates sobre o bucket ainda não cobre os gates da tarde — 9f, juiz, lint, brief, base do V5 aparecem como "—" nas 14 sessões, porque elas são anteriores a eles. A recontagem de hoje à tarde deu **os mesmos 272 achados da manhã, sem nenhuma mudança de veredito** — o que é esperado (as correções da tarde não mexem nos validadores que ele recomputa) e é, justamente, a prova de que ele sozinho não mede o que mudou.

6 A medição sobre as 14 sessões

Mudança de veredito (gravado em 22/09 → recomputado)	Sessões	Leitura
telemetria: amarelo → aprovado	5	erro de grafia deixou de virar erro de arquitetura
rastro de lacunas: bloqueado → amarelo ou aprovado	5	dono corrigido; placar deixou de ser pendência
PRD: bloqueado → amarelo	1	marcador de dono externo é compatível com **amarelo**
telemetria e PRD: passaram a acusar achado real	2	o que antes passava
evidência e KPI: — → bloqueado	14	gates que não existiam em 22/09

Seis bloqueios falsos deixaram de existir; dois achados verdadeiros passaram a aparecer. Os achados determinísticos somam 272, manhã e tarde. Os mais frequentes são formato novo (`gabarito-nao-declarado`, 14 de 14) e decisão humana (`lacuna:aberto:humano`, 14 de 14); os que medem qualidade de produto são reais e estão logo abaixo: `baseline-zero` em 9 sessões, `leitura-sem-leitor`, `tarefa-nao-atomica` e `numero-sem-origem` em 7 cada.

7 Onde a esteira está pronta

7.1 A fronteira que sustenta tudo

O que se confere contra lista, formato ou outro trecho do documento é determinístico; julgar o que o autor quis dizer fica com o LLM (`tools/bncc.py:11-13`). Das 53 verificações determinísticas medidas, **37 são fato e acertam 37/37**; as 16 de julgamento produziam 100% dos bloqueios falsos, e as 12 piores foram para juiz estruturado — o determinístico acha os candidatos, o juiz rebaixa ou troca o dono, nunca cria bloqueio sem citação.

7.2 O que a tarde acrescentou como princípio

Três das cinco correções da tarde são a mesma lição, e vale registrá-la: **ler por posição é o erro que mais se repete nesta esteira**. A §2 dos PRDs saiu em oito cabeçalhos diferentes; a linha de catálogo do agente 51 sai numa ordem que o prompt não pede. O que o modelo escreve deriva; o nome da coluna, não. `tools/kpis.py` e agora `tools/catalogo.py` leem pelo nome normalizado.

A outra lição: **cruzamento que acha defeito vira teste**. Status gravado × dossiê, instrução × ferramenta, argumento × escrita, dono × rota. Os dois cruzamentos da v3 que acharam o A-16 e o A-17 — agente reexecutado × ticket lido, autor × relatório do gate — ainda não são teste: viram junto com a correção.

8 Os marcos do plano, medidos

M	Marco	22/09	23/09 manhã	23/09 v3	Estado
M2	bloqueios por dono classificado errado	6	0	0	**fechado**
M3	`websocket-mencao` falso	8 de 14	0	0	**fechado**
M4	achados de campo órfão	68	0	0	**fechado**

M	Marco	22/09	23/09 manhã	23/09 v3	Estado
M5	banca cobrando o que o PRD entrega	24	0	0	fechado
M6	gates que aprovam com a chave vazia	8	0	0	fechado
M7	gates invisíveis no dossiê	4	3	0 *	fechado
M8	juízes sem regra de decisão	3	0	0	fechado
M9	juízes sem exigência de citação	3	0	0	fechado
M10	bloqueantes invisíveis ao consolidador	1	0	0	fechado
M11	fichas do catálogo que não sustentam o V5	10 de 10	10 de 15	7 de 28 local; produção: 1 entrada	parcial
M12	critérios de acessibilidade contáveis e sempre aplicados	0	4, só com CAA	4, sempre	fechado
M13	custo por missão	—	no dossiê	no dossiê	fechado
M14	suíte de testes	quebrada	64	74	fechado
M15	segredo fora da imagem	aberto	fechado	fechado	fechado
M16	tickets que somem sem rastro	não medido	não medido	0	fechado

* Fora do dossiê por construção, e registrados como tal no código: o status do registro no catálogo (roda depois do diagnóstico) e o do próprio diagnóstico.

9 O que fazer antes da próxima geração

1. **Fechar o A-16 e o A-17** — dois blocos de prompt, dez minutos no total. São os únicos defeitos de código abertos, e os dois são o mesmo: agente que reescreve sem ler o que o gate pediu.
2. **Decidir o índice de produção** (A-02) — subir as 14 fichas ao bucket, ou gerar localmente, onde o índice já está certo.
3. **Decidir as cópias da plataforma** (A-05) — se a próxima missão for do 5º ano, a porta 5184 e as rotas da exp-05 importam.
4. **Rodar uma missão de ponta a ponta** (A-09) e ler com olho humano o 9f, a tabela de KPIs, a D4a e o aviso do V5.

10 Conclusão

Atingimos o padrão ouro?

No código, a dez minutos disso. Tudo que é verificável sobre o artefato tem gate, aparece no dossiê e não aprova sem resposta; e, desde a v3, nenhum ticket some sem deixar rastro. Restam dois agentes que reescrevem sem ler o pedido do gate — um real e raro (A-16), um latente (A-17) — e a correção de cada um é um bloco de prompt.

Como sistema, ainda não, pelas mesmas três coisas da v2, nenhuma delas código: o gabarito da plataforma de 16/09, o índice de produção com uma entrada, e a ausência de uma execução real com o formato de hoje.

Uma observação sobre o próprio processo, porque ela vale para a próxima auditoria: **cada vez que um cruzamento sistemático foi feito sobre a árvore inteira, ele achou defeito** — e os mais graves (o índice 14 de 14 cego, o retrabalho da banca inerte) estavam atrás de correções que pareciam completas. O que os pegou não foi ler o código de novo, foi perguntar a mesma coisa a todos os agentes de uma vez. Por isso cada um vira teste — os dois da v3

entram junto com a correção do A-16 e do A-17.

Anexo — como reproduzir

```
python3 test_pipeline.py                       # 74 testes estruturais
python3 scripts/conferir_referencias.py        # fonte única x prompts
python3 scripts/catalogo.py listar             # estado do índice de missões
python3 scripts/reavaliar_gates.py --todas \
    gs://entre-redes-dev-adk-artifacts         # recomputa os gates (só lê)
python3 scripts/sincronizar_plataforma.py --help   # agora só mostra o uso
```