Auditoria do Padrão Ouro

O que os 28 gaps viraram, e o que ainda separa a esteira de uma geração confiável

Gerador de Missões Unooria — terceira leitura em quatro dias

Data: 23 de setembro de 2026 | **Referência:** Rubrica Unooria v1.19 | **HEAD:** `6b177f6`

Corpus: 103 agentes na árvore · 69 prompts · 34 referências · 64 testes · 14 sessões do bucket

---

1 Veredito

A resposta curta

Não estamos no padrão ouro, e estamos perto o suficiente para que a distância caiba numa lista de nove itens. Dos 28 gaps sistêmicos do relatório de 22/09, **21 estão fechados com evidência de código**, 4 estão parcialmente fechados, 2 seguem abertos e 1 foi fechado por decisão de negócio em sentido contrário ao recomendado. O que mudou de natureza é mais importante que a contagem: a esteira deixou de *aprovar no escuro*. Em 22/09 havia oito gates que aprovavam sem resposta, quatro que não apareciam no dossiê e uma banca consolidada por LLM que nunca reprovava. Hoje não há nenhum gate que aprove com a chave vazia, a consolidação é determinística sobre 22 critérios bloqueantes lidos dos próprios arquivos de critério, e o dossiê mostra 19 portões.

O que sobra é de outra ordem, e é honesto dizer: **o gerador ainda não foi visto funcionando com o formato novo**. As quatro estruturas mais recentes — matriz de evidência, tabela de medidas, sub-bloco 9f e a coerência KPI ↔ evento — nasceram entre ontem e hoje, e nenhuma missão foi gerada de ponta a ponta depois da última delas. Enquanto isso não acontecer, o que temos é um conjunto de gates testado por 64 testes estruturais e medido sobre 14 sessões antigas — o que é muito, e não é o mesmo que uma missão nova passando por eles.

2 Método, e o que este relatório não afirma

Três leituras foram cruzadas: o relatório de imersão de 20/09 (102 achados), a reavaliação de 22/09 (12 achados de imersão e 20 emendas, mais a Parte II com os 102) e o relatório dos 28 gaps sistêmicos de 22/09 à noite. Contra essas três, foi lido o repositório no `HEAD 6b177f6`: os 103 agentes da árvore real (não a documentação dela), os 69 prompts com `include` resolvido, as 34 referências, os validadores de `tools/` e os 64 testes.

Cada gap foi verificado **no código, por linha**, e não pelo commit que diz tê-lo corrigido — a diferença importa, porque três dos gaps de 22/09 tinham commit e continuavam abertos. Onde a verificação exigiu dado, o dado veio das 14 sessões do bucket, recomputadas em cópia local: **o bucket foi lido e nunca escrito**, como nas auditorias anteriores.

O que este relatório não afirma

Não afirma que as missões geradas são boas. A esteira verifica que a missão *declara* o que precisa declarar, de forma conferível; ela não sabe se a criança aprende. Os tetos da rubrica de ofício continuam marcados `[EXTRAPOLAÇÃO]` e `[CONVENÇÃO]` porque é isso que são — e a marca

é o que impede que virem fato por repetição. Com o protocolo de observação em sala removido por decisão de 23/09, essa fronteira ficou permanente: **padrão ouro aqui significa que tudo que é verificável sobre o artefato está verificado, e o que não é está marcado como tal**.

3 Confronto: os 28 gaps, um a um

Gap	Título	Estado	Evidência verificada hoje
Frente I — Execução, fail-safe e robustez			
GAP-01	Fail-open nos gates de design e dev	fechado	`treat_indefinido_as_blocked` não existe mais no código, só no comentário que explica por que saiu (`checkers.py:140`)
GAP-02	Status vazio aceito na adequação	fechado	`SaidaDeLoopAgent` deixou de usar `k in state`: chave ausente conta como reprovada
GAP-03	Teste principal quebrado em runtime	fechado	descoberta automática de `test_*`; 64 testes, todos verdes
GAP-04	Sem persistência nem contagem de tokens	fechado	`tokens`, `tokens_por_agente` e custo no dossiê (`diagnostico.py:321-342`)
GAP-05	Sem retry nem backoff	fechado	`HttpRetryOptions` em todos os agentes; teste dedicado
GAP-06	118 avisos de depreciação do ADK	parcial	20 avisos ao montar a árvore inteira, e os restantes vêm do SDK e do Python 3.14, não do nosso código
GAP-07	Governança de deploy	decisão	`.dockerignore` fecha `.env`, `.env.yaml` e os tokens do Miro; a autenticação do Cloud Run foi **revertida a pedido** — a app de geração é pública por decisão de produto
Frente II — Produto e pipeline pedagógico			
GAP-08	Beco sem saída pedagógico (agente 10)	fechado	`adequacao_report` chega aos três consumidores: gate final, spec e PRD
GAP-09	Brief de escopo esvaziado no loop	fechado	`A04bBriefEscopoSplit` grava `brief_escopo` antes do revisor tocar o one-pager
GAP-10	Sem guardrail de spoiler a jusante	fechado	dimensão D3b no QA aplica os quatro padrões do V1 sobre o que vai à tela
GAP-11	Evidência inventada tarde pelo 16b	fechado	a matriz nasce na spec (bloco 11) e o 16b copia; `tools/evidencia.py` confere
GAP-12	Eixo BNCC incompatível no EM	fechado	o anexo do EM não tem eixo, e a referência diz isso explicitamente
GAP-13	Sem reexecução parcial de produto	aberto	`ETAPAS = ("spec", "design", "dev", "transversal")` — `reexecucao.py:40`
GAP-14	Réguas temporais conflitantes	fechado	T1/T2/T3 unificadas em `literatura-cognitiva.md`
GAP-15	Gate cego à própria rodada	fechado	`gate_estrutural_rodada` interpolado e lido no prompt 11
Frente III — Design, imersão e experiência			

Gap	Título	Estado	Evidência verificada hoje
GAP-16	Retrabalho por tickets fantasma	fechado	`DespachoTicketsAgent` executa o despacho, com orçamento de reexecuções
GAP-17	Inversão de dependência no retrabalho	fechado	a ordem do código (copy antes de telas) é a correta; conferido sem alterar
GAP-18	Protótipo auto-aprovado	parcial	`PrototipoLintAgent` existe e roda — mas o status não aparece no dossiê e o relatório não vira arquivo (achado A-03)
GAP-19	Notação Mermaid ambígua	fechado	`stateDiagram-v2` fixado nos dois templates
GAP-20	Severidade do pico emocional	fechado	já corrigido em `c10e98b`
GAP-21	Sem critérios de acessibilidade	parcial	contraste $\geq$ 4,5:1, ordem de foco e alvo $\geq$ 64×64 são contáveis — mas só dentro da dimensão D8b, que não roda sem CAA (achado A-01)
GAP-22	2–4 por aparelho descartado	fechado	o cenário degradado entrou na exceção que não se corta por cota
GAP-23	Falsa dependência de ferramenta inativa	fechado	o QA recebe `stitch_mcp_mode` e confere na jornada quando o Stitch está desligado
Frente IV — Governança e contratos			
GAP-24	Catálogo incompleto trava o V5	aberto	10 de 15 entradas com `[preencher]`; 7 sem descoberta ou tipo de decisão; 4 sem slug (achado A-02)
GAP-25	Enum de status desalinhado	fechado	15 valores de status reconhecidos pelo código, com teste
GAP-26	Validação cega a pendências	fechado	validador vazio passou a bloquear em todos os nós; teste de truncamento
GAP-27	Drift das cópias da plataforma	parcial	o teste avisa (`71b4dbb` contra `29afc8f` lido), mas nada bloqueia nem alarma no CI
GAP-28	Banca consolidada por LLM	fechado	`ConsolidacaoBancaAgent` lê 22 bloqueantes dos próprios critérios, inclusive DES-14

O que a contagem esconde, e que é o ponto

Vinte e um fechados não é a notícia. A notícia é que **os três mecanismos que faziam a esteira aprovar no escuro foram desmontados**: (i) gate que aprova com a chave vazia — eram oito, hoje zero; (ii) veredito gravado como verde no dossiê — em 14 execuções nenhum gate de LLM apareceu amarelo embora os relatórios estivessem cheios de amarelo, e agora o roteamento e o dossiê usam leituras diferentes de propósito; (iii) consolidação da banca por LLM sobre 1,9 MB de contexto, que reprovou uma vez em quinze execuções. Enquanto esses três existiam, qualquer critério novo era decoração.

4 A medição sobre as 14 sessões do bucket

Os validadores determinísticos foram recomputados hoje sobre as 14 sessões, em cópia local — o bucket foi lido e nunca escrito. O que a recontagem mostra:

Mudança de veredito (22/09 gravado → recomputado hoje)	Sessões	Leitura
`telemetria_status`: amarelo → aprovado	5	erro de grafia deixou de virar erro de arquitetura
`rastro_lacunas_status`: bloqueado → amarelo	4	dono corrigido: pendência de plataforma não trava
`rastro_lacunas_status`: bloqueado → aprovado	1	o placar deixou de ser lido como pendência
`prd_status`: bloqueado → amarelo	1	marcador de dono externo é compatível com
`telemetria_status`: amarelo → **bloqueado**	1	achado real que antes passava
`prd_status`: aprovado → amarelo	1	idem
`evidencia_status` e `kpis_status`: — → bloqueado	14	gates que não existiam em 22/09

Seis bloqueios falsos deixaram de existir e dois achados verdadeiros passaram a aparecer. É a assimetria que se quer: afrouxar onde a régua estava errada e apertar onde ela era cega. O total de achados determinísticos recomputados é **272**, ainda alto — mas a composição mudou: os dois campeões de hoje são `gabarito-nao-declarado` (14 de 14) e `lacuna:aberto:humano` (14 de 14), que são *formato novo* e *decisão humana*, não defeito de missão. Os que medem qualidade de produto aparecem logo abaixo e são reais: `baseline-zero` em 9 sessões, `leitura-sem-leitor` em 7, `tarefa-nao-atomica` em 7, `numero-sem-origem` em 7.

Um achado sobre o próprio instrumento

O harness `reavaliar_gates.py` ainda não recomputa os dois gates das perguntas de produto (9f e o juiz) — eles aparecem como "—" nas duas colunas. A medição do 9f nas 14 sessões foi feita à parte e dá o mesmo resultado esperado: 14 bloqueios, todos por ausência do subbloco, que é formato de ontem. Atualizar o harness é meia hora e mantém a próxima auditoria comparável.

5 Os achados de hoje

Nove achados, dos quais quatro são novos — não aparecem em nenhum dos três relatórios anteriores — e cinco são remanescentes que a auditoria de hoje confirma que seguem abertos.

5.1 A-01 — A acessibilidade contável está atrás de uma porta que a maioria das missões não abre (novo)

O relatório de 22/09 registrou que `grep` por contraste ou WCAG em `prompts/design/` não retornava nada. Isso foi corrigido: contraste de texto $\geq$ 4,5:1 (e $\geq$ 3:1 em texto grande e ícone com significado), ordem de foco seguindo a ordem de leitura, e decisão alcançável sem depender de cor entraram como linhas contáveis sobre o frame construído.

O problema é onde entraram. As três vivem na dimensão **D8b do QA de design**, que começa com *"só quando o `camada_caa` vier `concluido`"*. Quando a camada CAA não se aplica — faixa mais velha, sem menção a CAA na spec ou no briefing — a dimensão fecha com um visto e uma nota, e **nenhuma outra dimensão confere contraste, foco ou alvo de toque**.

Medido nas 14 sessões do bucket: **4 declaram `nao_aplicavel`** de forma explícita (exp02em1b, exp09ef1b, exp04ef1b, exp06ef1b) e as outras 10 rodam a camada. Ou seja, quase um terço das missões geradas não teve uma única linha de acessibilidade auditada — e são justamente as do 6ž ano em diante, onde a leitura autônoma é pressuposta e o desenho fica mais denso.

Correção: mover as três linhas para uma dimensão que roda sempre (o QA de telas), deixando em D8b só o que é específico de comunicação alternativa: símbolo por conceito, chave de áudio, prancha fora do clone.

5.2 A-02 — O catálogo furado desliga o gate de semelhança (GAP-24, segue aberto)

O V5 do micro-gate existe para impedir que a missão nova repita uma anterior. Ele julga duas colunas: **descoberta central** e **tipo de decisão**. E tem uma válvula deliberada, que está certa: linha com campo `[preencher...]` *não sustenta reprovação*, porque não se reprova contra dado furado.

O estado do índice hoje, medido: **15 entradas, 10 com pelo menos um campo `[preencher do manifesto]`**. Sete delas têm furado exatamente `descoberta` ou `tipo_decisao`; quatro não têm nem `slug` — o campo que identifica a missão aparece literalmente como `[preencher do manifesto]`. Somando: o gate compara a missão nova contra cerca de metade do catálogo, e a válvula faz o resto passar em silêncio.

`scripts/catalogo.py reconstruir -seco` lê as 4 sessões locais e mantém 14 missões no índice, mas não preenche o que veio do catálogo legado em Markdown. **Nenhum gate acusa a incompletude** — e essa é a parte que o plano previa e que não foi feita.

5.3 A-03 — Três gates não aparecem no dossiê, e um deles reprova protótipo (novo)

Cruzando os `status_key` que os agentes de fato gravam com a lista `GATES` do diagnóstico: 24 status gravados, 19 no dossiê. Os que faltam:

- `prototipo_lint_status` — o lint determinístico do protótipo, criado justamente para fechar o GAP-18. Ele reprova um protótipo que não abre ou que não tem as telas do inventário, e **quem lê o dossiê não fica sabendo**. O relatório dele também não vira arquivo.
- `brief_escopo_status` — se o split falhar, o brief de escopo evapora, que é exatamente o GAP-09 voltando pela porta dos fundos.
- `catalogo_status` — o dossiê não diz se a missão foi registrada no índice.

O marco M7 do plano dizia "gates invisíveis no dossiê: 4 → 0". Foram de 4 para 3, e um dos três é novo.

5.4 A-04 — Correção parcial não cobre a etapa de produto (GAP-13, segue aberto)

`ETAPAS = ("spec", "design", "dev", "transversal")`. Quando o defeito está no one-pager — e vários dos achados das 14 sessões estão — não há como refazer só produto: ou se aceita o documento, ou se roda a esteira inteira, com o custo integral.

5.5 A-05 — As cópias da plataforma estão defasadas e nada trava (GAP-27, parcial)

O teste avisa em amarelo: a plataforma está em `71b4dbb` e as cópias que os juízes leem foram tiradas de `29afc8f`, de 16/09. Sete dias de deriva. Um juiz que confere a missão contra um gabarito velho produz dois erros simétricos: aprova o que a plataforma já não aceita e reprova o que ela passou a aceitar. O alarme existe, o bloqueio não.

5.6 A-06 — Depreciações do ADK (GAP-06, parcial)

De 118 para 20 ao montar a árvore inteira. As que restam vêm do SDK (`BaseAgentConfig`) e do Python 3.14, não do nosso código. É dívida de dependência, não de arquitetura.

5.7 A-07 — Instrução para uma ferramenta que a esteira não tem (novo)

O prompt de fechamento de lacunas manda criar um Google Docs na pasta compartilhada e devolver a URL. O agente **não recebe nenhuma ferramenta do Google Drive**; a variável interpolada já traz, como valor, a frase que explica que a ferramenta não está disponível. O bloco existe para ser desobedecido: toda execução cai no fallback e escreve "GDOCS: indisponível". É um parágrafo de instrução que só produz uma linha de ruído no relatório.

5.8 A-08 — Duas notas de versão defasadas

`criterios-experiencia.md:5` traz uma nota "v1.18" num corpo que é v1.19. (A ocorrência de "v1.13" em `candidatos-a-criterio.md` é citação histórica correta e não é achado.) Cosmético, mas é o tipo de coisa que faz um juiz hesitar sobre qual régua vale.

5.9 A-09 — O formato novo nunca rodou (novo, e é o mais importante)

As quatro estruturas que fecham os gaps mais caros — matriz de evidência, tabela de medidas com grau, sub-bloco 9f das perguntas de produto e a coerência KPI ↔ pergunta ↔ evento ↔ tela — foram escritas entre 22/09 à noite e 23/09 ao meio-dia. A única execução completa depois delas (1777 segundos, 44 chamadas, 5,8 M de tokens) validou as três primeiras; o 9f e o cruzamento com o PRD nasceram **depois** dela.

Recomputados hoje sobre as 14 sessões do bucket, os dois gates novos reprovam as 14 — sempre pelo mesmo motivo: a spec não traz o sub-bloco 9f. Isso é esperado e não é defeito das missões: é formato de ontem. Mas significa que **o gate nunca viu um 9f de verdade**, e a primeira geração vai ser, também, o primeiro teste dele.

6 Onde a esteira está pronta

6.1 A fronteira que sustenta tudo

O princípio que orienta o desenho está escrito em `tools/bncc.py:11-13` desde antes desta auditoria: *o que se confere contra lista, formato ou outro trecho do documento é determinístico; julgar o que o autor quis dizer fica com o LLM.* Medido nas 14 sessões: das 53 verificações determinísticas, **37 são fato e acertam 37/37, com zero falso positivo**; as 16 de julgamento produziam 100% dos bloqueios falsos. A correção foi mover as 12 piores para juiz estruturado, mantendo o determinístico como *recall* (acha candidatos) e o juiz como *precision* (rebaixa ou troca o dono, nunca cria bloqueio sem citação).

6.2 O caminho da pergunta de produto, fechado hoje

É a única cadeia da esteira que hoje tem gate em cada junta:

Onde	Quem confere	O que reprova
briefing do PO	`extrair_perguntas_do_briefing`	— (ausência é legítima)
spec, bloco 9f	`validar_9f` (determinístico)	menos de 5; decisão sem limiar; ação que a spec não emite; evento sem payload
spec, bloco 9f	juiz A15d (LLM, seed fixo)	pergunta que não muda decisão nossa; boletim disfarçado de produto
PRD, seção 2	`validar_kpis(prd, spec)`	pergunta da spec sem KPI; KPI citando pergunta que a spec não declara

O ponto que torna isso diferente do que existia: **a decisão de o que se quer saber acontece uma vez só**, na spec, com o PO podendo declarar no briefing ou validar as cinco propostas marcadas.

O redator do PRD transporta; não inventa. Em 22/09, 34 dos 49 KPIs gerados não tinham pergunta nem decisão, e 20 tinham baseline `0%` — que não é medida, é espaço em branco vestido de número.

7 Os marcos do plano, medidos

M	Marco	22/09	Hoje	Estado
M2	bloqueios por dono classificado errado	6	0	fechado
M3	`websocket-mencao` falso	8 de 14	0	fechado
M4	achados de campo órfão	68	0	fechado
M5	banca cobrando o que o PRD entrega	24	0	fechado
M6	gates que aprovam com a chave vazia	8	0	fechado
M7	gates invisíveis no dossiê	4	3	aberto
M8	juízes sem regra de decisão	3	0	fechado
M9	juízes sem exigência de citação	3	0	fechado
M10	bloqueantes invisíveis ao consolidador	1 (DES-14)	0	fechado
M11	catálogo que não sustenta o V5	10 de 10	10 de 15	aberto
M12	critérios de acessibilidade contáveis	0	4	parcial
M13	custo por missão	não medido	no dossiê	fechado
M14	suíte de testes	quebrada	64 verdes	fechado
M15	segredo fora da imagem	aberto	fechado	fechado

8 O que fazer antes da próxima geração

Em ordem, e com a estimativa honesta — nenhum destes é grande:

1. **Tirar a acessibilidade de trás da porta da CAA** (A-01). Meia hora. É o único desta lista que muda o que a criança recebe.
2. **Pôr os três gates no dossiê** e dar arquivo ao lint do protótipo (A-03). Vinte minutos. Sem isso, um protótipo reprovado passa despercebido.
3. **Fechar o catálogo ou fazer o gate acusar** (A-02). Duas horas: preencher as 10 linhas a partir dos `estado.json` das sessões, e um achado quando mais de um terço do índice estiver furado.
4. **Rodar uma missão de ponta a ponta** (A-09) e ler o 9f e a tabela de KPIs com olho humano. É o teste que nenhum teste substitui.

Os outros quatro achados (A-04 reexecução de produto, A-05 drift das cópias, A-06 depreciações, A-07 Google Drive) não impedem uma geração confiável e podem esperar a próxima janela.

9 Conclusão

Onde estamos

Em quatro dias a esteira saiu de *"os gates existem mas não reprovam"* para *"os gates reprovam, e o que eles reprovam é conferível"*. Os números que sustentam isso: 106 dos 283 achados das 14 sessões vinham de exigência que ninguém podia fechar, e foram cortados na raiz; oito gates que aprovavam vazio foram fechados; a consolidação da banca deixou de ser opinião de LLM sobre 1,9 MB e virou conta determinística sobre 22 critérios bloqueantes; e a telemetria de produto ganhou, pela primeira vez, uma cadeia inteira de gates — da pergunta do PO ao

evento que a responde.
Falta pouco, e o pouco que falta é específico: uma dimensão de acessibilidade no lugar errado, três gates fora do dossiê, um catálogo pela metade, e a única coisa que nenhuma auditoria substitui — **ver uma missão nova atravessar a esteira inteira com o formato de hoje**.

Anexo — como reproduzir

```
python3 test_pipeline.py                        # 64 testes estruturais
python3 scripts/conferir_referencias.py         # fonte única 𝔼 prompts
python3 scripts/catalogo.py listar              # estado do índice de missões
python3 scripts/reavaliar_gates.py --todas \
    gs://entre-redes-dev-adk-artifacts          # recomputa os gates (só lê)
```