# Auditoria do Padrão Ouro

## O que os 28 gaps viraram, e o que ainda separa a esteira de uma geração confiável

**Gerador de Missões Unooria — terceira leitura em quatro dias, revisada quatro vezes**

**Data:** 23 de setembro de 2026 | **Versão:** 5 (noite) | **Referência:** Rubrica v1.19 | **HEAD:** `d53cf06`

**Corpus:** 105 agentes na árvore · 49 de LLM · 69 prompts · 34 referências · 79 testes · 22 gates no dossiê · 14 sessões do bucket

---

## 1 Veredito

**A resposta curta, na versão 5**

**No código, sim — e desta vez sem nenhum gap aberto.** Dos 28 gaps sistêmicos, 24 estão fechados com evidência de código, 1 é parcial por um dado de produção que espera autorização, e 3 são decisões conscientes. O último aberto (GAP-13, correção parcial sem a etapa de produto) foi fechado — e fechá-lo mostrou que ele não era conveniência que faltava: **uma correção de mecânica pulava todos os gates de produto** e deixava o one-pager do PO contradizendo a spec.

Investigar esse gap revelou o defeito mais visível ao PO de toda a auditoria (A-19): **o material do Entre Redes anexado nunca chegava aos três agentes que o usam como fonte primária**. Das 7 sessões do bucket que o anexaram, 5 entregaram um one-pager resumido dizendo "material do bimestre não anexado". Corrigido: o material é guardado inteiro, sem limite de tamanho, e chega à spec, à avaliação pedagógica e ao resumido.

**Como sistema, ainda não**, pelas mesmas três coisas, nenhuma delas código:

1. **nenhuma missão atravessou a esteira com o formato de hoje** — e o risco de contexto (R-01) cresceu com o material inteiro indo a três agentes, sem que se possa medi-lo antes: as sessões antigas não guardaram o conteúdo dos anexos;
2. **as cópias da plataforma seguem em 16/09**, por decisão;
3. **o índice de missões de produção segue com 1 entrada**, à espera de autorização.

## 2 O que mudou desde a versão da manhã

A versão 1 deste relatório foi publicada às 12h06 (`bea95c5`), a versão 2 à tarde (`97a07bd`), a versão 3 no fim da tarde (`5d7ecda`), a versão 4 à noite (`9677b02`). Depois da v1, nove commits:

| Commit | O que corrigiu |
|---|---|
| `a3c3a30` | Acessibilidade conferida em toda missão (D4a), não só nas que têm camada CAA (A-01). |
| `00b0a9a` | Lint do protótipo e brief de escopo no dossiê; o lint volta a rodar depois do retrabalho (A-03, A-10); brief ausente sai **amarelo**, não verde (A-13). |
| `744a96f` | Extrator do catálogo lê a coluna pelo nome; ambiente novo não sai vazio; aviso de índice cego chega ao micro-gate e ao dossiê, e vê o caso de produção (A-02, A-11, A-12). |
| `a2542c0` | Todo o rastro do Google Drive removido; trava contra instrução de ferramenta que o agente não tem (A-07). |
| `80e1bbb` | `sincronizar_plataforma.py` lê argumentos antes de gravar: `--help` executava a sincronização inteira (A-14). |
| `0b186a1` | **Depois da v2.** Despacho traduz o nome do dono pela fonte única; ticket sem rota vira pendência humana no dossiê; a consolidação da banca volta a entregar dono e id ao despacho; `brief-oficio` ganha rota e lê o ticket (A-15, A-15b). |
| `5427dbf` | **Depois da v3.** O brief de assets lê o ticket da banca (A-16); o revisor do one-pager recebe a avaliação pedagógica e a experiência do estudante (A-17). As duas perguntas que os acharam viram teste. |
| `3d7639c` | **Depois da v4.** A correção parcial apaga tudo que a etapa regrava — seis gates novos tinham ficado fora, e o contador do juiz das perguntas sobrevivia (A-20); o critério de experiência declara a versão da rubrica no título (A-08). |
| `d53cf06` | O material anexado é guardado inteiro e chega à spec, à avaliação pedagógica e ao resumido (A-19); a correção ganha a etapa de produto, e a triagem a escolhe pelo lugar onde a decisão mora (A-04); os dois trechos inalcançáveis do A-18 saem. |

**Uma correção ao que a versão da manhã afirmou**

A versão 1 disse que as 20 depreciações restantes do ADK "vêm do SDK e do Python 3.14, não do nosso código". **Estava errado.** Quinze das vinte vêm do nosso código: cada `SequentialAgent`, `LoopAgent` e `ParallelAgent` que a esteira monta — que o ADK depreciou em favor do motor de grafo `Workflow`. E o risco não está na depreciação, está na dependência sem teto (`google-adk>=2.8.0`): os testes rodam na 2.8.0, e a revisão ativa do Cloud Run, de 22/09, muito provavelmente roda a 2.9.2. O item foi **adiado por decisão** (seção 5.3).

## 3 Método

Três leituras anteriores foram cruzadas: o relatório de imersão de 20/09 (102 achados), a reavaliação de 22/09 e o relatório dos 28 gaps sistêmicos de 22/09. Contra elas, o repositório no `HEAD d53cf06`: os 105 agentes da árvore real, os 69 prompts com `include` resolvido, as 34 referências, os validadores de `tools/` e os 79 testes. Cada gap foi verificado **no código, por linha**, não pelo commit que diz tê-lo corrigido.

Na tarde, três cruzamentos foram automatizados, e os três viraram teste: (i) todo `status_key` gravado por um agente aparece no dossiê; (ii) nenhum prompt instrui a usar ferramenta que o agente não recebe; (iii) todo dono citado num prompt de gate tem rota no despacho — revelou o A-15. Na v3, mais três perguntas sobre a árvore inteira: (iv) todo agente que um despacho reexecuta lê o ticket? (v) dentro de cada loop, o autor recebe o relatório de cada gate que o reprova? (vi) documento escrito por mais de um agente, em que o segundo apague o primeiro? As duas primeiras acharam o A-16 e o A-17; a terceira está limpa. Na v4, mais uma pergunta e uma medição: (vii) todo insumo que um prompt lê já foi escrito quando o agente roda — percorrendo a árvore na ordem de execução, separando o que chega de propósito só na rodada de correção; (viii) quanto contexto cada agente recebe, com os insumos reais da última execução completa. A (vii) voltou limpa. Na v5, ao fechar o GAP-13: (ix) toda chave que um agente da etapa grava é apagada quando a correção recomeça dali? — achou o A-20; (x) todo agente que cita o material anexado como fonte o recebe? — achou o A-19. Os dois viraram teste, e os dois foram vistos acusar o defeito no commit

anterior. As 14 sessões do bucket foram recomputadas duas vezes, em cópia local: **o bucket foi lido e nunca escrito**.

**O que este relatório não afirma**

Não afirma que as missões geradas são boas. A esteira verifica que a missão *declara* o que precisa declarar, de forma conferível; ela não sabe se a criança aprende. Com o protocolo de observação em sala removido por decisão, essa fronteira é permanente: **padrão ouro aqui significa que tudo que é verificável sobre o artefato está verificado, e o que não é está marcado como tal**.

## 4 Confronto: os 28 gaps, um a um

| Gap | Título | Estado | Evidência verificada hoje |
|---|---|---|---|
| **Frente I — Execução, fail-safe e robustez** | | | |
| GAP-01 | Fail-open nos gates de design e dev | fechado | `treat_indefinido_as_blocked` só sobrevive no comentário que explica por que saiu |
| GAP-02 | Status vazio aceito na adequação | fechado | `SaidaDeLoopAgent`: chave ausente conta como reprovada |
| GAP-03 | Teste principal quebrado em runtime | fechado | descoberta automática; 79 testes verdes |
| GAP-04 | Sem persistência nem contagem de tokens | fechado | custo e tokens por agente no dossiê |
| GAP-05 | Sem retry nem backoff | fechado | `HttpRetryOptions` em todos os agentes |
| GAP-06 | 118 avisos de depreciação do ADK | decisão | 20 hoje, 15 do nosso código; dependência sem teto. Adiado por decisão |
| GAP-07 | Governança de deploy | decisão | segredos fora da imagem; app de geração pública por decisão de produto |
| **Frente II — Produto e pipeline pedagógico** | | | |
| GAP-08 | Beco sem saída pedagógico | fechado | `adequacao_report` chega ao gate final, à spec e ao PRD |
| GAP-09 | Brief de escopo esvaziado no loop | fechado | separado antes do revisor; **e desde a tarde, ausente sai amarelo** |
| GAP-10 | Sem guardrail de spoiler a jusante | fechado | dimensão D3b sobre o que vai à tela |
| GAP-11 | Evidência inventada tarde pelo 16b | fechado | matriz nasce na spec e é conferida |
| GAP-12 | Eixo BNCC incompatível no EM | fechado | referência explícita |
| GAP-13 | Sem reexecução parcial de produto | fechado | etapa `produto` na correção, com o material da origem; a triagem a escolhe (A-04) |
| GAP-14 | Réguas temporais conflitantes | fechado | T1/T2/T3 unificadas |
| GAP-15 | Gate cego à própria rodada | fechado | rodada interpolada |
| **Frente III — Design, imersão e experiência** | | | |
| GAP-16 | Retrabalho por tickets fantasma | fechado | dono traduzido pela fonte única; ticket sem rota vira pendência humana; banca volta a entregar o dono (A-15, A-15b) |
| GAP-17 | Inversão de dependência no retrabalho | fechado | ordem conferida sem alterar |
| GAP-18 | Protótipo auto-aprovado | fechado | lint no dossiê, com arquivo, e **relintado depois de todo retrabalho** |
| GAP-19 | Notação Mermaid ambígua | fechado | `stateDiagram-v2` fixado |
| GAP-20 | Severidade do pico emocional | fechado | `c10e98b` |
| GAP-21 | Sem critérios de acessibilidade | fechado | D4a roda sempre: contraste, alvo, foco, nada-só-por-cor |

| Gap | Título | Estado | Evidência verificada hoje |
|---|---|---|---|
| GAP-22 | 2–4 por aparelho descartado | fechado | exceção que não se corta |
| GAP-23 | Falsa dependência de ferramenta inativa | fechado | Stitch condicional tratado; Drive removido |
| **Frente IV — Governança e contratos** | | | |
| GAP-24 | Catálogo incompleto trava o V5 | parcial | código corrigido: 14 fichas cegas → 0 na reconstrução. **Índice de produção ainda com 1 entrada** |
| GAP-25 | Enum de status desalinhado | fechado | 15 valores com teste |
| GAP-26 | Validação cega a pendências | fechado | validador vazio bloqueia em todos os nós |
| GAP-27 | Drift das cópias da plataforma | decisão | sincronizadas por acidente e **descartadas por decisão**; seguem em `29afc8f` |
| GAP-28 | Banca consolidada por LLM | fechado | consolidação determinística, 22 bloqueantes, DES-14 incluído |

| Estado | v1 | v2 | v3–v4 | v5 |
|---|---|---|---|---|
| Fechado com evidência de código | 21 | 22 | 23 | **24** |
| Parcial | 4 | 2 | 1 | 1 |
| Aberto | 2 | 1 | 1 | **0** |
| Decisão de negócio ou adiamento consciente | 1 | 3 | 3 | 3 |

O GAP-16 passou de fechado (v1) a parcial (v2) e de volta a fechado (v3): a verificação da tarde olhou mais fundo, achou o ralo, e fechá-lo expôs um defeito maior no mesmo lugar. O GAP-13 fechou na v5, e fechá-lo foi o que expôs o A-19. O único parcial que resta é o GAP-24, pelo índice de produção — que é dado, não código.

# 5 Os achados, com o estado de cada um

## 5.1 Corrigidos hoje

**Da lista da manhã**

**A-01 — Acessibilidade atrás da porta da CAA.** As quatro contagens (contraste ≥ 4,5:1, alvo ≥ 64×64, ordem de foco, nada-só-por-cor) viviam na D8b, que só roda com CAA `concluido`; 4 das 14 missões saíram sem nenhuma verificação. Agora vivem na D4a, que roda sempre; a D8b cobra os mesmos mínimos também na rota não-leitora. `a3c3a30`.

**A-03 — Gates fora do dossiê.** O lint do protótipo e o brief de escopo entraram; o relatório do lint vira arquivo. Um teste cruza todo status gravado com o dossiê, para gate novo não nascer invisível. `00b0a9a`.

**A-07 — Instrução para o Google Drive.** Removida inteira — prompt, envelope, configuração, `.env.example`, README, pré-visualização no app. Trava nova impede instrução de Drive em qualquer prompt. `a2542c0`.

**Achados novos da tarde, já corrigidos (v2 e v3)**

**A-10 — O lint do protótipo ficava velho.** No retrabalho de design o protótipo era reconstruído e o lint não rodava de novo: o QA da rodada 2 lia o lint da rodada 1, sobre o HTML antigo, com a instrução de tratá-lo como fato. O lint entrou no pós-fixo do retrabalho. `00b0a9a`.

**A-11 — O extrator do catálogo lia por posição.** A causa real do GAP-24, mais funda que dado velho. O extrator esperava o slug na primeira coluna da linha que o agente 51 propõe; o modelo escreve a linha começando por `Ano`, sem slug. A linha era descartada em toda execução e `tipo_decisao` saía vazio — **mesmo reconstruído das sessões, o índice saía 14 de 14 cego**, e o registro automático repetia isso a cada missão nova. Agora a coluna é lida pelo nome, e o ambiente vem do campo `secao_ds` da spec. Reconstrução em cópia: **14 cegas → 0**. `744a96f`.

**A-12 — O aviso de índice cego não chegava a ninguém, e era cego ao caso de produção.** Ele só aparecia no relatório do catálogo, que roda depois do dossiê, e só contava linhas furadas — o bucket tinha 14 sessões e 1 missão indexada, zero linhas furadas, nenhum aviso. Agora compara sessões gravadas com o índice, vai antes da tabela que o micro-gate julga, e o dossiê mostra a base do V5 como gate. `744a96f`.

**A-13 — Brief ausente saía verde.** Quando o brief de escopo não vinha, o separador escrevia **aviso** no log e gravava o status do envelope do one-pager: `aprovado`. Pôr isso no dossiê seria exibir um verde que mente; agora sai **amarelo** com achado `secao-ausente`. `00b0a9a`.

**A-14 — `--help` executava a sincronização.** O script não tinha parser: qualquer argumento era ignorado e ele começava apagando todos os `.md` do destino. Foi assim que as 47 cópias foram reescritas por acidente nesta auditoria. Agora `--help` mostra o uso e argumento desconhecido falha, sem gravar. `80e1bbb`.

**A-15 — Ticket de design com dono sem rota era descartado em silêncio** (achado na v2). O despacho casava só o nome literal do dono, e três casos sumiam sem aviso: ticket sem dono, dono que nenhum agente atende, mapa apontando para agente ausente. A tabela que traduz os nomes que os gates de fato escrevem — a banca escreveu `wireframes` 16 vezes, `spec` 15, `copy` 2 — existia na fonte única e nenhum código a lia; agora é lida. O que continua sem rota vai à mensagem e ao dossiê como pendência humana, com id, dono e motivo. `brief-oficio`, que a D7 do QA exige e que não estava nem na lista do próprio envelope do QA, ganhou rota antes da jornada e o prompt passou a ler o ticket. `0b186a1`.

**A-15b — O retrabalho da banca não consertava nada desde 22/09** (achado ao corrigir o A-15, e o mais grave do dia). A consolidação determinística da banca, escrita em 22/09, montava o envelope que o despacho lê só com código, severidade, dimensão, classe e resumo — **descartava o `agente_responsavel` e o `id`**. Todo ticket da banca chegava sem dono e era jogado fora: a banca reprovava, o despacho respondia "nenhum ticket com dono executável", e a rodada seguinte julgava o mesmo documento. Agora o dono atravessa a consolidação, e o envelope da banca tem o campo obrigatório, com a lista fechada de onze donos. `0b186a1`.

## 5.2 No código: nenhum defeito aberto

**Fechados na v4**

Os dois que a v3 deixou abertos foram fechados em `5427dbf`:

**A-16 — O brief de assets era reexecutado pela banca às cegas.** Dos seis agentes que a banca reexecuta, era o único que não lia nem o ticket nem o relatório. Ganhou a rodada de correção com `{tickets_retrabalho?}`, no molde dos outros cinco.

**A-17 — O revisor do one-pager não recebia a avaliação pedagógica.** O loop das avaliações repete quando ela reprova, e quem reescreve não a lia. Recebe agora a avaliação pedagógica e a experiência do estudante, e aplica os "**vermelho** obrigatórios — correção pronta" de cada uma como aplica o complemento do gate.

As regras que acharam os dois viraram teste, e foi conferido que elas **pegam** os dois defeitos quando rodadas contra os prompts do commit anterior — um teste que nunca falha não prova nada.

## Corrigidos na v5

**A-19 — O material anexado nunca chegava a quem o usa como fonte** (novo na v5, e o mais visível ao PO). O conteúdo dos anexos existia só na mensagem, que só o núcleo narrativo lê; a sessão guardava os nomes dos arquivos. A spec, a avaliação pedagógica e o one-pager resumido são instruídos a usar o material do Entre Redes como fonte primária de código BNCC e de componente curricular, e nenhum dos três o via. Medido nas 14 sessões: **das 7 que anexaram o material do Entre Redes, 5 entregaram um resumido dizendo "material do bimestre não anexado"**. Agora o texto integral de cada anexo — PDF inclusive, pelo texto extraído — é guardado com a sessão, sem limite de tamanho, sai como artefato (`produto/00-material-anexado.md`) e chega aos três. `d53cf06`.

**A-04 — Uma correção de mecânica pulava todos os gates de produto** (era o GAP-13, e era pior que conveniência). A triagem mandava para `spec` os pedidos de mecânica, etapas e narrativa, e a correção a partir da spec não refaz o one-pager nem passa pelo gate estrutural, pela avaliação pedagógica ou pelo gate final. A spec mudava, o one-pager do PO ficava como estava, e a regra nova não era avaliada por ninguém. A correção ganha a etapa `produto`, que refaz a missão desde o núcleo, com o material da geração original remontado na mensagem, e a triagem passa a decidir pelo lugar onde a decisão mora. Sessão antiga sem material guardado usa o que o pedido anexar; sem nenhum dos dois, a correção é **recusada antes de tocar a sessão**, com a lista dos arquivos a anexar de novo. `d53cf06`.

**A-20 — A correção parcial não apagava o que os gates novos gravam** (achado ao preparar o A-04, e introduzido nesta própria auditoria). Seis gates criados em 22–23/09 tinham ficado fora das listas do que a correção apaga antes de refazer uma etapa. O que doía era o contador de rodadas do juiz das perguntas: uma correção a partir da spec começava com as rodadas já esgotadas, e não havia rodada de correção. O teste novo percorre cada etapa e exige que toda chave gravada esteja na lista. `3d7639c`.

**A-08 — A versão da rubrica no critério de experiência** (descrição corrigida). A v4 descrevia a nota "v1.18" como defeito; ela é histórico legítimo e ficou. O defeito era outro: os outros três critérios de produto declaram *Rubrica v1.19* no título, e este não — quem o lia via duas notas de versão e nenhuma dizendo qual vale. Um teste exige que os quatro declarem a mesma. `3d7639c`.

## A-18 — Duas rodadas de correção que o fluxo não alcançava: removidas na v5

A pergunta (vii) da v4 achou dois trechos de prompt que liam um insumo que nunca chega: a experiência do estudante lendo o relatório do gate final "quando já houve uma passada", e a adequação pedagógica lendo o ambiente simulado "quando já decidido". A v4 afirmou que os dois ficariam vivos com a correção de produto. **Não ficam**: a correção de produto apaga justamente esses relatórios antes de refazer, porque refazer produto é refazê-lo sobre o mesmo pedido e o mesmo material, não sobre o veredito anterior. Mantê-los seria o caso do Google Drive outra vez — instrução que nunca se exerce. Saíram em `d53cf06`.

## R-01 — Risco medido: o contexto dos dois agentes que escrevem as entregas

Com os insumos reais da última execução completa (exp06ef1b, 22/09), o contexto de cada agente de LLM:

| Agente | Total | Prompt | Insumos |
|---|---|---|---|
| Redator do PRD | 784 KB | 393 KB | 391 KB |
| Handoff de dev | 668 KB | 303 KB | 365 KB |
| Banca — técnica e arquitetura | 597 KB | 336 KB | 260 KB |
| Banca — dados e LGPD | 553 KB | 293 KB | 260 KB |
| Banca — pedagogia e BNCC | 407 KB | 147 KB | 260 KB |
| Mediana dos 33 agentes | 189 KB | | |

Cabe no modelo — são cerca de 200 mil tokens, bem abaixo do limite. O risco é outro: **regra no meio de um prompt muito longo sendo ignorada**. Há um caso documentado: o commit `fd68d9b` existiu porque o redator do PRD não seguia a regra do KPI no lugar onde ela estava escrita, e ela teve de ir para onde ele "de fato olha". Não é verificável sem rodar. *O que fazer:* na primeira execução, conferir se o PRD segue as regras 8 e as de consistência interna; se não seguir, o corte é nas referências da plataforma (393 KB fixos), não nos insumos da missão.

**Na v5 o risco cresceu, por decisão.** O material anexado vai inteiro, sem limite, a três agentes — spec, avaliação pedagógica e resumido. Quanto isso soma não dá para medir antes: as 14 sessões guardaram só os nomes dos anexos, e cinco delas anexaram de 42 a 45 documentos de uma geração anterior. A primeira execução com material mede.

## 5.3 Abertos por decisão, ou fora do código

### O que fica, e por quê

**A-02 — Índice de produção com 1 entrada.** O índice certo — 14 fichas das sessões do bucket, todas úteis ao V5 — está pronto em cópia local. Escrevê-lo no bucket depende de autorização. Até lá, uma geração no Cloud Run compara a missão nova contra uma só, mas o dossiê agora diz isso em **amarelo**. Localmente o índice foi mesclado: **28 fichas, 21 úteis** (eram 4). As 7 restantes são missões reais do catálogo oficial (Rastro do Boato, Manifesto IA, O Eco no Grupo…) cujas fichas nunca tiveram descoberta ou tipo de decisão escritos — preenchimento humano.

**A-05 — Cópias da plataforma em `29afc8f` (16/09), plataforma em `71b4dbb` (18/09).** A diferença é a exp-05 "Quem Mandou Isso?": 18 rotas, a porta 5184, o módulo novo. Com as cópias velhas, uma missão nova do 5º ano pode pedir a mesma porta ou propor rota que já existe. Sincronizadas por acidente, descartadas por decisão. Fechar é `python3 scripts/sincronizar_plataforma.py`, agora sem risco de disparar por engano.

**A-06 — ADK sem teto de versão.** Ver o quadro de correção na seção 2. Migrar para `Workflow` é reescrita de dias (21 construções, loops por aresta, 63 asserções de forma de árvore), com ganho funcional zero hoje. Adiado por decisão.

## 5.4 O que só uma execução responde

### A-09 — O formato novo nunca rodou

Sete estruturas entraram entre 22/09 à noite e hoje à tarde: matriz de evidência, tabela de medidas com grau, sub-bloco 9f, juiz das perguntas, KPI em modo estrito cruzado com a spec, D4a, e o índice de missões que de fato alimenta o V5. A última execução completa (22/09, 1777 s, 44 chamadas, 5,8 M tokens) viu só as três primeiras. **Nenhum gate novo viu uma**

**missão real.**
E há um limite do instrumento: o harness que recomputa os gates sobre o bucket ainda não cobre os gates da tarde — 9f, juiz, lint, brief, base do V5 aparecem como "—" nas 14 sessões, porque elas são anteriores a eles. A recontagem de hoje à tarde deu **os mesmos 272 achados da manhã, sem nenhuma mudança de veredito** — o que é esperado (as correções da tarde não mexem nos validadores que ele recomputa) e é, justamente, a prova de que ele sozinho não mede o que mudou.

# 6 A medição sobre as 14 sessões

| **Mudança de veredito (gravado em 22/09 → recomputado)** | **Sessões** | **Leitura** |
|---|---|---|
| telemetria: amarelo → aprovado | 5 | erro de grafia deixou de virar erro de arquitetura |
| rastro de lacunas: bloqueado → amarelo ou aprovado | 5 | dono corrigido; placar deixou de ser pendência |
| PRD: bloqueado → amarelo | 1 | marcador de dono externo é compatível com **amarelo** |
| telemetria e PRD: passaram a acusar achado real | 2 | o que antes passava |
| evidência e KPI: — → bloqueado | 14 | gates que não existiam em 22/09 |

**Seis bloqueios falsos deixaram de existir; dois achados verdadeiros passaram a aparecer.** Os achados determinísticos somam 272, manhã e tarde. Os mais frequentes são formato novo (`gabarito-nao-declarado`, 14 de 14) e decisão humana (`lacuna:aberto:humano`, 14 de 14); os que medem qualidade de produto são reais e estão logo abaixo: `baseline-zero` em 9 sessões, `leitura-sem-leitor`, `tarefa-nao-atomica` e `numero-sem-origem` em 7 cada.

# 7 Onde a esteira está pronta

## 7.1 A fronteira que sustenta tudo

*O que se confere contra lista, formato ou outro trecho do documento é determinístico; julgar o que o autor quis dizer fica com o LLM* (`tools/bncc.py:11-13`). Das 53 verificações determinísticas medidas, **37 são fato e acertam 37/37**; as 16 de julgamento produziam 100% dos bloqueios falsos, e as 12 piores foram para juiz estruturado — o determinístico acha os candidatos, o juiz rebaixa ou troca o dono, nunca cria bloqueio sem citação.

## 7.2 O que a tarde acrescentou como princípio

Três das cinco correções da tarde são a mesma lição, e vale registrá-la: **ler por posição é o erro que mais se repete nesta esteira**. A §2 dos PRDs saiu em oito cabeçalhos diferentes; a linha de catálogo do agente 51 sai numa ordem que o prompt não pede. O que o modelo escreve deriva; o nome da coluna, não. `tools/kpis.py` e agora `tools/catalogo.py` leem pelo nome normalizado.

A outra lição: **cruzamento que acha defeito vira teste**. Status gravado × dossiê, instrução × ferramenta, argumento × escrita, dono × rota, agente reexecutado × ticket lido, autor × relatório do gate, chave gravada × chave apagada na correção, citação do material × material recebido. Todos são teste.

## 8 Os marcos do plano, medidos

| M | Marco | 22/09 | 23/09 manhã | 23/09 v5 | Estado |
|---|---|---|---|---|---|
| M2 | bloqueios por dono classificado errado | 6 | 0 | 0 | **fechado** |
| M3 | `websocket-mencao` falso | 8 de 14 | 0 | 0 | **fechado** |
| M4 | achados de campo órfão | 68 | 0 | 0 | **fechado** |
| M5 | banca cobrando o que o PRD entrega | 24 | 0 | 0 | **fechado** |
| M6 | gates que aprovam com a chave vazia | 8 | 0 | 0 | **fechado** |
| M7 | gates invisíveis no dossiê | 4 | 3 | 0 * | **fechado** |
| M8 | juízes sem regra de decisão | 3 | 0 | 0 | **fechado** |
| M9 | juízes sem exigência de citação | 3 | 0 | 0 | **fechado** |
| M10 | bloqueantes invisíveis ao consolidador | 1 | 0 | 0 | **fechado** |
| M11 | fichas do catálogo que não sustentam o V5 | 10 de 10 | 10 de 15 | 7 de 28 local; produção: 1 entrada | **parcial** |
| M12 | critérios de acessibilidade contáveis e sempre aplicados | 0 | 4, só com CAA | 4, sempre | **fechado** |
| M13 | custo por missão | — | no dossiê | no dossiê | **fechado** |
| M14 | suíte de testes | quebrada | 64 | 79 | **fechado** |
| M15 | segredo fora da imagem | aberto | fechado | fechado | **fechado** |
| M16 | tickets que somem sem rastro | não medido | não medido | 0 | **fechado** |
| M17 | agentes que reescrevem sem ler o pedido do gate | não medido | não medido | 0 | **fechado** |
| M18 | agentes que citam o material anexado como fonte sem recebê-lo | não medido | não medido | 0 (eram 3) | **fechado** |
| M19 | gates de produto que uma correção de mecânica pula | não medido | não medido | 0 (eram todos) | **fechado** |

* Fora do dossiê por construção, e registrados como tal no código: o status do registro no catálogo (roda depois do diagnóstico) e o do próprio diagnóstico.

## 9 O que fazer antes da próxima geração

1. **Decidir o índice de produção** (A-02) — subir as 14 fichas ao bucket, ou gerar localmente, onde o índice já está certo.
2. **Decidir as cópias da plataforma** (A-05) — se a próxima missão for do 5º ano, a porta 5184 e as rotas da exp-05 importam.
3. **Rodar uma missão de ponta a ponta** (A-09) e ler com olho humano o 9f, a tabela de KPIs, a D4a e o aviso do V5 — e conferir o R-01: se o PRD e o handoff seguem as regras que estão no meio dos prompts deles, e se a spec, a avaliação e o resumido, agora com o material inteiro, também seguem. Com o material do Entre Redes anexado, o resumido tem de trazer o componente curricular do bimestre, não "material não anexado".

# 10 Conclusão

**Atingimos o padrão ouro?**

**No código, sim, e sem gap aberto.** Tudo que é verificável sobre o artefato tem gate, aparece no dossiê e não aprova sem resposta; nenhum ticket some sem rastro; quem reescreve lê o que o gate pediu; o material que o PO anexa chega a quem o usa como fonte; e uma correção passa pelos mesmos gates que a geração, a partir da etapa onde a decisão mora. Dos 28 gaps, nenhum está aberto: o único parcial é um dado de produção que espera autorização.
**Como sistema, ainda não**, por três coisas que não são código: nenhuma execução real com o formato de hoje, o gabarito da plataforma de 16/09, e o índice de produção com uma entrada. A primeira decide, e é a única que mede o R-01 — agora maior, com o material inteiro.
Sobre o processo, uma última observação. A v4 concluiu que o que sobrava "não se acha mais olhando o código". **Estava errada**: fechar o último gap aberto achou mais dois defeitos, e um deles era o mais visível ao PO de toda a auditoria. O que eles tinham em comum é o ângulo que os achou: olhar a esteira pelo lado da correção — o que ela precisa guardar para refazer uma etapa, e o que ela apaga antes — um ângulo que nenhuma pergunta anterior tinha usado. Um dos dois nem era da correção: o material que não chegava à spec faltava em toda geração normal, e só apareceu quando se perguntou o que refazer o produto exigiria. A lição que fica não é que o código está limpo; é que **a pergunta certa ainda acha defeito, e a execução real é a próxima pergunta**.

## Anexo — como reproduzir

```
python3 test_pipeline.py                        # 79 testes estruturais
python3 scripts/conferir_referencias.py         # fonte única x prompts
python3 scripts/catalogo.py listar              # estado do índice de missões
python3 scripts/reavaliar_gates.py --todas \
    gs://entre-redes-dev-adk-artifacts          # recomputa os gates (só lê)
python3 scripts/sincronizar_plataforma.py --help   # agora só mostra o uso
```