Unooria — Gerador de Missões

Proposta de Emendas

para Missões Imersivas

Modificações nos prompts, referências e critérios para que a esteira gere missões que prendem, que medem e que cabem na escola pública brasileira

Responde a: Auditoria de Imersão, versão 1.0, de 20 de setembro de 2026
Conteúdo: 20 emendas em 3 ondas, com redação pronta, teste falsificável e indicador de campo
Tese: acrescentar à régua do limite uma régua do agarre, sem inventar número sem fonte

Data: 20 de setembro de 2026 • **Versão:** 1.0

Documento de proposta. Não altera nenhum artefato da esteira; cada emenda está redigida para ser aplicada por decisão humana.

Sumário

1 Sumário executivo **2**
1.1 O que esta proposta faz . . . 2
1.2 Do achado à emenda . . . 2
1.3 O que a proposta deliberadamente não faz . . . 3

2 Como ler cada emenda **3**

3 Onda 1 — Correções mecânicas, sem decisão pedagógica **4**

4 Onda 2 — Emendas que a casa já aprovou **8**

5 Onda 3 — Decisões de produto **10**

6 Como saber se as emendas funcionaram **18**
6.1 O que "missão mensurável" significa aqui . . . 18
6.2 Indicadores por emenda . . . 18
6.3 A matriz de cobertura depois das emendas . . . 19

7 Sequência, esforço e riscos **20**
7.1 Ordem recomendada . . . 20
7.2 Esforço por emenda . . . 21
7.3 Riscos da proposta como um todo . . . 21
7.4 O que fica em aberto . . . 22

8 Anexo — Changelog proposto para a rubrica v1.19 **22**

1 Sumário executivo

1.1 O que esta proposta faz

A auditoria concluiu que a esteira tem uma boa *teoria do limite* (o que não sobrecarrega a criança) e nenhuma *teoria do agarre* (o que a prende), e que o cenário brasileiro está bem medido na infraestrutura e ausente no comportamento da criança. Esta proposta responde às duas lacunas com três compromissos:

1. Um piso, além do teto. Toda missão passa a ter que provar que exige o bastante da faixa, em todas as faixas, com um teste que não depende de gosto: o estudante que faz o mínimo chega a um resultado diferente do estudante que investiga. É a variável que a literatura associa à aprendizagem em jogos educacionais, e é a que a esteira hoje não mede.
2. Imersão como instrumento de medida, declarada e verificável. A tese que já vive em um critério não bloqueante passa a ser premissa lida por todo agente que constrói ou julga tela. A fidelidade deixa de depender de uma tabela vazia e de uma intuição sobre "o que a criança usa": a tabela é preenchida e a intuição é substituída por levantamento nacional com desagregação por idade.
3. A escola pública como caminho principal, não como *fallback*. O banco curado vira o padrão nos anos iniciais; a conta compartilhada ganha protocolo; a defasagem de leitura do 9º ano e do Médio ganha cláusula; e os cinco achados que convergem nos anos iniciais viram um pacote único com dono.

Cada emenda carrega, além da redação, **um teste falsificável no gate** e **um indicador observável em campo**. Isso é o que torna a proposta mensurável: nenhum critério novo entra sem que se saiba, de antemão, o que confirmaria ou refutaria sua utilidade.

1.2 Do achado à emenda

Achado	Emenda que o resolve	Onda	Decisão exigida
A1	E-01 Roblox sai da lista fechada em todos os lugares	**Onda 1**	nenhuma
A5	E-02 Tabela de ausências preenchida, uma linha por seção	**Onda 1**	conferência no storybook
A7	E-03 Catálogo atualizado, com colunas de progressão	**Onda 1**	nenhuma
A6	E-04 A régua chega ao design por um resumo operacional gerado	**Onda 1**	nenhuma
novo	E-05 Deriva de números fora da fonte única	**Onda 1**	nenhuma
A11	E-06 Uso de plataforma por idade entra na régua e nos testes 2.1 e 6.4	**Onda 1**	nenhuma
A8	E-07 Critério 2.7: a mecânica sustenta a descoberta (C1)	**Onda 2**	priorização
A8	E-08 Falha de plataforma nunca vira decisão do estudante (C7)	**Onda 2**	priorização
A8	E-09 Não-negociável de ofício com mecanismo, sem reordenar a esteira (C3)	**Onda 2**	priorização

Achado	Emenda que o resolve	Onda	Decisão exigida
A2	E-10 A regra comparativa do pico passa a bloquear	**Onda 3**	produto
A4	E-11 Simulação diegética obrigatória, com três testes	**Onda 3**	produto
A12	E-12 Posse da conta no cenário compartilhado	**Onda 3**	produto
A9	E-13 Piso de desafio por faixa, em todas as faixas	**Onda 3**	produto e pedagogia
§4.3	E-14 Premissa da imersão como instrumento, propagada	**Onda 3**	produto
§5.6	E-15 Banco curado como caminho principal nos anos iniciais	**Onda 3**	produto
§5.5	E-16 Leitura não monotônica: cláusula para 9º ano e Médio	**Onda 3**	pedagogia
A7, §4.5	E-17 Progressão na trilha como critério	**Onda 3**	produto
A9–A12	E-18 Pacote anos iniciais, consolidado	**Onda 3**	produto e pedagogia
A10, A2	E-19 Observação de campo com instrumento e protocolo	**Onda 3**	campo
A3	E-20 O que a esteira faz com critérios que não são dela	**Onda 3**	produto

1.3 O que a proposta deliberadamente não faz

- **Não muda o framework de seis etapas.** O achado A10 é uma pergunta empírica, e a resposta certa é medir (E-19), não redesenhar por precaução.
- **Não reescreve os critérios do banco de dev.** `criterios-dev.md` declara que os 72 critérios são "do gate `/validar-missao` do time de dev", lidos em uma versão datada. Mudar a severidade de DES-03 lá é decisão de outro time; o que a esteira pode fazer é garantir a mesma coisa a montante (E-20).
- **Não inventa número novo.** Toda quantidade nova nesta proposta carrega a marca **[DADO DIRETO]**, **[EXTRAPOLAÇÃO]** ou **[CONVENÇÃO]**, na disciplina de `literatura-cognitiva.md`.
- **Não promove O2–O5 a bloqueante antes da calibragem.** Só a regra comparativa do pico, que não depende de número, sobe agora (E-10).
- **Não infla o contexto dos prompts de design com a referência inteira.** A régua chega por um resumo gerado da fonte única (E-04), no mesmo padrão em que a lista BNCC em markdown é gerada do JSON.

2 Como ler cada emenda

Toda emenda tem a mesma anatomia, para que possa ser aprovada, recusada ou adiada item a item:

- **Resolve:** o achado da auditoria, e a seção onde está a evidência.
- **Arquivos:** exatamente o que muda, com o nome do arquivo e, quando cabe, a linha.

- **Redação atual / proposta:** o texto como está e o texto como ficaria. A proposta preserva a forma da rubrica (número, negrito, tipo, teste prático) para ser colada sem reformatar.
- **Teste falsificável:** a pergunta que o avaliador responde com sim ou não, citando o documento. Item que precisa de debate para responder está mal redigido, regra que a própria rubrica de ofício impõe.
- **Como medir se funcionou:** o indicador observável, nos relatórios da esteira ou em campo, que confirmaria ou refutaria a emenda. Este bloco é o que separa proposta de opinião.
- **Custo e risco:** tamanho da mudança e o que pode dar errado.

Três regras de redação valem para tudo o que segue. **Um critério novo só entra com teste de trinta segundos**, no padrão de `candidatos-a-criterio.md`. **Severidade é proporcional à evidência**: dado direto sustenta reprovação, extrapolação sustenta alerta, convenção só sustenta reprovação quando é comparativa e não numérica. **A esteira lê `severidade: "bloqueio"`**: o filtro de retrabalho em `agents/checkers.py` roteia por essa string, então toda emenda que quer bloquear precisa fazer o agente emitir exatamente esse valor, e nenhuma emenda exige mudança no código Python.

3 Onda 1 — Correções mecânicas, sem decisão pedagógica

Seis emendas que alinham o sistema ao que ele já decidiu. Nenhuma muda régua ou tese.

E-01 — Roblox sai da lista fechada em todos os lugares — Onda 1

Resolve: A1. `ambientes.md:27` já decidiu ("Roblox saiu"), o prompt do gate já avisa no passo 2, e o critério que o mesmo prompt inclui ainda lista Roblox como ambiente válido.
Arquivos: `criterios-gate-estrutural.md` (linha 21 e lista de falso-positivos), `criterios-experiencia.md` (linha 49), `catalogo-missoes.md` (campo "Ambiente simulado", que cita LinkedIn).

Redação atual

2.1 **Ambiente é um dos 6 suportados, com conta própria e comportamento fiel** — Lista fechada: Instagram, YouTube, Roblox, ChatGPT, TikTok, WhatsApp. Nenhum outro ambiente passa.

Redação proposta

2.1 **Ambiente é um dos 5 suportados, com conta própria e comportamento fiel** — Lista fechada, com a seção do design system entre parênteses: Instagram (`instanooria`), YouTube (`unitube`), ChatGPT (`chatgpt`), TikTok (`tiktooria`), WhatsApp (`whatsappmobile`). Nenhum outro ambiente passa. Roblox não tem seção e reprova; se voltar, volta por `ambientes.md`, nunca por este critério. **Nota sobre TikTok:** a seção existe sem ponte em `@edu/ui`; a missão passa no 2.1 e declara a ponte como pré-requisito com responsável (DES-01).
Falso-positivos: acrescentar "**Roblox:** está fora da lista desde a revisão de setembro de 2026; missão em Roblox reprova aqui, não em DES-01".
6.4: trocar "Dentro dos 6 ambientes suportados" e "qual dos 6" por "5".

Teste falsificável: uma busca por "Roblox", "6 ambientes" e "dos 6" em `prompts/references/` devolve zero linhas fora de `ambientes.md`.
Como medir se funcionou: nenhuma execução da esteira chega ao banco de dev com ambiente Roblox. Hoje o custo de descobrir isso tarde é uma etapa de design inteira.
Custo e risco: quatro linhas. Risco nulo.

E-02 — Tabela de ausências preenchida, uma linha por seção — Onda 1

Resolve: A5. O critério O3 da rubrica de ofício se declara desarmado enquanto a tabela estiver vazia, e ela está vazia.
Arquivos: `ambientes.md`, seção "Ausências por ambiente".
Redação proposta. Cada linha é **[PROPOSTA]** até conferência contra o storybook e contra o bloco 5 das specs já aprovadas; o que importa é que a tabela deixe de estar vazia, porque uma lista imperfeita é conferível e uma lista vazia não é.

Seção	Não tem (o que a plataforma real tem e a simulação deliberadamente não)
`instanooria`	Mensagens diretas ů Stories e Reels, salvo quando a mecânica os pede ů anúncios e publicações patrocinadas ů loja e compras ů notificações fora da missão ů busca aberta na internet ů perfis fora do banco curado ů contadores de seguidores ao vivo (todo número visível é gabarito ou cosmético declarado, PED-03)
`unitube`	Anúncios ů transmissão ao vivo e chat ů monetização ů autoplay infinito fora do banco ů comentários de terceiros reais ů download ů histórico entre sessões fora do estado salvo
`chatgpt`	Memória entre conversas ů upload de arquivo ou imagem ů navegação na web ů plugins e GPTs ů modo de voz ů histórico lateral fora da missão ů resposta em tempo real sem curadoria (8.2)
`whatsappmobile`	Chamadas de voz e vídeo ů status ů localização ů pagamentos ů contatos fora do grupo da missão ů encaminhar para fora da simulação ů tema claro (ADR-68)
`tiktooria`	Transmissão ao vivo ů loja ů mensagens diretas ů efeitos e filtros de criação ů monetização ů download ů "Para você" infinito fora do banco

Acrescentar abaixo da tabela: "**Regra de leitura:** ausência desta tabela é ausência da seção, vale para toda missão. Ausência do bloco 5 da spec é da missão. O3 confere as duas; o D9 copia a linha da seção para o bloco 14 e acrescenta as da missão."
Teste falsificável: O3 deixa de devolver "por causa que não é do agente 5" em qualquer missão dos cinco ambientes.
Como medir se funcionou: contagem de tickets de fidelidade com classe "reapareceu por realismo" por missão, antes e depois. A tabela existe para essa contagem cair.
Custo e risco: cinco linhas de markdown mais uma conferência no storybook. Risco: linha errada gera devolução falsa; por isso cada linha nasce marcada e o QA registra o desvio em vez de burlar.

E-03 — Catálogo atualizado, com colunas de progressão — Onda 1

Resolve: A7, e prepara E-17. O catálogo lista três missões; o banco de dev trata quatro outras como gabarito.
Arquivos: `catalogo-missoes.md`.
Redação proposta. Duas colunas novas e as linhas que faltam. As colunas novas são o que E-17 vai ler; sem elas, "progressão" não tem onde ser verificada.

- Coluna **Porta de abstração**: *descrever* ů *explicar* ů *criticar com apoio* ů *criticar*, na escala de `literatura-cognitiva.md` §4.
- Coluna **Habilidade primária**: o código de letramento digital da Regra 12 do P0a.
- Coluna **Observada em campo**: *não* ů *piloto* ů *sim (data)*, que E-19 preenche.

Linhas a acrescentar, com o que os artefatos já dizem e o restante marcado para preenchimento a partir do manifesto de cada experiência:

Ano	Missão	Ambiente	Preencher do manifesto
1º EF	O Que a Foto Conta (exp-04)	[do manifesto]	eixo, descoberta, decisão, porta, habilidade
6º EF	Rastro do Boato (exp-06)	WhatsApp	eixo, descoberta, decisão, porta, habilidade
[do manifesto]	O Eco no Grupo (exp-07)	WhatsApp	ano, eixo, descoberta, decisão, porta, habilidade
[do manifesto]	Manifesto IA (exp-08)	[do manifesto]	tudo
1º EF	Magia ou Truque	TikTok	status (citada em `candidatos-a-criterio.md`)
5º EF	A foto é real	[do one-pager]	idem
7º EF	Quem ficou fora	WhatsApp	idem

Remover "LinkedIn" da descrição do campo "Ambiente simulado" e substituir por "um dos cinco de `ambientes.md`".
Teste falsificável: o critério 2.5 não devolve "N/A — catálogo incompleto" para missão de ano coberto pelo catálogo.
Como medir se funcionou: proporção de avaliações pedagógicas em que o 2.5 é de fato aplicado (hoje tende a zero, porque o catálogo se autoanula).
Custo e risco: uma hora de preenchimento a partir dos manifestos. Risco: manter o catálogo exige que o agente de aprendizado proponha a linha e alguém a aceite; o prompt 51 já faz a primeira parte.

E-04 — A régua chega ao design por um resumo operacional gerado — Onda 1

Resolve: A6. A fonte única dos números é incluída em um único prompt; quem desenha tela recebe tetos "a calibrar" sem a explicação de quando não se aplicam.
Arquivos: novo `references/literatura-cognitiva-resumo.md` (gerado); novo `scripts/gerar_resumo_literatura.py`; diretiva `include` em `22_jornada.md`, `26_telas.md`, `24_copy_ptbr.md`, `19_ambiente_simulado.md` e `21_brief_oficio.md`.
Por que um resumo e não a referência inteira. A referência tem 268 linhas e mais de vinte citações bibliográficas que quem desenha tela não precisa ler. Incluí-la em cinco prompts custa contexto e dilui a instrução. O padrão da casa para isso já existe: a lista BNCC em markdown é gerada de um JSON por script, com aviso de "não edite à mão". O resumo segue o mesmo padrão: uma página, só as tabelas e as regras de aplicação, gerada da fonte para não divergir.
Conteúdo do resumo (uma página):

1. Tabela de opções comparadas por faixa, com a regra "opção visível não é opção lembrada" e o +1, porque é uma regra de *layout*.
2. Tabela de duração por ato e o teto agregado da missão.
3. As três portas de abstração por idade.
4. As condições em que narrar ajuda e em que atrapalha.
5. O cenário de piso da escola pública, seis linhas.
6. A tabela de uso de plataforma por idade (E-06).
7. Três frases do registro negativo: sem choice overload, sem decision fatigue, sem "idade igual a minutos".

Teste falsificável: o resumo não contém número que não esteja na fonte, e o script falha se a fonte mudar e o resumo não for regenerado (comparação de *hash*, como o BNCC faz).
Como medir se funcionou: tickets de D4 (adequação etária nas telas) que citam a regra "visível versus lembrada" passam a existir; hoje não podem existir, porque a regra não chega a quem constrói.
Custo e risco: um script pequeno e cinco linhas de include. Risco: duas fontes. O script e o hash existem para evitá-lo.

E-05 — Deriva de números fora da fonte única (achado novo) Onda 1

Resolve: um achado que apareceu ao preparar esta proposta e que confirma o A6 por outro ângulo. `literatura-cognitiva.md` se declara fonte única e diz que existe "porque números soltos em prompts divergem sem que ninguém perceba". Divergiram.
Evidência:

- `defaults-missao.md`, classe `duracao`, padrão `teto-por-ato`: "Ato ≤ 12 min em anos iniciais, ≤ 15 nos anos finais, ≤ 20 no EM". São os tetos **antigos**: a seção 8 da fonte registra a troca de "12 / 15 / 20" por "6–8 / 8–10 / 10–12 / 12–15". O D0 aplica o teto revogado como padrão verde.
- `defaults-missao.md`, "Tetos de referência": Ensino Médio "≤ 4–5" opções. A fonte corrigiu para 4 e explica por quê.
- `10_adequacao_pedagogica.md`, "Condições materiais": "30 a 40 estudantes". A fonte, seção 6, fixa 25 nos anos iniciais e 32 nos finais e Médio, e diz literalmente que afirmar "30 a 40" infla a dificuldade. O mesmo prompt usa Bloom e DOK como régua, que a seção 7 da fonte lista entre o que não usar para adequação etária.
- `09_experiencia_estudante.md`, protocolo de simulação: "o tipo de raciocínio é compatível com o estágio (Piaget)?". A seção 7 da fonte proíbe Piaget como veto de abstração e manda usar Demetriou e Fischer. O mesmo protocolo manda aplicar "os dois testes do 3.5", mas o teste de volume foi rebaixado a desejável na revisão de setembro.

Redação proposta: alinhar os quatro pontos à fonte, e acrescentar ao topo de `defaults-missao.md` a regra "**nenhum número aqui: padrão de duração e de opções cita `literatura-cognitiva.md` pela seção, nunca pelo valor**". No prompt 09, trocar a linha de Piaget por "o nível de abstração que a decisão pede cabe na porta da faixa (`literatura-cognitiva.md` §4)?".
Teste falsificável: uma busca por "12 min", "4–5", "30 a 40" e "Piaget" em `prompts/` devolve só a fonte única, onde aparecem como registro do que mudou.
Como medir se funcionou: dois relatórios sobre a mesma missão citam o mesmo teto. Hoje o D0 e o P3 podem citar tetos diferentes para o mesmo ato.
Custo e risco: dez linhas. Risco nulo. É a correção mais barata do documento e a que mais desmente a promessa de fonte única.

E-06 — Uso de plataforma por idade entra na régua e nos testes 2.1 e 6.4 Onda 1

Resolve: A11 e a seção 5.2 da auditoria. Dois critérios obrigatórios perguntam o que a criança brasileira usa, e nenhum arquivo cita a fonte que responde.
Arquivos: `literatura-cognitiva.md` (nova seção 10), `criterios-gate-estrutural.md` (2.1, teste de plataforma real), `criterios-experiencia.md` (6.4).

Redação proposta

10. Que plataforma a criança brasileira usa, por idade
Fonte: TIC Kids Online Brasil 2024 (CETIC.br/NIC.br), amostra probabilística nacional, N = 2.424, 9 a 17 anos. [**DADO DIRETO**] para 9–17; **a pesquisa não cobre 6 a 8 anos**, e qualquer afirmação sobre essa faixa é [**EXTRAPOLAÇÃO**].

	9–10	11–12	13–14	15–17
Tem perfil em alguma rede social	60 %	70 %	93 %	99 %
Mais usada várias vezes ao dia	YouTube	transição	Instagram	Instagram

Perfil declarado, 9 a 17 anos: WhatsApp 69 %, Instagram 63 %, TikTok 45 %, YouTube 42 %.
Regras de aplicação: (a) **3º–5º ano**, o ambiente de consumo mais plausível é YouTube; WhatsApp é plausível como *grupo da família ou da turma*, não como conta pessoal; (b) **6º–7º ano** é zona de transição: qualquer um dos cinco é defensável, e a spec justifica; (c) **8º ano em diante**, Instagram, TikTok e WhatsApp são os de maior uso; (d) **1º–2º ano**, sem dado: presumir uso mediado por adulto e sem perfil próprio, o que faz da "primeira conta" um evento diegético legítimo (E-18); (e) aos 9–10 anos, 40 % **não têm** perfil algum: missão dessa faixa que pressupõe conta declara o que faz com quem nunca teve uma.

Redação proposta

2.1, teste de plataforma real (substitui "o aluno diria eu uso isso?"): consulte `literatura-cognitiva.md` §10. O ambiente está entre os de maior uso para a faixa? Se está, **passa**. Se é zona de transição, **passa** com justificativa na seção 18. Se está fora (ex.: Instagram pessoal no 3º ano), **alerta**; e **reprova** se além disso a missão pressupõe conta própria numa faixa em que a maioria não tem, sem tratar a primeira conta na ficção.
6.4 (substitui "qual dos 5 um estudante mediano daquele ano usaria de fato?"): a resposta sai da tabela de §10, não da intuição do avaliador. Cite a linha. Se a atividade simulada (consumir, postar, conversar, pesquisar) não tem ambiente plausível na tabela para a faixa, a missão precisa mudar de mecanismo, não forçar encaixe.

Teste falsificável: todo relatório do P3 que aplica 6.4 cita a linha da tabela. Relatório sem citação é achado de F4 (coerência) no gate final.
Como medir se funcionou: a distribuição de ambientes por faixa nas missões geradas passa a acompanhar a tabela; hoje ela acompanha a intuição do modelo. E-19 confronta a tabela com a turma real.
Custo e risco: uma seção de vinte linhas e dois testes reescritos. Risco: a tabela envelhece; a TIC Kids é anual, e a seção declara a edição lida.

4 Onda 2 — Emendas que a casa já aprovou

Os três itens marcados "pronto pra emenda" em `candidatos-a-criterio.md`. A decisão é de priorização, não de mérito. Uma observação antes: o C7 está **parcialmente** aplicado, porque o critério 9.4 (estados de falha) já existe e é obrigatório; o que falta é a cláusula que motivou o candidato.

E-07 — Critério 2.7: a mecânica sustenta a descoberta central (C1) Onda 2

Resolve: A8. O caso de origem passou em 2.1, 2.2 e 2.4 com a frase dizendo "o TikTok não avisa" e a mecânica fazendo o TikTok avisar. Está implementado como passo 4.5 do agente 1, sem critério formal, o que significa que o gate estrutural confere por instrução de prompt e

não por rubrica.
Arquivos: `criterios-gate-estrutural.md`, seção 2 (o subset passa a ser 2.1, 2.6 e 2.7); resumo de contagem; `candidatos-a-criterio.md` (C1 vira "aplicado em v1.19").

Redação proposta

2.7 **A mecânica sustenta a descoberta central** — O que a plataforma simulada faz com o estudante na etapa Resultado não contradiz a frase da descoberta. **Obrigatório**. **Teste de 30 segundos:** leia a frase-chave da seção 1; leia a regra do sistema da etapa Resultado na seção 4; uma nega a outra? Estenda ao podcast, às falas do guia e aos textos do professor. Se a frase diz "a plataforma não avisa" e alguma etiqueta, alerta ou painel avisa, **reprova**. **Falso-positivo:** a verdade chegar por conteúdo de terceiro dentro da simulação (padrão P1) não é a plataforma avisando; é o estudante indo olhar.

Teste falsificável: o de trinta segundos acima; sim ou não com citação das duas seções.
Como medir se funcionou: o agente de aprendizado registra ocorrências de C1 por missão. A emenda funciona quando a contagem para de crescer.
Custo e risco: uma linha de tabela. Risco nulo; o passo 4.5 já faz isso, a emenda só tira a verificação da dependência de um parágrafo de prompt.

E-08 — Falha de plataforma nunca vira decisão do estudante (C7) Onda 2

Resolve: A8, no agravante que o próprio candidato descreve: "onde o estado alimenta a evidência, falha técnica pode ser gravada como decisão pedagógica". Uma queda de conexão registrada como "não encaminhou".
Arquivos: `criterios-gate-estrutural.md`, critério 9.4 (acrescentar um teste); `formato-spec.md`, bloco 9 (uma regra de grau); `defaults-missao.md`, padrão `erro-na-voz-da-ficcao` (uma frase).

Redação proposta

9.4, acrescentar ao teste prático: "**Teste de contaminação:** para cada estado de falha (conexão, sessão expirada, mídia que não carregou), em qual estado do bloco 9 ele é registrado? Se cai em um estado de decisão do estudante (encaminhou / não encaminhou, salvou / pulou), **reprova**. Falha de plataforma alimenta o grau `none` (a oportunidade não chegou), nunca `zero` (teve a chance e não foi)."
Bloco 9 da spec, graus de medida, acrescentar: "Estado de falha de plataforma é sempre `none` para toda medida que dependia da tela que falhou."

Teste falsificável: o de trinta segundos do candidato (procurar "conexão", "offline", "sessão", "falha", "carregar" na spec) mais a pergunta "em qual grau cai?".
Como medir se funcionou: a matriz PED-06 de toda spec nova tem uma linha por estado de falha com grau `none`. Em campo, E-19 compara quedas de conexão registradas contra "recusas" registradas na mesma janela.
Custo e risco: três frases. Risco nulo. É a emenda com maior consequência ética por linha escrita: evita que um adulto leia como recusa de uma criança o que foi falha de rede.

E-09 — Não-negociável de ofício com mecanismo, sem reordenar a esteira (C3) Onda 2

Resolve: A8. O candidato diagnostica ordem de esteira errada: o briefing roda depois de o gate fechar a spec, então seus não-negociáveis nunca passam por verificação de mecanismo. Propõe reordenar. Esta emenda oferece uma alternativa mais barata e uma mais completa.

Opção A (recomendada) — classificar, não reordenar. A spec já tem um mecanismo para pedido de mudança depois do Gate 0: os pedidos de re-spec `[RS-n]` do bloco 13, que o D0 registra e o gate estrutural fecha. Basta obrigar o D1 a usá-lo.

Redação proposta

Em `21_brief_oficio.md`, seção "Não-negociáveis de ofício": "Cada não-negociável recebe **uma** de duas marcas: `[MECANISMO: bloco 2, regra <n>]` quando a spec já garante o comportamento por ordenação, bloqueio ou restrição de geração; ou `[RS-n → gate-estrutural]` quando depende de comportamento que a spec não garante. Não-negociável sem marca não é vinculante para jornada, copy e wireframes, e o QA (D7) o devolve com dono `brief-oficio`."
Em `30_qa_entregaveis.md`, D7: "Não-negociável marcado `[RS-n]` ainda aberto quando o wireframe o honra é **reprova** com dono `gate-estrutural`: a construção materializou um comportamento que a spec não garante."

Opção B — reordenar. Rodar o D1 sobre o one-pager, antes do 13 (spec), para que os não-negociáveis entrem no Gate 0. Custo: o D1 perde o insumo do D9 (o que o ambiente não tem), que hoje é matéria-prima do "sai de propósito"; seria preciso rodar o D9 também antes da spec. É mudança de orquestração em `agents/design/__init__.py`, não de prompt. Fica registrada como opção se a A não bastar.
Teste falsificável: todo não-negociável do briefing tem uma das duas marcas; contagem de marcas igual à contagem de não-negociáveis.
Como medir se funcionou: lacunas da classe "não-negociável sem mecanismo" encontradas pelo QA ou pela banca caem a zero, porque passam a ser encontradas pelo D1.
Custo e risco: opção A, seis linhas de prompt. Risco: o D1 marca tudo como `[MECANISMO]` por conveniência; o D7 do QA é a segunda defesa.

5 Onda 3 — Decisões de produto

Onze emendas que mudam tese. Cada uma diz quem decide e o que a decisão custa se estiver errada.

E-10 — A regra comparativa do pico passa a bloquear — Onda 3

Resolve: A2 e A3, na única parte que não depende de calibragem. A rubrica de ofício já diz: "a tela `pico` tem menos elementos que suas vizinhas; essa é comparativa e vale mesmo se todos os números acima estiverem errados". Hoje essa regra é emitida na faixa `"oficio"`, que a esteira não roteia como bloqueio.
Arquivos: `rubrica-oficio.md` (O1, terceira linha); `30_qa_entregaveis.md` (instrução de severidade no gate de ofício); `22_jornada.md` (seção 4, para o principal saber que é bloqueante). Nada muda em Python: o filtro de retrabalho já roteia `severidade: "bloqueio"`.

Redação proposta

Em `rubrica-oficio.md`, O1, linha "A tela `pico` é a mais enxuta do trecho?": acrescentar coluna ou nota "**severidade: bloqueio**, agente `jornada`". As demais linhas de O1–O5 continuam `oficio` até a calibragem de E-19.
Em `30_qa_entregaveis.md`, "Gate de ofício": "Achado O1–O5 sai com `severidade: "oficio"`, **exceto** a inversão de hierarquia (tela `pico` com mais elementos que qualquer vizinha no arco), que sai com `severidade: "bloqueio"`, `codigo: "O1"`, dono `jornada`. A contagem é a da coluna "Teto de elementos (contado)" da seção 4 da jornada, sobre o frame construído, não sobre a intenção."

Por que só esta. A auditoria mostra que todo critério de imersão que bloqueia é mecânico e todo que exige juízo não bloqueia. Esta regra é a exceção: exige juízo de composição mas

se verifica por contagem comparativa. É a ponte entre as duas classes, e o lugar certo para começar a dar poder de veto ao ofício sem bloquear por número não calibrado.
Teste falsificável: n(`pico`) $<$ min(n(vizinha anterior), n(vizinha seguinte)), com n contado no frame. Empate é **alerta**; maior é **reprova**.
Como medir se funcionou: proporção de missões em que o pico é a tela mais cheia (padrão P5, já observado uma vez) vai a zero na saída do QA. Em campo, E-19 mede dwell e ação na tela de pico contra as vizinhas.
Custo e risco: três parágrafos. Risco: uma rodada a mais de QA em missões que hoje passariam com o pico invertido; é o custo que a emenda quer.

E-11 — Simulação diegética obrigatória, com três testes — Onda 3

Resolve: A4. O único critério que pergunta se o mundo ficcional se sustenta é desejável e tem um teste binário fraco.
Arquivos: `criterios-pedagogicos.md`, critério 2.3; resumo de contagem (Imersão passa a 2 obrigatórios e 1 desejável).

Redação atual

2.3 **Simulação diegética** — O ambiente simulado existe por uma razão dentro da narrativa. Desejável. Teste: a narrativa justifica por que aquele ambiente existe, ou ele aparece "do nada"?

Redação proposta

2.3 **Simulação diegética** — O estudante entra no ambiente por uma razão que é dele, por uma ação que é do ambiente, e o ambiente não é trocável. **Obrigatório**. Três testes, todos precisam passar:
(a) Teste da porta: o *job-to-be-done* do Desafiar (Regra 9 do P0a) diz por que o estudante abre *este* app *agora*, e é algo que um estudante da faixa faria fora da missão (`literatura-cognitiva.md` §10)? "A Unooria te leva ao feed" não é porta; "o Léo mandou o link no grupo" é.
(b) Teste da troca: substitua mentalmente o ambiente por outro dos cinco. Se o Desafiar e o Decidir continuam válidos sem reescrita, o ambiente é cenário, não diegese: **reprova**.
(c) Teste da chegada: a entrada no ambiente é uma ação nativa (abrir o app, abrir um grupo, tocar um link, receber uma notificação) e não uma transição da plataforma? Transição da Unooria dentro da simulação já reprova no 2.1 (permanência); aqui o que se testa é se a *primeira* entrada tem verossimilhança.
Falha em (a) ou (c) é **reprova**; falha só em (b) com justificativa na seção 18 é **alerta**.

Fundamento. Transporte narrativo [3, 14] depende de o leitor ter um motivo para estar ali; a barreira de entrada de Brown e Cairns [1] é justamente a primeira. O teste (b) é o que separa "imersão" de "tema": se qualquer app serve, o app não é parte da descoberta.
Teste falsificável: os três acima, com citação do Desafiar.
Como medir se funcionou: na esteira, contagem de **alerta** e **reprova** em 2.3 por rodada; no campo, minutos até a primeira ação (o D1 já pede esse número) caem quando a porta é boa.
Custo e risco: um critério reescrito. Risco: reprovar missões boas cujo Desafiar é genérico; a correção é barata (reescrever o Desafiar), e é exatamente o que a Regra 9 já pede.

E-12 — Posse da conta no cenário compartilhado — Onda 3

Resolve: A12. O 2.1 reprova conta que não é do estudante; o 10.2 exige que a missão funcione com três estudantes num aparelho; ninguém diz de quem é a conta.
Arquivos: `criterios-gate-estrutural.md` (2.1 teste de posse; 10.2); `defaults-missao.md` (padrão `2-4-decide-em-grupo-registra-por-grupo`, que já existe marcado como pendente

de confirmação e ganha a parte da identidade).
A decisão proposta: no cenário 2–4, **a conta é do grupo**, com identidade escolhida pelo grupo por affordance nativa (nome de usuário, nome no grupo, foto de perfil entre as do banco), e revezamento declarado por etapa. Das três opções que a auditoria lista, é a única que preserva agência (1.3) sem violar posse (2.1) e sem inventar tela que a plataforma real não tem (padrão P3).

Redação proposta

2.1, teste de posse: "a conta é do estudante, ou, no cenário 2–4 por aparelho, do grupo que opera o aparelho, com identidade escolhida pelo grupo por affordance nativa. Conta de personagem da narrativa **reprova**. Conta "da turma" operada pelo professor só no cenário de projeção."
10.2, teste prático: "**Protocolo de revezamento:** para cada etapa com decisão, a spec diz quem toca, como o grupo decide (alternância, consenso, voto por affordance nativa) e o que é registrado quando há desacordo. 'Eles decidem juntos' sem protocolo é **alerta**; nenhum protocolo é **reprova**. **Teste da descoberta:** com o protocolo aplicado, o grupo chega ao Resultado com consequência própria? Se a consequência só existe para quem tocou, a missão degrada para plateia."

Teste falsificável: existe, na spec, uma tabela etapa × (quem toca, como decide, como registra) para o cenário 2–4.
Como medir se funcionou: E-19 observa turmas em cenário compartilhado e conta quantos do grupo tocam a tela por etapa; hoje o dado que existe é "53 % das escolas não fornecem computador" [12], e nada sobre o que acontece com o trio.
Custo e risco: decisão de produto mais dois testes. Risco: a identidade de grupo funciona no WhatsApp (nome no grupo) e no Instagram (perfil), e menos no ChatGPT, onde não há perfil visível; o D9 registra a diferença por ambiente.

E-13 — Piso de desafio por faixa, em todas as faixas — Onda 3

Resolve: A9, e é a emenda central desta proposta. Nenhum critério pergunta se a missão é difícil o bastante, exceto o 6.5, e só a partir do 6º ano.
Arquivos: `criterios-experiencia.md` (6.5 é absorvido por um 6.6 novo, obrigatório em todas as faixas); `literatura-cognitiva.md` (nova seção 11, com a marca de cada linha); `01_nucleo_narrativo.md` (Regra 14, para o P0a desenhar contra o piso e não descobri-lo no gate).
O fundamento, com a delimitação honesta. Hamari e colegas [4] encontraram desafio como preditor forte de aprendizagem percebida em dois jogos educacionais com estudantes de ensino médio e superior, e imersão sem efeito isolado. Cheng, She e Annetta [2] encontraram o efeito da imersão mediado pelo desempenho. Nenhum dos dois mediu crianças de 6 a 10 anos, e nenhum mediu letramento digital. O que se transfere é o princípio: **a decisão precisa discriminar**, no sentido do desenho centrado em evidência [7]: uma tarefa que qualquer estudante resolve igual não produz evidência sobre nenhum. Por isso o piso é redigido como **discriminação**, não como "dificuldade", e a tabela por faixa é marcada **[EXTRAPOLAÇÃO]** das portas de abstração de §4 e **[CONVENÇÃO]** na redação exata.

Redação proposta

6.6 **Piso de desafio** — A missão exige da faixa um repertório que a decisão principal discrimina. **Obrigatório** em todas as faixas (absorve o 6.5).

Faixa	Piso: a decisão principal exige, pelo menos,	Marca
1º–2º	**observar antes de decidir**: a opção certa não é identificável pela aparência (cor, tamanho, posição); é preciso abrir, rolar ou ouvir algo	**[EXTRAPOLAÇÃO]** de §4
3º–5º	**investigar**: comparar dois itens ou abrir uma segunda fonte antes de decidir, com andaime no primeiro uso e removido depois (6.3)	**[EXTRAPOLAÇÃO]** de §4
6º–9º	**investigar e revisar**: a missão devolve informação que pode mudar a escolha, e o estudante pode mudá-la antes de fechar; ou justificar a escolha	**[EXTRAPOLAÇÃO]**
Ensino Médio	**justificar e confrontar**: a justificativa encontra contra-evidência dentro da simulação antes do Resultado	**[EXTRAPOLAÇÃO]**

Teste do estudante apressado (obrigatório): simule o estudante que faz o mínimo (padrão P2) e o estudante que investiga. Os dois chegam ao *mesmo* Resultado? Se sim, a decisão não discrimina: **reprova**. **Teste da resposta na cara:** a opção "certa" se identifica sem ler ou ouvir nada? **reprova**. **Teste dos dois erros (C8):** a revelação responde ao excesso e à falta (confiar demais e desconfiar demais), ou só ao erro que produz conteúdo visível? Só a um é **alerta**. **Falso-positivo:** missão de 1º–2º ano em que "observar" é ouvir a narração inteira antes de tocar: isso é andaime de leitura (6.1), não desafio; o piso pede que o *conteúdo* observado mude a escolha.

Redação proposta

`01_nucleo_narrativo.md`, Regra 14: "**Desenhe contra o piso da faixa (`literatura-cognitiva.md` §11).** Antes de fechar a seção 4, rode o estudante apressado e o estudante que investiga; se chegam ao mesmo Resultado, a decisão está fraca e o gate vai devolver. Registre na seção 18 o que o estudante apressado perde."

Teste falsificável: o do estudante apressado. Duas simulações, um Resultado cada, iguais ou diferentes.

Como medir se funcionou: o dado já existe na plataforma: os eventos de investigação (`abriu_busca`, `buscou` na exp-01; "tempo revendo antes de concluir" do PROD-07). Missão que passa no 6.6 deve mostrar **variância** nesses eventos entre estudantes; missão onde todo mundo investiga zero ou todo mundo investiga tudo não discriminou. E-19 fixa o piso numérico depois de três turmas.

Custo e risco: um critério, uma seção, uma regra. Risco maior do documento: elevar o piso nos anos iniciais pode colidir com o teto de etapas cognitivas do 6.3 (máximo duas sem andaime). A redação cuida disso: o piso do 3º–5º pede andaime no primeiro uso, e o do 1º–2º não pede etapa nova, pede que a observação importe.

E-14 — Premissa da imersão como instrumento, propagada — Onda 3

Resolve: a seção 4.3 da auditoria (detalhe sedutor) e o A3. A tese que resolve a tensão com a literatura aparece uma vez, num critério não bloqueante, num arquivo lido por um agente.

Arquivos: novo `references/premissa-imersao.md` (meia página); diretiva `include` em `01_nucleo_narrativo.md`, `21_brief_oficio.md`, `22_jornada.md`, `26_telas.md`, `30_qa_entregaveis.md` e `40_validacao_design_imersao.md`.

Redação proposta

Premissa: a imersão é o instrumento de medida
Na missão Unooria, a fidelidade ao ambiente real não é ornamento: é a condição de validade do que se mede. Um feed que se comporta como feed real é o que torna a decisão do estudante uma decisão sobre feeds reais. Isso tem quatro consequências, e toda tela, string e critério obedece a elas:

1. **Constitutivo ou sedutor.** Um elemento é constitutivo quando o estudante toma alguma decisão que depende dele, ou quando é chrome nativo que o ambiente real sempre tem. Fora disso, é detalhe sedutor: a literatura mede seu custo em $g = -0{,}33$ sobre a aprendizagem [11], e ele sai. **Teste:** "que decisão muda se eu tirar isto?" Nenhuma, e não é chrome: corta.
2. **Imersão se perde por barreira, não se ganha por enfeite.** As barreiras conhecidas são: erro que vaza da ficção (PROD-13), marca institucional no disfarce (DES-13), estado vazio que parece tela quebrada (DES-07, O5), voz que não se distingue (O2), spoiler (Regra Zero do P0a). Construir é remover barreiras.
3. **Fidelidade tem lista.** O que o ambiente real tem e a simulação não tem está em `ambientes.md`, por seção, e no bloco 5 da spec, por missão. Completar a interface "por realismo" é violar a lista.
4. **Imersão não substitui desafio.** A evidência empírica associa aprendizagem a desafio e engajamento, não a imersão isolada [4, 2]. O piso de desafio (6.6) é a outra metade desta premissa.

Teste falsificável: o "que decisão muda se eu tirar isto?" por elemento, aplicado pelo D5 na seção 4 da jornada e pelo QA em D1.
Como medir se funcionou: contagem de elementos por tela `pico` cai sem que a contagem de decisões caia; é o sinal de que saiu enfeite e não mecânica.
Custo e risco: meia página e seis includes. Risco: agente que lê "corta o sedutor" e corta chrome nativo; a consequência 1 define chrome como constitutivo por padrão.

E-15 — Banco curado como caminho principal nos anos iniciais — Onda 3

Resolve: a seção 5.6 da auditoria. O 4.3 reprova missão "100 % estática" e trata o banco curado como *fallback*, exigindo curadoria por IA do professor menos formado da rede (43 % com formação na rede municipal, 15 % de uso de IA pelos estudantes dos anos iniciais [12]).
Arquivos: `criterios-pedagogicos.md`, critério 4.3; `01_nucleo_narrativo.md`, Regra 11 (inverter a ordem: banco primeiro, parâmetro depois); `30_qa_entregaveis.md`, D6 (a tela `E0-PROF-01` abre no banco padrão).

Redação atual

4.3 [...] além de banco curado padrão (default/fallback imediato). Teste: [...] Existe banco curado default caso o professor não queira customizar? Missão 100 % estática sem parametrização → reprova.

Redação proposta

4.3 **Banco curado padrão como caminho principal; parametrização por IA como camada** — A missão roda inteira com o banco curado de fábrica; o professor pode, se quiser, parametrizar tema e contexto, e a IA gera rascunhos que ele cura antes de liberar. **Obrigatório**. **Teste do caminho curto:** a missão funciona por completo com o professor tocando apenas "usar banco padrão" na tela de preparação? Se não, **reprova**. **Teste de ordem, anos iniciais:** a preparação *abre* no banco padrão, com a parametrização a um toque e fora do caminho; nos anos finais e Médio, a ordem é livre. **Teste de completude da camada:** os prompts, os schemas e o fluxo de curadoria estão definidos? Sem eles, **alerta** nos anos iniciais e **reprova** nos anos finais e Médio. Missão sem banco curado **reprova** em qualquer faixa.

Teste falsificável: o do caminho curto.
Como medir se funcionou: a plataforma já registra a preparação docente; a proporção de turmas que rodam no banco padrão, por rede e por faixa, diz se o caminho principal é o que os professores usam. Se nos anos iniciais essa proporção for baixa, a emenda estava errada.
Custo e risco: um critério reescrito e uma regra invertida. Risco: reduzir o incentivo a parametrizar; por isso a camada continua obrigatória nos anos finais e Médio, onde a base instalada existe.

E-16 — Leitura não monotônica: cláusula para 9º ano e Médio — Onda 3

Resolve: a seção 5.5 da auditoria. O 6.1 retira a narração a partir do 3º ano por *expertise reversal*, o que é correto, mas pressupõe fluência crescente, e no Brasil a defasagem é maior no 9º ano (62 % abaixo do adequado) e no Médio (65 %) do que no 5º (39 %) [9, 8].
Arquivos: `criterios-experiencia.md`, 6.1 (cláusula); `literatura-cognitiva.md`, §5 (um parágrafo).

Redação proposta

6.1, acrescentar: "**Cláusula de defasagem, 9º ano e Médio.** A retirada do andaime a partir do 3º ano é regra de *expertise reversal*, não atestado de proficiência. Onde a maioria está abaixo do adequado em leitura (9º ano e Médio, Saeb 2025), valem três regras: (a) o teto de palavras por string é o do 6º–9º, não maior **[CONVENÇÃO]**; (b) strings acima desse teto têm áudio *sob demanda*, nunca autoplay, para não reintroduzir redundância a quem lê **[EXTRAPOLAÇÃO]** de Kalyuga; (c) o 'estudante mediano' do teste é o mediano do Saeb para o ano, não o nominal. Missão de 9º ano ou Médio cujo Decidir exige ler um texto acima do teto sem áudio sob demanda é **alerta**."

Teste falsificável: amostra de strings do Decidir contra o teto; presença do botão de áudio nas que excedem.
Como medir se funcionou: uso do áudio sob demanda por faixa, que a plataforma pode registrar como microinteração instrumentada (DES-12). Se ninguém toca no 9º ano, a cláusula pode sair.
Custo e risco: uma cláusula. Risco: tratar o Médio como criança; a cláusula não muda a complexidade da decisão (6.3), só o canal de acesso ao texto.

E-17 — Progressão na trilha como critério — Onda 3

Resolve: A7 e a seção 4.5 da auditoria. A meta-análise de letramento midiático [5] encontra intervenções de múltiplas sessões superando as de sessão única; a esteira só pergunta se as missões são diferentes, nunca se acumulam.
Arquivos: `criterios-pedagogicos.md` (critério 2.8, desejável até o catálogo cobrir a trilha do ano; obrigatório depois); `catalogo-missoes.md` (colunas de E-03).

Redação proposta

2.8 **Progressão na trilha** — Quando o catálogo tem missão anterior do mesmo ano, ou do ano anterior no mesmo eixo, esta missão sobe pelo menos um degrau em uma de três escadas. **Desejável** enquanto o catálogo não cobrir o ano; **Obrigatório** depois. **Escadas:** (1) porta de abstração, descrever → explicar → criticar com apoio → criticar (§4); (2) piso de repertório (6.6); (3) ambiente, de mais familiar para menos familiar (§10). **Teste:** cite a linha do catálogo e a escada. Mesmo degrau nas três é **alerta**; degrau *abaixo* da missão anterior é **reprova**.

Teste falsificável: comparação de duas linhas do catálogo em três colunas.
Como medir se funcionou: é a emenda que precisa de campo: E-19 compara, na mesma turma, desempenho na segunda missão do bimestre contra a primeira. Sem catálogo (E-03), não é verificável, e por isso nasce desejável.
Custo e risco: um critério e a dependência de E-03. Risco: trilha com missões de eixos diferentes não tem escada comum; a redação limita ao mesmo eixo.

E-18 — Pacote anos iniciais, consolidado — Onda 3

Resolve: a convergência que a auditoria aponta na seção 7.4: cinco achados independentes caem no 1º–5º ano, que é a faixa com menos critério próprio e mais fragilidade de rede. Esta emenda não cria critério novo; consolida o que as outras já fazem para essa faixa e acrescenta uma decisão de produto que só faz sentido aqui.
O que o pacote contém:

- E-06, regras (d) e (e): sem dado para 6–8 anos; 40 % sem perfil aos 9–10.
- E-12: posse no cenário compartilhado, mais frequente na rede municipal.
- E-13: piso de desafio para 1º–2º e 3º–5º.
- E-15: banco curado como caminho principal.
- E-19: a pergunta A10 (Explicar depois versus antes no 2º–5º) só se responde nessa faixa.
- C2 de `candidatos-a-criterio.md` (redundância não textual), que o 6.1 e o padrão `texto-icone-audio-anos-iniciais` já cobrem; registrar como aplicado.
- Crédito: a Passada 1b do D9 (mini-jogo só para 1º–5º, com gate de quatro condições) já é a resposta certa ao problema "clonar app que a criança não usa". O pacote não a altera.

A decisão nova: a primeira conta como evento diegético. Para 1º a 5º ano, o Desafiar pode incluir *criar a conta* dentro da simulação, com o cadastro simplificado que a plataforma real tem: escolher nome, foto entre as do banco, o que compartilhar. Isso resolve três coisas de uma vez: torna verdadeira a posse (2.1) numa faixa em que a maioria não tem conta; dá porta diegética (E-11) a quem nunca abriu o app; e exercita literalmente as habilidades de segurança e dados pessoais do 1º e 2º ano (`EF01CO07`, `EF02CO06`), que hoje são difíceis de exercitar sem uma tela de cadastro.

Redação proposta

Em `01_nucleo_narrativo.md`, Regra 15 (só anos iniciais): "Se a faixa é 1º–5º e a missão pressupõe conta, considere a primeira conta como parte do Desafiar: cadastro nativo simplificado, dentro do teto de gestos novos por ato (§5). Registre na seção 18 a decisão e o que ela custa em minutos."

Teste falsificável: missão de 1º–5º ano que pressupõe conta declara, na seção 18, o que faz com quem nunca teve uma.
Como medir se funcionou: E-19, com o dado que falta a todo mundo: o que a criança de 6 a 8 anos de fato reconhece na tela.

Custo e risco: uma regra e uma consolidação. Risco: o cadastro consome minutos do teto agregado; a regra o sujeita ao teto de gestos novos por ato.

E-19 — Observação de campo com instrumento e protocolo — Onda 3

Resolve: A10 e A2 (calibragem), e a seção 9 de `literatura-cognitiva.md`, que já reivindica isso: "nenhum número desta página é medição feita com missões da Unooria".
Arquivos: novo `references/observacao-campo.md`; coluna "Observada em campo" no catálogo (E-03).
Protocolo mínimo (uma página):

1. **Amostra:** três turmas por faixa, rede pública, ao menos uma municipal nos anos iniciais; uma em cenário 1:1 e uma em 2–4 por aparelho, porque é o cenário de 53 % das escolas.
2. **Atenção na tarefa:** amostragem momentânea, a cada dois minutos, de quantos estudantes estão na tarefa, no método de Godwin e colegas já citado na fonte única. É o dado que calibra os tetos de duração e a tabela de densidade v0.1.
3. **Experiência:** questionário pós-missão de seis itens, um por fator do *Game Experience Questionnaire* revisto [6]: competência, imersão, *flow*, tensão, afeto positivo e desafio; escala de três faces para anos iniciais, de cinco pontos para os demais. Marcado **[CONVENÇÃO]** até validação.
4. **Telemetria que já existe:** tempo até a primeira ação; dwell na tela de pico contra as vizinhas (E-10); eventos de investigação e sua variância entre estudantes (E-13); tempo revendo antes de concluir (PROD-07); quedas de conexão contra recusas na mesma janela (E-08).
5. **A pergunta A10:** nas turmas de 2º a 5º ano, rodar a mesma missão em duas ordens, Explicar depois do Aha (framework atual) e uma explicação curta antes do Navegar, e comparar a provocação do Refletir. É o único desenho que responde se a inversão de efeito de Sinha e Kapur [10] vale aqui.
6. **Saída:** cada número da rubrica de ofício v0.1 e da fonte única ganha, ao lado da marca epistêmica, a marca **[OBSERVADO: n turmas]** quando houver dado.

Teste falsificável: o protocolo produz, por missão observada, os cinco números acima.
Como medir se funcionou: é a emenda que mede as outras. Seu sucesso é a primeira correção de um teto v0.1 feita por dado e não por opinião.
Custo e risco: o maior do documento em tempo de pessoa, o menor em linhas. Risco: a observação alterar o comportamento; o protocolo usa a telemetria que a missão já grava como linha de base.

E-20 — O que a esteira faz com critérios que não são dela — Onda 3

Resolve: A3, na parte que a esteira pode resolver. O banco de dev pertence ao time da plataforma; DES-03, DES-07, DES-08 e DES-13 são não bloqueantes lá, e mudar isso não é decisão desta esteira.
O que a esteira controla: o que chega ao banco. Se os mesmos juízos forem bloqueantes *a montante*, o banco recebe insumo que já passou por eles. A tabela abaixo mostra o equivalente, emenda por emenda:

Banco de dev	O que pergunta	Equivalente bloqueante a montante
DES-03	O clone é fiel, com lista do que difere	O3 com a tabela de ausências (E-02) e a premissa (E-14); 2.3 diegese (E-11)
DES-07	Estados vazios parecem intencionais	O5 e o padrão `vazio-e-carregando`; 9.4 com o teste de contaminação (E-08)
DES-08	Copy real e adequada à série	6.1 com a cláusula de defasagem (E-16); D4 do QA com o resumo da régua (E-04)
DES-13	Marca fora do disfarce	já bloqueante no QA por D8b e na regra de `ambientes.md`; sem emenda

Redação proposta: uma nota em `criterios-dev.md`, seção "Duas coisas que o gate deles resolveu do nosso lado", renomeada para "O que o gate deles não bloqueia e o nosso bloqueia antes", com a tabela acima. Serve para que a banca não relaxe a montante por achar que o banco pega depois.
Teste falsificável: toda linha da tabela aponta um critério nosso com severidade bloqueante em vigor.
Como medir se funcionou: achados DES-03/07/08 na consolidação da banca caem, porque o insumo chega limpo.
Custo e risco: uma tabela. Risco nulo.

6 Como saber se as emendas funcionaram

6.1 O que "missão mensurável" significa aqui

Uma missão é mensurável quando cada afirmação sobre aprendizagem que ela faz tem uma tarefa que a evidencia, um dado que a captura e um grau de confiança declarado. A esteira já tem esse esqueleto: a matriz habilidade → evidência → interação → dado do PED-02, os graus de medida do PED-06, o vocabulário de telemetria do DAD-01. É desenho centrado em evidência [7] na prática, e é bom.

O que falta é aplicar a mesma disciplina aos **critérios**, não só às missões. Um critério novo que não diga o que o confirmaria é opinião com número de série. Por isso cada emenda acima traz "como medir se funcionou". A tabela seguinte consolida isso.

6.2 Indicadores por emenda

E	Teste no gate (sim ou não)	Indicador em campo ou na esteira	Dado que já existe
01	busca sem Roblox fora de `ambientes.md`	zero missões Roblox chegam ao dev	relatórios da banca
02	O3 não devolve por lacuna de biblioteca	tickets "reapareceu por realismo" por missão	QA, classe do ticket
03	2.5 sem "N/A — catálogo"	proporção de 2.5 aplicados	relatórios do P2
04	hash do resumo bate com a fonte	tickets D4 citam "visível vs lembrada"	QA
05	busca sem número revogado	D0 e P3 citam o mesmo teto	relatórios D0 e P3

E	Teste no gate (sim ou não)	Indicador em campo ou na esteira	Dado que já existe
06	6.4 cita linha da tabela	ambiente por faixa segue a tabela	seção 0 das specs
07	frase e Resultado não se negam	ocorrências de C1 param de crescer	agente de aprendizado
08	falha cai em `none`	quedas de conexão vs recusas na mesma janela	telemetria, estados
09	todo não-negociável tem marca	lacunas "sem mecanismo" no QA vão a zero	registro de lacunas
10	$n(\text{pico}) < n(\text{vizinhas})$	dwell e ação na tela de pico	telemetria de tela
11	porta, troca, chegada	minutos até a primeira ação	briefing D1 e telemetria
12	tabela etapa × revezamento	toques por membro do grupo por etapa	observação (E-19)
13	apressado ≠ investigador	variância dos eventos de investigação	`abriu_busca`, revisão antes de concluir
14	"que decisão muda se tirar"	elementos por pico caem, decisões não	seção 4 da jornada
15	caminho curto funciona	proporção de turmas no banco padrão, por rede	preparação docente
16	strings do Decidir vs teto	uso do áudio sob demanda por faixa	microinteração instrumentada
17	duas linhas do catálogo, três escadas	segunda missão do bimestre vs primeira	E-19
18	seção 18 trata quem nunca teve conta	reconhecimento de tela aos 6–8 anos	E-19
19	cinco números por missão observada	primeira correção de teto por dado	rubrica v0.1
20	cada linha aponta critério bloqueante	achados DES-03/07/08 na banca caem	consolidação da banca

6.3 A matriz de cobertura depois das emendas

A auditoria mostrou que todo critério de imersão que bloqueia é mecânico e todo que exige juízo não bloqueia. Depois das emendas, o quadro fica assim:

Código	O que pergunta	Severidade	Exige juízo?
2.1	Ambiente na lista, posse (inclusive de grupo), fidelidade, permanência	bloqueante	Pouco
2.2	É vivência e não leitura?	bloqueante	Pouco
2.3	**Porta, troca e chegada: o mundo se sustenta?**	bloqueante	**Sim**
2.4	A descoberta cabe numa frase?	bloqueante	Pouco
2.5	Diferencia-se do catálogo?	não bloqueante	Sim
2.6	Verbos nativos?	bloqueante	Não
2.7	**A mecânica sustenta a frase?**	bloqueante	**Sim**
2.8	**Sobe um degrau na trilha?**	condicional	Sim
6.6	**O apressado e o investigador divergem?**	bloqueante	**Sim**
O1 (pico)	**O pico é a tela mais enxuta?**	bloqueante	**Sim, por contagem**
O1–O5	Hierarquia, voz, fidelidade, beat, legibilidade	faixa própria	Sim

Quatro critérios que exigem juízo passam a bloquear, e cada um tem um teste que se responde com sim ou não. É o que a auditoria chamou de teoria do agarre: não uma régua de gosto, mas perguntas falsificáveis sobre se a missão prende.

7 Sequência, esforço e riscos

7.1 Ordem recomendada

1. **Onda 1 inteira, numa única emenda da rubrica (v1.19).** São correções sem decisão, e E-05 mostra que a fonte única já divergiu; quanto mais se espera, mais diverge. E-06 é a que mais muda o comportamento do avaliador por linha escrita.
2. **Onda 2 na mesma emenda ou na seguinte.** Já tem consenso documentado. E-08 é a de maior consequência ética.
3. **Onda 3 em duas partes.** Primeiro as que não dependem de número: E-10, E-11, E-12, E-14, E-20. Depois as que precisam de decisão pedagógica: E-13, E-15, E-16, E-17, E-18. E-19 começa em paralelo, porque tudo o que é **[CONVENÇÃO]** nesta proposta espera por ela.

7.2 Esforço por emenda

E	Arquivos	Linhas	Quem decide
01	3 arquivos de critério e catálogo	4	ninguém
02	`ambientes.md`	8	conferência no storybook
03	`catalogo-missoes.md`	10	ninguém, uma hora de pre-enchimento
04	script novo, resumo gerado, 5 includes	60	ninguém
05	`defaults-missao.md`, prompts 09 e 10	10	ninguém
06	fonte única, 2 testes	25	ninguém
07	gate estrutural, candidatos	3	priorização
08	9.4, bloco 9, defaults	4	priorização
09	prompts 21 e 30	6	priorização
10	rubrica de ofício, prompts 30 e 22	6	produto
11	2.3	12	produto
12	2.1, 10.2, defaults	8	produto
13	6.6, §11 da fonte, Regra 14	30	produto e pedagogia
14	arquivo novo, 6 includes	25	produto
15	4.3, Regra 11, D6	10	produto
16	6.1, §5 da fonte	8	pedagogia
17	2.8	8	produto
18	Regra 15, consolidação	6	produto e pedagogia
19	arquivo novo, catálogo	30	campo, semanas de pessoa
20	`criterios-dev.md`	10	produto

Fora E-19, o conjunto inteiro cabe em menos de trezentas linhas de markdown e um script pequeno. Nenhuma emenda toca o código Python da esteira: a severidade que o código lê já é a que as emendas usam.

7.3 Riscos da proposta como um todo

Quatro riscos, e o que cada emenda faz com eles

- **Bloquear por número não calibrado.** A auditoria elogiou a esteira por não fazer isso. Esta proposta só eleva a bloqueante o que é comparativo (E-10) ou o que se responde por simulação de dois estudantes (E-13). Todo número novo está marcado, e E-19 existe para calibrá-los.
- **Inflar o contexto dos prompts.** Cinco includes novos de uma referência de 268 linhas seriam um custo real. E-04 resolve com um resumo de uma página, gerado, com hash. E-14 tem meia página.
- **Reprovar mais e produzir menos.** Quatro critérios novos com veto vão reprovar missões que hoje passam. É o objetivo; mas a redação de cada um traz o falso-positivo conhecido, e o gate estrutural já propõe a correção junto com o achado.
- **Deriva.** A fonte única já divergiu (E-05). A proposta cria duas fontes novas (premissa e resumo) e as protege do mesmo modo: uma é meia página sem número; a outra é gerada e conferida por hash.

7.4 O que fica em aberto

Três coisas esta proposta não decide, e diz por quê:

- **O framework de seis etapas nos anos iniciais (A10).** A evidência é moderada por idade e vem de matemática e ciências; o "Explicar" da Unooria é mediado pelo professor. E-19 desenha o teste; a decisão vem depois do dado.
- **A severidade dos critérios do banco de dev.** Não são desta esteira. E-20 faz o que cabe: garante o equivalente a montante.
- **Os tetos numéricos da rubrica de ofício v0.1.** Continuam v0.1. Só a regra comparativa sobe. Os demais esperam E-19.

8 Anexo — Changelog proposto para a rubrica v1.19

Formato do changelog de `rubrica-oficio.md` e de `literatura-cognitiva.md` §8, para entrar nos arquivos junto com as emendas aceitas.

Mudança	Antes	Agora	Motivo
Lista fechada	6, com Roblox	5, com seção do DS	Roblox saiu em `ambientes.md`; o critério não acompanhou
Ausências por ambiente	tabela vazia	5 linhas [PROPOSTA]	O3 estava desarmado
Régua no design	1 prompt	resumo gerado em 6	regra de layout não chegava a quem faz layout
Números fora da fonte	tetos revogados em defaults e prompts	só citação por seção	fonte única divergiu
Uso por idade	intuição do avaliador	TIC Kids 2024, §10	dois obrigatórios eram decididos sem dado
2.3 diegese	desejável, teste binário	obrigatório, 3 testes	único critério sobre o mundo ficcional
2.7 mecânica sustenta	passo de prompt	critério	C1, pronto para emenda
2.8 progressão	não existia	condicional	dose importa; catálogo permite
6.5 repertório	obrigatório só 6º+	6.6 piso em todas as faixas	havia teto, não havia piso
6.1 defasagem	retirada uniforme	cláusula 9º e EM	leitura não é monotônica no Brasil
4.3 parametrização	IA principal, banco fallback	banco principal, IA camada	rede municipal, 43 % com formação
2.1 posse	só do estudante	ou do grupo, com protocolo	53 % das escolas compartilham
9.4 falha	estados exigidos	falha nunca é decisão	C7, grau `none`
O1 pico	faixa `oficio`	`bloqueio`	comparativa, sem calibragem
Premissa	uma frase em DES-03	arquivo lido por 6 agentes	detalhe sedutor vs fidelidade
Campo	reivindicado em §9	protocolo e instrumento	todo número é extrapolação até lá

Referências

[1] BROWN, E.; CAIRNS, P. *A grounded investigation of game immersion*. In: CHI '04 Extended Abstracts on Human Factors in Computing Systems. ACM, 2004, p. 1297–1300. DOI 10.1145/985921.986048.

[2] CHENG, M.-T.; SHE, H.-C.; ANNETTA, L. A. *Game immersion experience: its hierarchical structure and impact on game-based science learning*. Journal of Computer Assisted Learning, v. 31, n. 3, p. 232–253, 2015. DOI 10.1111/jcal.12066.

[3] GREEN, M. C.; BROCK, T. C. *The role of transportation in the persuasiveness of public narratives*. Journal of Personality and Social Psychology, v. 79, n. 5, p. 701–721, 2000. DOI 10.1037/0022-3514.79.5.701.

[4] HAMARI, J.; SHERNOFF, D. J.; ROWE, E.; COLLER, B.; ASBELL-CLARKE, J.; EDWARDS, T. *Challenging games help students learn: an empirical study on engagement, flow and immersion in game-based learning*. Computers in Human Behavior, v. 54, p. 170–179, 2016. DOI 10.1016/j.chb.2015.07.045. (Dois jogos educacionais; estudantes de ensino médio e superior; aprendizagem autorrelatada.)

[5] HUANG, G.; JIA, W.; YU, W. *Media literacy interventions improve resilience to misinformation: a meta-analytic investigation of overall effect and moderating factors*. Communication Research, 2024. DOI 10.1177/00936502241288103.

[6] LAW, E. L.-C.; BRÜHLMANN, F.; MEKLER, E. D. *Systematic review and validation of the Game Experience Questionnaire (GEQ): implications for citation and reporting practice*. In: Proceedings of the 2018 Annual Symposium on Computer-Human Interaction in Play (CHI PLAY). ACM, 2018, p. 257–270. DOI 10.1145/3242671.3242683.

[7] MISLEVY, R. J.; ALMOND, R. G.; LUKAS, J. F. *A brief introduction to evidence-centered design*. ETS Research Report Series, RR-03-16. Princeton: Educational Testing Service, 2003. DOI 10.1002/j.2333-8504.2003.tb01908.x.

[8] INEP — INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. *Relatório Brasil no PISA 2022*. Brasília: Inep/MEC, 2023. (50 % dos estudantes brasileiros de 15 anos abaixo do Nível 2 em leitura; média OCDE 26 %.)

[9] INEP — INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. *Sistema de Avaliação da Educação Básica — Saeb 2025: resultados*. Brasília: Inep/MEC, 2026.

[10] SINHA, T.; KAPUR, M. *When problem solving followed by instruction works: evidence for productive failure*. Review of Educational Research, v. 91, n. 5, p. 761–798, 2021. DOI 10.3102/00346543211019105.

[11] SUNDARARAJAN, N.; ADESOPE, O. *Keep it coherent: a meta-analysis of the seductive details effect*. Educational Psychology Review, v. 32, p. 707–734, 2020. DOI 10.1007/s10648-020-09522-4.

[12] CETIC.BR — CENTRO REGIONAL DE ESTUDOS PARA O DESENVOLVIMENTO DA SOCIEDADE DA INFORMAÇÃO. *TIC Educação 2024: pesquisa sobre o uso das tecnologias de informação e comunicação nas escolas brasileiras*. São Paulo: NIC.br, 2025.

[13] CETIC.BR — CENTRO REGIONAL DE ESTUDOS PARA O DESENVOLVIMENTO DA SOCIEDADE DA INFORMAÇÃO. *TIC Kids Online Brasil 2024: pesquisa sobre o uso da Internet por crianças e adolescentes no Brasil*. São Paulo: NIC.br, 2024. Amostra de 2.424 crianças e adolescentes de 9 a 17 anos.

[14] VAN LAER, T.; DE RUYTER, K.; VISCONTI, L. M.; WETZELS, M. *The extended transportation-imagery model: a meta-analysis of the antecedents and consequences of consumers' narrative transportation*. Journal of Consumer Research, v. 40, n. 5, p. 797–817, 2014. DOI 10.1086/673383.

Proposta redigida sobre o estado do repositório em 20 de setembro de 2026, em resposta à Auditoria de Imersão v1.0.
Nenhum artefato da esteira foi alterado na produção deste documento.