Reavaliação e Auditoria Ampliada

do Gerador de Missões

Parte I: o que os dois relatórios de 20 de setembro apontaram e o que segue em aberto.
Parte II: tudo o mais que separa o gerador de hoje do padrão ouro

Parte I: 12 achados e 20 emendas de 20/09 reconferidos contra 9 commits e 44 arquivos alterados
Parte II: auditoria nova em três frentes — 102 achados, 43 de gravidade alta, 11 pacotes de correção
Veredito: a esteira ficou mais rigorosa em contrato e currículo; nenhum achado de imersão fechou;
há gates que aprovam sem ler, e a esteira não se lembra de si

Data: 22 de setembro de 2026 • **Versão:** 2.0

Documento de análise. Não altera nenhum artefato da esteira.

Sumário

1 Sumário executivo **2**
1.1 O veredito em um parágrafo . . . 2
1.2 Farol dos doze achados . . . 2
1.3 Farol das vinte emendas . . . 3

2 Método **3**

3 O que mudou desde 20 de setembro **4**

4 Achado a achado **6**

5 Emendas que a evolução obriga a revisar **9**
5.1 E-15 — Banco curado como caminho principal, reconciliada com a transversalidade . 9
5.2 E-05 — Deriva de números: o lint do one-pager é o molde para as referências 9
5.3 E-09 — Não-negociável com mecanismo, mais barata com o modo de correção 10
5.4 E-20 — Equivalentes a montante, com DES-14 . . . 10
5.5 E-03 e E-18 — Ajustes menores . . . 10

6 Quatro achados da reavaliação de imersão **10**

7 Parte II — Auditoria ampliada: o que mais falta para o padrão ouro **11**
7.1 Por que esta parte existe . . . 12
7.2 Os números . . . 12
7.3 O que já está no padrão ouro, nas três frentes . . . 12

8 Os seis padrões por trás dos 102 achados **13**

9 Frente Produto — 30 achados **13**

10 Frente Design — 37 achados **16**

11 Frente Dev, código e governança — 35 achados **18**

12 Onze pacotes de correção **20**

13 Plano consolidado para o padrão ouro **22**
13.1 Sequência . . . 22
13.2 Esforço por pacote . . . 23
13.3 O que continua deliberadamente fora . . . 23

14 Mensurabilidade: o que se pode medir depois dos pacotes **23**

15 Anexo **24**
15.1 Commits entre 20 e 22 de setembro . . . 24
15.2 O que foi reconferido por busca direta neste relatório . . . 24
15.3 Changelog v1.19 revisto . . . 24

1 Sumário executivo

Este documento tem duas partes. A **Parte I** (Seções 1 a 6) reconfere os doze achados e as vinte emendas de 20 de setembro contra o repositório de hoje. A **Parte II** (Seção 7 em diante) é auditoria nova: o que mais falta, em qualquer dimensão, para o padrão ouro.

1.1 O veredito em um parágrafo

A esteira evoluiu em três frentes que os relatórios de 20 de setembro não pediram, e não se moveu em nenhuma das que pediram.
Entre 20 e 22 de setembro entraram um lint determinístico de contrato de plataforma e de origem de números, uma régua curricular bem mais exigente, a visão do professor como entregável de primeira classe (cinco telas, segundo grafo, critério novo no banco de dev), um one-pager resumido em linguagem simples e um modo de correção por etapa. São avanços reais, e vários deles melhoram a *mensurabilidade* que a proposta pedia.
Mas **nenhum dos doze achados de imersão foi fechado** e **nenhuma das vinte emendas foi aplicada**. Os arquivos que os achados citam ou não mudaram, ou mudaram em outro ponto. Três achados ficaram mais consequentes: o banco de dev ganhou um critério de design não bloqueante (A3), o catálogo desatualizado passou a ser lido por mais um agente (A7), e a emenda do banco curado (E-15) colide com a transversalidade que virou obrigatória e precisa ser reescrita.
O padrão que a auditoria descreveu se acentuou: **todo gate novo é mecânico e de contrato ou currículo; nenhum é de imersão**. A esteira ficou melhor em garantir que a missão seja conforme. Continua sem meio de garantir que ela prenda.

1.2 Farol dos doze achados

#	Achado	Estado 22/09	Evidência de hoje
A1	Roblox na lista fechada	**ABERTO**	`criterios-gate-estrutural.md:21`, `criterios-experiencia.md:49` ainda dizem "6" e listam Roblox
A2	Ofício não reprova	**ABERTO**	envelope em `30_qa_entregaveis.md:194` intacto; `rubrica-oficio.md` sem alteração
A3	Imersão com menos veto no dev	**ABERTO, agravado**	DES-14 entrou em `criterios-dev/2-design-imersao.md:89` sem `[BLOQUEANTE]`: Design passa a 2 em 14
A4	Diegese é desejável	**ABERTO**	`criterios-pedagogicos.md:8` intacto
A5	Tabela de ausências vazia	**ABERTO**	`ambientes.md:48-54`, cinco linhas em branco
A6	Régua não chega ao design	**ABERTO**	`literatura-cognitiva.md` incluída só em `09_experiencia_estudante.md`
A7	Catálogo desatualizado	**ABERTO, agravado**	3 missões, LinkedIn no campo; agora incluído também em `16b_one_pager_resumido.md:47`
A8	Emendas prontas e não aplicadas	**ABERTO**	`candidatos-a-criterio.md` sem alteração; C1, C3 e C7 "pronto pra emenda"
A9	Há teto, não há piso	**ABERTO**	6.5 em `criterios-experiencia.md:50` intacto, só anos finais e Médio

#	Achado	Estado 22/09	Evidência de hoje
A10	Framework uniforme por idade	CAMPO	pergunta de observação; nenhum protocolo de campo criado
A11	Uso por idade sem fonte nacional	ABERTO	zero ocorrências de “Kids Online” em `prompts/`
A12	Posse versus dispositivo compartilhado	ABERTO	2.1 e 10.2 em `criterios-gate-estrutural.md:21,79` intactos

1.3 Farol das vinte emendas

E	Emenda	Estado	O que a evolução muda nela
01	Roblox sai em todos os lugares	ABERTO	nada
02	Ausências preenchidas	ABERTO	nada
03	Catálogo com colunas de progressão	REVISAR	slug passou a ser `expNNefNb`; catálogo agora em 5 prompts
04	Resumo da régua no design	ABERTO	nada
05	Deriva de números fora da fonte	REVISAR	o lint de números do one-pager é o molde para conferir as referências
06	TIC Kids na régua e em 2.1/6.4	ABERTO	nada
07	2.7 mecânica sustenta (C1)	ABERTO	nada
08	Falha nunca é decisão (C7)	ABERTO	nada
09	Não-negociável com mecanismo (C3)	REVISAR	modo de correção barateia a opção A
10	Regra do pico bloqueia	ABERTO	nada
11	2.3 obrigatório	ABERTO	nada
12	Posse no compartilhado	ABERTO	nada
13	Piso de desafio por faixa	ABERTO	5.1 mais rigoroso é aliado natural
14	Premissa da imersão	ABERTO	nada
15	Banco curado principal	REVISAR	transversalidade obrigatória invalida a redação
16	Cláusula de leitura 9º e EM	ABERTO	nada
17	Progressão na trilha	ABERTO	depende de E-03
18	Pacote anos iniciais	REVISAR	ganha item: carga de preparo docente
19	Observação de campo	ABERTO	nada
20	Equivalentes a montante	REVISAR	DES-14 entra na tabela

2 Método

- **Diferença de repositório.** `git diff 5d7fcf9 HEAD` sobre `prompts/`, `agents/`, `pipeline/`, `tools/`, `scripts/` e `config.py`: 9 commits, 44 arquivos, 1.809 linhas acrescentadas e 129 removidas. Árvore de trabalho limpa.
- **Reconferência achado a achado.** Para cada um dos doze achados e das vinte emendas, a busca literal que o relatório anterior usou como evidência foi repetida sobre os arquivos de hoje. Arquivo citado que não aparece no diff é tratado como idêntico; arquivo que aparece foi lido na íntegra do diff.

- **Leitura dos artefatos novos.** `tools/contrato_produto.py` (185 linhas), `prompts/produto/16b_one_pager_resumido.md` (270), `prompts/transversal/00_triagem_correcao.md` (43), `pipeline/reexecucao.py` (663), `scripts/rerodar_etapa.py` (90), e a nova orquestração em `agents/produto/__init__.py`.
- **Regra de evidência.** Igual à dos dois relatórios: nenhuma afirmação sobre o repositório sem arquivo e linha conferidos hoje; nenhum número acadêmico novo.
- **Fora do escopo.** O relatório "padrão ouro de 20 agentes" em `documentacao-latex/` repete os mesmos doze achados e propõe outra arquitetura; por decisão do solicitante, não entra na comparação.

3 O que mudou desde 20 de setembro

Seis frentes. Para cada uma, o que merece crédito e o que ela faz com os achados.

F1 — Contrato de plataforma e origem dos números virou gate determinístico

O que entrou. `tools/contrato_produto.py` e o agente `A04bContratoProdutoCheck` (`agents/produto/__init__.py:271`), rodando antes do gate estrutural a cada rodada. Quatro regras: WebSocket como canal de sala reprova; estado em `localStorage` ou `IndexedDB` sai do texto; descritor SAEB só nos anos avaliados (`ANOS_SAEB = {2, 5, 9}`, linha 29); e **número com unidade sem origem no núcleo nem no briefing vira marcador** (seções 7, 8, 9, 10, 15 e 16, linha 27). O critério 9.1 ganhou os itens (h) e (i) (`criterios-gate-estrutural.md:64`); o 4.6 proíbe estado de cliente (linha 38); o P0b recebeu a regra "Origem dos parâmetros" (`04_secoes_apoio.md:31`) e uma seção de contrato de plataforma (linha 137); o gate recebe o relatório do lint e o aplica sem reavaliar (`05_gate_estrutural.md:21,51`).
Por que importa. É a primeira vez na esteira que um número sem fonte **reprova**. A auditoria elogiou `literatura-cognitiva.md` por marcar cada número como dado, extrapolação ou convenção; agora o mesmo princípio vale para o one-pager, por máquina.
O que faz com os achados. Nada, diretamente, mas oferece o molde para E-05: a deriva de números nas *referências* (tetos revogados em `defaults-missao.md`) continua intocada, e o lint que a pegaria é o mesmo desenho apontado para outro alvo (Seção 5.2).

F2 — A régua curricular ficou falsificável

O que entrou. 5.1 exige que **o texto oficial da habilidade descreva a ação em tela, sem reinterpretação**, e bloqueia com decisão pendente quando nenhuma habilidade de Cultura Digital do ano descreve a ação (`criterios-pedagogicos.md:37`); 5.2 manda **remover** código secundário sem momento em tela; 5.3 manda remover conexão disciplinar sem ação observável ("ausência é melhor do que conexão forçada"); 5.6 limita SAEB a 2º, 5º, 9º e 3º EM (linha 42). A Regra 12 do P0a (`01_nucleo_narrativo.md:67`) e as regras (a)–(d) do P0b (`04_secoes_apoio.md`) proíbem "escolher a menos ruim"; a spec copia o marcador de decisão pendente para o bloco 11 e o gate determinístico bloqueia por ele (`13_spec_missao.md`). PED-04 deixou de exigir autor e revisor nomeados (`criterios-dev/3-pedagogia-bncc.md:38`), decisão de 22/09 com justificativa registrada: reprovava por um ato que nenhum agente pratica.
Por que importa. A proposta pedia mensurabilidade; aqui a esteira ganhou uma medida curricular que não aceita aproximação. A justificativa de PED-04 é exemplar: um critério que só produzia marcador aberto foi removido com o motivo escrito.
O que faz com os achados. É aliado direto de E-13 (piso de desafio): uma decisão que discrimina estudantes e uma habilidade cujo texto descreve a ação são as duas metades do

mesmo argumento de evidência. Nenhum achado fecha por isso.

F3 — A visão do professor virou entregável, e a missão virou transversal

O que entrou. A Regra 11 do P0a (`01_nucleo_narrativo.md:66`) define o **recorte da aula** (disciplina, tema, assuntos, contexto) e o teste das três disciplinas; o bloco 8 da spec fixa o contrato (`formato-spec.md:83`); o P0b ganha as seções 9a e 9b (`04_secoes_apoio.md:77-78`); o 4.3 ganha o teste das três disciplinas (`criterios-pedagogicos.md:20`); a jornada ganha a Seção 1c e **cinco telas obrigatórias do professor** `E0-PROF-01..05` (`22_jornada.md:57,73`); o fluxo ganha o segundo grafo (`23_fluxo.md:49`); as telas do professor não podem ser cortadas por cota (`26_telas.md:58,132`); a copy ganha as strings do preparo; o QA ganha D6 reforçado e D6c (`30_qa_entregaveis.md:117,119`); o banco de dev ganha **DES-14** (`criterios-dev/2-design-imersao.md:89`); o coletor de links avisa quando não há tela do professor no Stitch (`agents/checkers.py`).
Por que importa. A auditoria apontou que 46 % dos professores não tiveram formação recente e que a rede municipal caiu para 43 %. Tratar o professor como usuário com telas, fluxo e critério próprios é a resposta correta a esse dado.
O que faz com os achados. Três coisas. **(1)** Invalida a redação de E-15: a parametrização deixou de ser camada opcional e virou contrato (Seção 5.1). **(2)** Agrava A3: DES-14 entrou sem `[BLOQUEANTE]`, e o banco de dev passa a ter 2 bloqueantes em 14 na dimensão de design. **(3)** Cria um item novo para o pacote dos anos iniciais: o professor menos formado da rede agora tem cinco telas de preparo obrigatórias, e nenhum critério mede quanto tempo isso leva (Seção 6).

F4 — Um one-pager para quem vai ler

O que entrou. O agente `A16bOnePagerResumido` ao fim da etapa de Produto, com o prompt `16b_one_pager_resumido.md`: sete seções, nove regras de linguagem (frase curta, voz ativa, verbo no lugar de substantivo abstrato, termo técnico com tradução na mesma frase, nada de jargão pedagógico), e um **contrato de evidência ternário por habilidade**. Sai em `.md`, `.docx` e `.html`. Roda *depois* da spec, de propósito, para copiar códigos já conferidos.
Por que importa. O relatório comparativo de 21/09 mostrou que o documento gerado tinha 3,4 vezes mais palavras que o do time e 35 minutos de leitura. A esteira respondeu com um documento para o leitor real, sem tirar o de auditoria. E o contrato de evidência ternário é mensurabilidade pedagógica escrita para o professor.
O que faz com os achados. Agrava A7: o catálogo, ainda com três missões e LinkedIn como exemplo, agora é incluído em **cinco** prompts (`16b:47`, `17:29`, `19:29`, `21:33`, `51:62`), e alimenta a "caixa de diferenciação" do documento que o time de produto lê.

F5 — Modo de correção por etapa

O que entrou. `00_triagem_correcao.md` decide de qual etapa recomeçar (spec, design, dev, nenhuma) a partir de um pedido em linguagem natural; `pipeline/reexecucao.py` e `scripts/rerodar_etapa.py` reexecutam uma etapa sobre o estado salvo; a etapa de Produto aceita `a_partir_de="spec"` e monta só o fim da etapa.
Por que importa para este relatório. Muda o custo de aplicar as emendas. Uma emenda de critério de produto podia exigir rodar a esteira inteira para ser observada; agora se reroda a etapa. E-09, que oferecia reordenar a esteira como opção B, fica ainda mais inclinada à opção A: o não-negociável sem mecanismo vira pedido de correção com etapa `spec`, e o modo de correção faz o resto.

F6 — Miudezas que evitam retrabalho

O slug passou a ser o id da plataforma, `expNNefNb`, derivado de ano e bimestre (`01_nucleo_narrativo.md:90`), o que elimina o marcador aberto por número de catálogo; os validadores de rastro ganharam correções de falso-positivo; o PRD deixou de acusar caminho divergente para experiência que já existe na plataforma. Nada disso toca os achados, mas E-03 precisa adotar o slug novo no catálogo.

O que não mudou, e é o que os relatórios pediam

Nenhum arquivo de `prompts/references/` citado pelos achados de imersão foi alterado: `ambientes.md`, `catalogo-missoes.md`, `candidatos-a-criterio.md`, `literatura-cognitiva.md`, `rubrica-oficio.md`, `defaults-missao.md`, `criterios-experiencia.md` e `criterios-gate-final.md` têm o mesmo conteúdo de 20/09. `criterios-gate-estrutural.md` e `criterios-pedagogicos.md` mudaram em 4.3, 4.6, 5.x e 9.1; as linhas 2.1, 2.3 e 10.2 são as mesmas.

4 Achado a achado

Para cada achado: estado, evidência de hoje, o que mudou ao redor e a emenda vigente. Quando a redação da proposta continua válida, ela é citada e não repetida.

A1 — Roblox na lista fechada ABERTO

Evidência de hoje. `criterios-gate-estrutural.md:21`: "um dos 6 suportados … Instagram, YouTube, Roblox, ChatGPT, TikTok, WhatsApp". `criterios-experiencia.md:49`: "Dentro dos 6 ambientes suportados … qual dos 6". `ambientes.md:27` e `05_gate_estrutural.md:44` continuam dizendo o contrário no mesmo contexto do mesmo agente.
Ao redor. O slug `expNNefNb` e a Regra 11 reforçam "um dos 5" no P0a; a contradição está só nos dois arquivos de critério.
Emenda vigente. E-01, redação inalterada. Quatro linhas.

A2 — Ofício não reprova, por construção ABERTO

Evidência de hoje. `30_qa_entregaveis.md:194` mantém as quatro faixas `"bloqueio-"atencao "oficio "decisao_humana"`; nenhuma instrução converte O1–O5 em bloqueio. `rubrica-oficio.md` continua v0.1, com a regra comparativa do pico declarada independente de calibragem e sem severidade.
Ao redor. O QA ganhou D6 reforçado e D6c, ambos sobre o professor, ambos com marca de bloqueio (bloqueio) para tela ausente. Ou seja: **tela do professor ausente bloqueia; pico invertido não**. A assimetria que a auditoria descreveu ficou mais visível.
Emenda vigente. E-10, redação inalterada. O filtro em `agents/checkers.py` continua roteando por `severidade == "bloqueio"`, então nada muda no código.

A3 — Imersão é a dimensão com menos veto no banco de dev ABERTO, agravado

Evidência de hoje. `criterios-dev/2-design-imersao.md` tem 14 critérios; os bloqueantes continuam DES-01 e DES-02. **DES-14 (linha 89) entrou sem `[BLOQUEANTE]`**, embora seu texto diga que "tela do preparo ausente do Stitch é lacuna com dono `telas`". A consolidação da banca exige zero reprovação nos 72 para verde, então DES-14 reprovado rebaixa para amarelo,

não bloqueia.
Matriz atualizada.

Dimensão	Bloqueantes	Total	Proporção
Dados, telemetria e LGPD	7	15	47 %
Produto e narrativa	5	16	31 %
Pedagogia e BNCC	4	15	27 %
Design e imersão	**2**	**14**	**14 %**
Técnica e arquitetura	2	13	15 %

Nuance. O banco de dev é do time da plataforma, e a esteira o lê em versão datada; DES-14 foi acrescentado do lado de cá, o que mostra que a esteira *pode* escrever nesse arquivo. Se pode acrescentar critério, pode marcar severidade, e a decisão de deixar DES-14 sem bloqueio é decisão desta esteira.
Emenda vigente. E-20, com a tabela de equivalentes ganhando a linha DES-14 (Seção 5.4).

A4 — Simulação diegética é desejável — ABERTO

Evidência de hoje. `criterios-pedagogicos.md:8`: 2.3 Desejável, teste binário inalterado. O resumo de contagem continua "Imersão: 1 obrigatório, 2 desejáveis".
Ao redor. O arquivo mudou em 4.3 e 5.x, na mesma tabela; a linha 8 não foi tocada.
Emenda vigente. E-11, redação inalterada (porta, troca, chegada).

A5 — Tabela de ausências vazia — ABERTO

Evidência de hoje. `ambientes.md:48-54`: cinco linhas com a coluna "Não tem" em branco. O3 da rubrica de ofício continua se declarando desarmado.
Ao redor. O D9 e o D5 seguem incluindo `ambientes.md`; a tabela vazia chega a mais dois agentes do que a auditoria contou, porque o QA de design e a banca a leem também.
Emenda vigente. E-02, com as cinco linhas propostas marcadas [**PROPOSTA**]. Continua sendo a correção mais barata e mais valiosa do arquivo, nas palavras do próprio arquivo.

A6 — A régua empírica não chega ao design — ABERTO

Evidência de hoje. Mapa de includes reconferido: `literatura-cognitiva.md` continua incluída em exatamente um prompt (`09_experiencia_estudante.md:19`). Jornada e QA recebem `rubrica-oficio.md`; telas, copy e ambiente não recebem régua nenhuma.
Ao redor. Os prompts de design cresceram (Seção 1c, cinco telas do professor, segundo grafo). Cada acréscimo torna mais caro incluir a referência inteira, e mais necessário o resumo gerado que E-04 propõe.
Emenda vigente. E-04, redação inalterada.

A7 — Catálogo desatualizado desarma a diferenciação — ABERTO, agravado

Evidência de hoje. `catalogo-missoes.md`: três missões, "LinkedIn" na linha 11 como exemplo de ambiente, nenhuma das missões-gabarito exp-04, 06, 07 e 08. O 2.5 continua se autoanulando por "N/A — catálogo incompleto".
Ao redor. O catálogo passou a alimentar também o one-pager resumido (`16b_one_pager_resumido.md:47`), que tem uma caixa de diferenciação lida pelo time de produto. Um catálogo com três linhas produz uma caixa de diferenciação vazia no documento mais lido da esteira.

Emenda vigente. E-03, com uma revisão: a coluna de identificação usa o slug da plataforma `expNNefNb` (Regra 0 do P0a), não "exp-NN". E-17 (progressão) continua dependente dela.

A8 — Emendas prontas e não aplicadas ABERTO

Evidência de hoje. `candidatos-a-criterio.md` sem alteração: C1 "implementado como Passo 4.5, emenda formal pendente"; C3 "pronto pra emenda, mais proposta de reordenar"; C7 "pronto pra emenda".
Ao redor. O 9.4 continua obrigatório e continua sem o teste de contaminação (falha registrada como decisão), que é o que motivou C7. O gate estrutural continua fazendo o passo 4.5 por instrução de prompt (`05_gate_estrutural.md`), sem critério na rubrica.
Emenda vigente. E-07 e E-08 inalteradas. E-09 revisada: o modo de correção favorece a opção A (Seção 5.3).

A9 — Há teto, não há piso ABERTO

Evidência de hoje. `criterios-experiencia.md:50`: 6.5 obrigatório só em anos finais e Médio, desejável nos iniciais. Nenhum critério novo pergunta se a missão exige o bastante.
Ao redor. A frente F2 criou o aliado que faltava: 5.1 agora exige que o texto da habilidade descreva a ação. Habilidade que descreve a ação e decisão que discrimina estudantes são as duas condições do desenho centrado em evidência [5]; a esteira passou a exigir a primeira e continua sem a segunda.
Emenda vigente. E-13, redação inalterada (6.6 com o teste do estudante apressado).

A10 — Framework uniforme do 1º EF ao 3º EM CAMPO

Evidência de hoje. As seis etapas seguem aplicadas sem variação por idade. Nenhum protocolo de observação de campo foi criado; `literatura-cognitiva.md` §9 continua reivindicando.
Ao redor. O modo de correção (F5) torna barato rodar a mesma missão em duas ordens para o teste que E-19 desenha, porque a variante é uma correção a partir da spec.
Emenda vigente. E-19, redação inalterada. Continua sendo pergunta, não defeito.

A11 — Uso de plataforma por idade sem fonte nacional ABERTO

Evidência de hoje. Busca por "Kids Online" e "TIC Kids" em `prompts/`: zero ocorrências. Os testes "o aluno diria eu uso isso?" (2.1) e "qual dos 6 um estudante mediano usaria" (6.4) continuam decididos por intuição.
Ao redor. Nada. É a emenda de Onda 1 que mais muda o comportamento do avaliador por linha escrita, e a única que tem dado nacional pronto para colar.
Emenda vigente. E-06, redação inalterada.

A12 — Conta própria e três por computador nunca reconciliados ABERTO

Evidência de hoje. `criterios-gate-estrutural.md:21` (teste de posse: "a conta é do aluno ou de um personagem?") e linha 79 (10.2: "3 alunos dividem 1 computador") intactos. O padrão `2-4-decide-em-grupo-registra-por-grupo` de `defaults-missao.md` continua marcado como pendente de confirmação.
Ao redor. A transversalidade (F3) adicionou uma pergunta nova ao mesmo cenário: no dispositivo compartilhado, o recorte da aula é um só por Atividade, então o grupo vê o mesmo conteúdo; isso favorece a decisão "conta do grupo" de E-12, porque o conteúdo já é coletivo por construção.

Emenda vigente. E-12, redação inalterada.

5 Emendas que a evolução obriga a revisar

Cinco emendas mudam de redação ou de custo. As outras quinze valem como estão na proposta.

5.1 E-15 — Banco curado como caminho principal, reconciliada com a transversalidade

O conflito. A proposta pedia que o banco curado fosse o caminho principal e a parametrização por IA uma camada opcional, obrigatória só nos anos finais e Médio. Desde 21/09 a parametrização é o **recorte da aula**, contrato do bloco 8 da spec, com cinco telas obrigatórias e teste das três disciplinas em 4.3, D6c e DES-14. A decisão de produto está tomada e registrada; a emenda não pode contrariá-la.

O que a evidência brasileira ainda sustenta. O professor dos anos iniciais é o menos formado da rede (43 % na rede municipal [10]) e agora tem cinco telas de preparo. O risco que E-15 apontava não desapareceu: mudou de "o professor precisa parametrizar" para "o professor precisa atravessar cinco telas antes de dar aula".

A reconciliação. Manter a transversalidade como está e exigir três coisas que hoje o 4.3 não exige: que o banco padrão funcione *sozinho*, que ele esteja a um toque na segunda tela, e que o caminho curto seja medido.

Redação proposta

4.3, acrescentar ao teste prático, depois do teste das três disciplinas:
"**Teste do caminho curto:** a missão roda por completo com o professor tocando apenas 'usar banco padrão' em `EO-PROF-02`, sem passar por geração nem curadoria (`EO-PROF-03` e `04` puladas)? Se não, **reprova**: o banco curado é *fallback* de nome, não de fato. **Teste de posição, anos iniciais:** em missão de 1º–5º ano, o botão do banco padrão é a primeira ação visível de `EO-PROF-02`, e o recorte da aula vem depois; nos anos finais e Médio a ordem é livre. Ordem invertida nos anos iniciais é **alerta**. **Contagem de preparo:** a seção 9a declara quantas telas e quantos toques o caminho curto e o caminho com IA exigem; sem a contagem, **alerta**."
Em `26_telas.md`, "Telas de professor — obrigatórias": "`EO-PROF-02` sai construída nos dois estados: com o banco padrão em primeiro nível (anos iniciais) e com o recorte em primeiro nível (anos finais e Médio)."
Em `30_qa_entregaveis.md`, D6: acrescentar "o caminho curto `EO-PROF-01` → `02` → `05` existe no fluxo do professor como aresta própria, rotulada 'usar banco padrão'; ausência é ticket com dono `fluxo`."

Teste falsificável: o caminho curto existe como aresta no segundo grafo Mermaid e a missão chega a `ativado` por ele.

Como medir se funcionou: a plataforma registra a preparação por Atividade; a proporção de Atividades ativadas pelo caminho curto, por rede e por faixa, diz se a transversalidade está sendo usada ou contornada. Se nos anos iniciais a maioria usa o banco padrão, a decisão de posição estava certa; se ninguém usa, pode sair.

5.2 E-05 — Deriva de números: o lint do one-pager é o molde para as referências

Estado. Os quatro pontos de deriva continuam: `defaults-missao.md:90` ("Ato ≤ 12 min em anos iniciais, ≤ 15 nos finais, ≤ 20 no EM", tetos revogados na revisão de setembro da fonte única), `defaults-missao.md:100` ("≤ 4–5" opções no Médio, corrigido para 4 na fonte), `10_adequacao_pedagogica.md:44` ("30 a 40 estudantes", contra 25 e 32 na fonte), `09_experiencia_estudante.md:27,36` (Piaget como estágio e "os dois testes do 3.5").

O que mudou. A esteira agora tem um lint que lista número sem origem no one-pager (`tools/contrato_produto.py`). O mesmo desenho, apontado para `prompts/references/` e `prompts/produto/`, resolve E-05 de forma permanente em vez de pontual.

Redação proposta

Ampliação de E-05. Além de alinhar os quatro pontos à fonte, criar `scripts/conferir_referencias.py`, no molde de `contrato_produto.py`: extrai da fonte única as tabelas de teto (opções por faixa, minutos por ato, teto agregado, alunos por turma) e procura em `references/` e `produto/` qualquer número com a mesma unidade que não esteja na fonte. Saída: lista de arquivo, linha e número divergente. Roda no mesmo lugar em que `gerar_bncc_referencia.py` confere o hash do JSON. Primeira execução deve devolver exatamente os quatro pontos acima; execução limpa é a condição de fechar E-05.

5.3 E-09 — Não-negociável com mecanismo, mais barata com o modo de correção

A proposta oferecia duas opções: classificar os não-negociáveis do briefing de ofício (`[MECANISMO]` ou `[RS-n]`) ou reordenar a esteira. O modo de correção (F5) muda o custo relativo: um `[RS-n]` agora é literalmente um pedido de correção com etapa `spec`, que `00_triagem_correcao.md` sabe classificar e `reexecucao.py` sabe rodar. A opção A passa a ter caminho de execução pronto; a opção B continua exigindo mudança em `agents/design/__init__.py`. **Recomendação: só a opção A**, com uma frase a mais no D1: "todo `[RS-n]` é emitido no formato do envelope da triagem de correção, com etapa `spec`".

5.4 E-20 — Equivalentes a montante, com DES-14

A tabela de equivalentes da proposta ganha uma linha. DES-14 pergunta se a visão do professor está completa e transversal; não bloqueia no banco; a montante, D6 e D6c do QA já bloqueiam tela do professor ausente. Ou seja, para DES-14 a esteira *já* faz o que E-20 pede para os outros. O que falta é o inverso: registrar em `criterios-dev.md` que DES-14 nasceu do lado de cá e que a severidade dele é decisão desta esteira, não do time da plataforma. Se a esteira pode acrescentar critério ao banco, a objeção da auditoria a mudar DES-03 ("não é nosso") enfraquece, e a decisão de promover DES-03 a bloqueante volta à mesa como decisão de produto.

5.5 E-03 e E-18 — Ajustes menores

E-03. A coluna de identificação do catálogo usa `expNNefNb` (o id da plataforma fixado na Regra 0 do P0a), não "exp-NN". As linhas propostas na proposta continuam válidas; só o formato do slug muda. Acrescentar a coluna "Observada em campo" continua sendo o gancho de E-19.

E-18. O pacote dos anos iniciais ganha um item: **carga de preparo docente**. Com cinco telas obrigatórias e o professor menos formado da rede, o pacote precisa da contagem de preparo de E-15 revisada e de um teste em D6b ("a professora como usuária") que hoje é amarelo: "conduz sem ter feito a missão antes?". Para 1º–5º ano, esse teste deveria ser respondido com uma simulação de preparo em minutos, no mesmo espírito do protocolo de simulação do P3.

6 Quatro achados da reavaliação de imersão

Quatro achados que surgiram ao reconferir os doze da auditoria. Entram nos pacotes da Parte II (N1 no Pacote I, N2 no E, N3 no G, N4 no D).

N1 — DES-14 entrou sem bloqueio, e a esteira escreveu nele

Evidência. `criterios-dev/2-design-imersao.md:89`, sem `[BLOQUEANTE]`; `40_validacao_design_imersao.md` passou a pedir "14 critérios". `criterios-dev.md` continua declarando os critérios como "do gate do time de dev".
O que quebra. Missão sem tela do professor no Stitch reprova no QA de design (D6, bloqueio) e só rebaixa para amarelo na banca de dev. Duas severidades para o mesmo fato, em duas etapas consecutivas. E a premissa de que o banco de dev não é desta esteira ficou falsa por ação da própria esteira.
Correção. Marcar DES-14 `[BLOQUEANTE]` ou explicar em `criterios-dev.md` por que não é; e registrar naquele arquivo quais critérios nasceram do lado de cá. Uma linha.

N2 — Cinco telas de preparo, nenhum teto de tempo de preparo

Evidência. `22_jornada.md:73` fixa cinco telas obrigatórias; `04_secoes_apoio.md:77` descreve o fluxo em cinco passos; 4.3 testa completude e transversalidade; D6b pergunta "em quantos segundos ela entende onde a turma está" e é amarelo. Nenhum critério pergunta **quanto tempo o preparo leva** nem simula o professor sem formação em tecnologia.
O que quebra. A régua do estudante tem teto por ato e teto agregado, com fonte. A régua do professor não tem nenhum número. Para a rede municipal (43 % com formação continuada, 27 % de uso efetivo em atividade [10]), o preparo é a barreira de entrada da missão inteira.
Correção. A contagem de preparo de E-15 revisada (telas e toques do caminho curto e do caminho com IA, declarada na seção 9a) e o teste de simulação de preparo em E-18. Sem número novo: é contagem, marcada **[CONVENÇÃO]** até E-19 medir.

N3 — Todo gate determinístico novo é de contrato ou currículo

Evidência. Os gates determinísticos da esteira hoje: `BnccCheck` (currículo), `ManifestoCheck` (contrato), `TelemetriaCheck` (contrato), rastro de lacunas (contrato), checagem de PRD (contrato) e, desde 21/09, `ContratoProdutoCheck` (contrato e origem de números). Zero sobre imersão, ofício ou desafio.
O que quebra. Nada quebra; é a auditoria confirmada com mais dados. O que se verifica por máquina bloqueia; o que exige juízo não. A proposta já apontou a exceção que permite começar a inverter isso sem número calibrado: a regra comparativa do pico (E-10), que é verificável por contagem sobre o frame e poderia até ser determinística, se a jornada emitir a contagem de elementos por tela em formato legível por máquina.
Correção. E-10 como está, mais uma frase em `22_jornada.md`: a coluna "Teto de elementos (contado)" da Seção 4 sai como número inteiro, sem texto, para que um checker futuro a leia.

N4 — A fonte única continua a divergir, e agora há molde para impedir

Evidência. Os quatro pontos de E-05, intactos, ao lado de um lint que faz exatamente isso para o one-pager.
O que quebra. O D0 aplica como padrão verde um teto que a fonte única revogou; o P3 pode citar outro. Dois relatórios sobre a mesma missão podem discordar sobre o mesmo ato.
Correção. E-05 ampliada (Seção 5.2).

7 Parte II — Auditoria ampliada: o que mais falta para o padrão ouro

7.1 Por que esta parte existe

As duas partes anteriores respondem à pergunta "os achados de 20 de setembro fecharam?". Esta responde a outra: **o que mais, além daqueles, separa o gerador de hoje do padrão ouro?** Para isso, a esteira inteira foi relida do zero, em três frentes paralelas, sem o recorte de imersão: produto (11 prompts, 2 transversais, 16 referências e a orquestração), design (11 prompts, 8 referências, a orquestração e as ferramentas de Stitch, Miro e protótipo) e dev, código e governança (9 prompts, 6 referências, todo o código Python, testes, scripts, Dockerfile, CI e duas execuções reais em `output/`).

Regra de evidência. Cada achado traz arquivo e linha. Os de maior gravidade de cada frente foram reconferidos por busca direta neste relatório (lista no anexo); os demais carregam a citação do auditor da frente. Nenhum achado repete A1–A12 nem E-01–E-20; quando reforça um deles, diz.

7.2 Os números

Frente	Achados	Alta	Média	Baixa
Produto (P)	30	9	19	2
Design (D)	37	15	21	1
Dev, código e governança (V)	35	19	14	2
Total novo	**102**	**43**	**54**	**5**

Somados aos 12 achados da auditoria e aos 4 desta reavaliação, são **118 achados abertos**. O número assusta menos do que parece: a Seção 8 mostra que quase todos são manifestações de seis padrões, e a Seção 12 os agrupa em onze pacotes de correção.

7.3 O que já está no padrão ouro, nas três frentes

Honestidade metodológica antes da lista de falhas. Os três auditores registraram, com evidência, o que está acima da média:

- **A Regra Zero e os quatro padrões de spoiler** (`01_nucleo_narrativo.md:26-50`): erro definido, par contraexemplo/exemplo, teste operacional e palavras-sentinela.
- **O registro negativo da literatura** (`literatura-cognitiva.md:218-240`): o que não sustenta a régua, com as replicações.
- **O lint determinístico antes do gate** (`agents/produto/__init__.py:270-278`): "não reavalie: aplique".
- **O teste de acionabilidade dos ajustes** (`10_adequacao_pedagogica.md:186-194`): "ficou mais claro" não é aceite.
- **`celulas-consumidas.md` inteiro**: uma linha por célula da spec com quem consome e o que acontece sem ela, mais a regra "célula que nenhum agente consome sai".
- **A guarda `minimo_fracao`** (`agents/checkers.py:208-214`): impede que um fragmento substitua o documento, com o incidente que a motivou no docstring.
- **Mermaid renderizado nó a nó com fallback sem rede** (`tools/artefatos_html.py:146-156`).
- **"Consistência perfeita é sinal de alerta"** (`30_qa_entregaveis.md:101`): a única heurística anti-eco entre agentes encadeados que os auditores conhecem.
- **O teste de interpolação** (`test_pipeline.py:108-131`): toda chave de prompt precisa existir no estado. Impede a classe de falha mais cara desta arquitetura.

- **O teste de vocabulário de status** (`test_pipeline.py:1849-1874`): fecha a distância prompt-código no ponto em que ela costuma abrir.
- **Cópia sincronizada da plataforma com SHA e neutralização de chaves** (`scripts/sincronizar_plataforma.py:78-166`).
- **Contenção de resposta de MCP com orçamento por agente** (`agents/callbacks.py:201-249`).

8 Os seis padrões por trás dos 102 achados

Padrão 1 — Gates que falham para o lado do aprovado. Quando o modelo devolve vazio, truncado ou sem envelope, três gates diferentes concluem "aprovado" (V-01 banca, D-27 QA de design, P-01 parecer de adequação, cuja chave de status nunca é escrita). Envelopes marcados "bloqueante" não têm leitor (V-08, D-07, D-08). É o inverso do que um gate deve fazer.
Padrão 2 — Escrito e nunca lido. Colunas, envelopes, definições de pronto e propostas inteiras são produzidas a cada execução e descartadas: a coluna Tensão (D-05), a raia de evidência (D-24), os envelopes de D1–D8 (D-07), o brief de escopo (P-13), as propostas do agente de aprendizado (P-25, V-30). Custam contexto e não compram nada, e ensinam o agente a declarar sem verificar.
Padrão 3 — Opinião onde cabia máquina. A consolidação da banca é LLM (V-02); o frontmatter do PRD, a matriz habilidade–evidência–dado, os graus de medida e a estrutura do PRD não têm verificador (V-11, V-12, V-17); o QA audita o relatório sobre o protótipo e não o HTML (D-01); a fidelidade é aferida por um screenshot que o QA é proibido de pedir (D-02). Confirma o achado A3 da auditoria com mais dados: o que se verifica por máquina bloqueia, o que exige juízo não; e há muito do que se verifica por máquina que ainda é juízo.
Padrão 4 — Vocabulário sem fonte única. Versões de rubrica (v1.13 a v1.18 em arquivos diferentes, P-21, V-31), IDs de tela (três convenções, D-13), IDs de achado (P-07), status de envelope (P-05, P-06), etapas do framework (P-18), "anos iniciais" (1º–2º ou 1º–5º, D-20), contagem de critérios (72 ou 73, V-20), donos de ticket (V-05). Cada divergência é pequena; juntas, tornam o roteamento e a contagem não confiáveis.
Padrão 5 — A escola pública é o primeiro corte. O estado degradado (2–4 por aparelho) é o primeiro a sair quando a cota aperta (D-18); sem CAA não há piso de alvo de toque (D-19); o 3º–5º ano fica sem áudio obrigatório (D-20); o piso "sem dispositivo, sem sinal em sala" que a fonte única declara não tem cenário (P-29); a exposição de dado de criança na projeção é pergunta de opinião com teto amarelo (D-23). É o mesmo padrão da auditoria (anos iniciais com menos critério), agora visto no design.
Padrão 6 — A esteira não se lembra. Sem temperatura, seed, modelo ou hash de prompt registrados (V-22); sem tokens contados (V-23); sem histórico entre execuções (V-30); sem fixture de missão-gabarito (V-28); referências vivas com um único commit desde 02/09 (P-25); versão da plataforma citada em dois lugares com dois commits (V-18). Não há como responder se o gerador melhora com o tempo.

9 Frente Produto — 30 achados

ID	Achado e evidência	Grav.	Correção
P-01	**O status do parecer de adequação nunca é escrito.** O loop de avaliações lê `adequacao_status` (`agents/produto/__init__.py:334`); nenhum agente o produz. Parecer INADEQUADA, com cinco vetos, não bloqueia nem reexecuta nada.	Alta	`EnvelopeGateAgent` após o A10 gravando a chave
P-02	**O gate final não lê o parecer.** `11_gate_final.md:5-21` lista só três relatórios; F1 fala de "três". Viabilidade na escola pública, evidência e equidade ficam fora do release.	Alta	`{adequacao_report?}` no 11; F1–F3 com quatro relatórios
P-03	**A spec também não lê o parecer.** `13_spec_missao.md:7-27`; "Ajustes exigidos" (`10:141`) morrem; o revisor por parecer só roda com mais de uma rodada (`config.py:122`).	Alta	tornar o parecer bloqueante ou declará-lo consultivo
P-04	**Gate final: critério binário, prompt ternário.** F8 manda só verde ou vermelho (`criterios-gate-final.md:14`); o prompt manda amarelo (`11:35`).	Média	reescrever F8 com três vereditos
P-05	**Envelope fora do contrato.** `aprovado_com_ressalvas` não está no enum de `contrato-saida.md:23`; `artefatos`, `pronto` e `devolucao` nunca são emitidos em produto.	Média	atualizar o contrato ao vocabulário real
P-06	**Mesmo veredito, dois status.** `criterios-pedagogicos.md:79` diz `aprovado`; `08:39` diz `aprovado_com_ressalvas`.	Média	apagar o parêntese da linha 79
P-07	**Esquema de IDs violado.** `formato-relatorios.md:11` define A como atenção; `08:84` usa A1 como bloqueio; 09 usa E1; 10 usa E2-A3. A contagem por classe do aprendizado sai errada.	Média	namespace por agente
P-08	**O gate estrutural não recebe a rodada.** `gate_estrutural_rodada` vai ao 11 e ao 51, não ao 05, cuja regra de parada depende dela (`05:74-80`).	Média	injetar a variável no A05
P-09	**Ninguém a jusante do micro-gate testa spoiler.** Zero ocorrências de "spoiler" ou "gap" nos quatro arquivos de critério; o código afirma que o P1 audita (`agents/produto/__init__.py:255`). Reforça C3 da auditoria.	Alta	critério de gap no gate estrutural ou em F6
P-10	**Bloco 7 da spec (acessibilidade) sem produtor.** Consumido por D4, D4b e D5 (`celulas-consumidas.md:86`); o one-pager não tem seção de acessibilidade e o único critério é o áudio de 1º–2º.	Alta	seção no 04 e critério na categoria 6
P-11	**Ensino Médio bloqueado por eixo que não existe.** Prompts 01 e 04 exigem "eixo Cultura Digital"; `bncc-computacao-letramento-digital.md:15` e `tools/bncc.py:176` dizem que o EM não tem eixo e emitem só atenção.	Média	exceção do EM nas Regras 12 e 2 e no 5.1
P-12	**Triagem manda mecânica para spec, e a reexecução a partir da spec não toca o one-pager.** `00_triagem:20`; `reexecucao.py:40` não tem etapa produto; `agents/produto:233`. Spec e one-pager divergem sem gate.	Alta	criar etapa `produto` na reexecução

ID	Achado e evidência	Grav.	Correção
P-13	**Brief de escopo some na primeira revisão.** Compartilha `output_key` com o one-pager (`04:108`; `07:38`; `artifacts.py:22`) e nenhum critério o cobre.	Média	chave e artefato próprios
P-14	**O contrato de evidência nasce no último agente.** `16b:119` inventa marcadores ternários; `16b:9` diz que não decide nada; sem fonte na seção 12 nem no bloco 11; sem gate depois.	Alta	matriz na seção 12 e no bloco 11; 16b só copia
P-15	**"Esse produto distingue quem aprendeu?" só no parecer sem poder** (`10:96`); 7.3 pede só que descreva o que captura (`criterios-gate-estrutural.md:55`).	Alta	novo 7.5 obrigatório
P-16	**Prompt 10 proíbe número próprio e fixa um.** `10:29` versus `10:68` ("três a quatro elementos"), o erro histórico que a fonte única registra (`literatura-cognitiva.md:5`).	Média	reportar contagem sem teto
P-17	**Três réguas de tempo incompatíveis.** 25 min (6.2), 50 min (4.5), mais de 50 % do declarado (`10:117`), "aulas" (`16b:150`); nenhum gate reconcilia.	Média	subordinar 4.5 e o veto 5 ao teto do 6.2
P-18	**4.5 usa etapas que não existem no framework** ("ambientação, exploração, revelação", `criterios-gate-estrutural.md:37`).	Média	reescrever nas seis etapas
P-19	**7.4 é "Obrigatório — aplicado como sugestão"** (`:56`); o tipo condicional só existe no resumo.	Baixa	tipo Desejável
P-20	**Resumo de contagem pedagógico errado.** Imersão "1 obrigatório" com 2.2 e 2.4 obrigatórios; 13 declarados, 14 reais (`criterios-pedagogicos.md:66,70`).	Média	recontar
P-21	**Versão de rubrica diverge em todo par prompt/critério** (v1.17 nos prompts, v1.16 nos critérios; v1.18; v1.15; v1.13).	Baixa	versão única incluída
P-22	**`formato-spec` proíbe campo aberto, `13_spec` o obriga**; cabeçalhos diferentes (`formato-spec:14` e `13:81`); "Gate 0, agente 1" sem correspondente.	Média	atualizar `formato-spec.md`
P-23	**`modelo-de-insumo.md` contradiz a spec** em gabarito com autor (31), execução offline (86) e inputs do professor (52).	Média	alinhar ou marcar legado
P-24	**`celulas-consumidas.md:94` ainda cobra "tema, foco, contexto"**; sem `disciplina` e `assuntos`, o D0 não cobra transversalidade.	Média	trocar a célula 8; acrescentar a tabela das três aulas
P-25	**Aprendizado sem aplicador.** `51:6,121` propõe; catálogo, padrões e candidatos têm um único commit (`59b52d8`, 02/09). Reforça A7 e A8 com datas.	Alta	arquivo versionado de pendências e passo humano
P-26	**Linha de catálogo proposta pelo 51 não encaixa no catálogo** (7 colunas em `51:71`, 8 no arquivo); status "Gold standard" fora do vocabulário.	Média	copiar o cabeçalho literal
P-27	**Aprendizado não recebe** `adequacao_report`, `one_pager_resumido`, `micro_gate_report`, `contrato_produto_report` (`51:30-58`).	Média	acrescentar os quatro
P-28	**Rodada de correção do 09 espera um gate final que ainda não rodou** (avaliações antes do gate final, `agents/produto:347-360`).	Média	remover o bloco ou fechar o loop
P-29	**O piso "sem dispositivo, sem sinal" não tem cenário.** `literatura-cognitiva.md:208-209` o declara; 10.1 exige só 1:1, 2–4 e projeção.	Alta	cenário (d) conectividade intermitente

ID	Achado e evidência	Grav.	Correção
P-30	**Guia, voz, minutos até a primeira ação e tensão são exigidos no design e nunca no produto** (21:56; 30:123).	Média	item no one-pager e no gate estrutural

10 Frente Design — 37 achados

ID	Achado e evidência	Grav.	Correção
D-01	**O QA audita o relatório sobre o protótipo, não o HTML** (30:37,81,85). "Abre sozinho, sem placeholder" é autodeclaração do D8.	Alta	lint determinístico do HTML no `ArtefatosDesignAgent`
D-02	**O3 exige screenshot** (`rubrica-oficio.md:58`) **e o QA é proibido de pedir imagem** (30:73). A fidelidade é aferida por opinião.	Alta	teste sobre duas telas do Stitch, ou mover O3 à revisão humana
D-03	**Sem inventário de affordances e microinterações por ambiente**; DES-12 sem produtor ("microinter" tem zero ocorrências em design).	Alta	`affordances-por-ambiente.md`; coluna instrumentada no inventário
D-04	**Nenhum prompt trata áudio do ambiente clonado**; dois dos cinco ambientes são de vídeo.	Média	linha "Áudio nativo" na ficha do D9
D-05	**A coluna Tensão do mapa de beats** (21:72) **não é consumida** pela jornada (22:76) nem pelo QA (30:123).	Média	coluna no inventário e item em D7
D-06	**"Minutos até a primeira ação" sem coluna de tempo** em tela ou aresta; o D7 confere contra nada.	Média	coluna minuto acumulado
D-07	**Envelopes de D1–D8 nunca lidos.** Diagnóstico lê três chaves (`diagnostico.py:22-35`); `pronto.itens_abertos` não retém, contra `contrato-saida.md:72`.	Alta	checker leve por agente, ou remover a promessa
D-08	**`devolvido` da jornada não existe na execução** (22:29; Sequential puro); `brief-oficio` fora de `MAPA_RETRABALHO` (`agents/design:277`): é o único documento que ninguém pode corrigir.	Alta	brief no mapa; gate registrador
D-09	**Ordem de retrabalho inverte a dependência**: copy-revisão antes de CAA e telas (`agents/design:264`), que ela consome (27:19,35).	Alta	reordenar
D-10	**Telas leem a copy da passada 1** (26:25) enquanto tickets de texto vão à revisão (30:165).	Média	consumir a revisada com queda
D-11	**Nenhum ticket é endereçável ao protótipo** (tabela 30:152-161; mapa).	Média	dono `prototipo-navegavel`
D-12	**`atencao`, `oficio` e `decisao_humana` nunca são despachados** (`checkers.py:622`) contra `contrato-saida.md:77`; o contrato não é incluído em prompt nenhum. Reforça A2.	Média	decidir e alinhar
D-13	**Três convenções de ID para a mesma tela**: `E2-ALU-01`, `E2A`, `E2` (22:41; 23:31); o QA manda cruzar (30:83).	Média	ID único `E2_ALU_01`
D-14	**Template do fluxo usa `stateDiagram-v2`** (23:92-101) **contra a própria recomendação** (23:27).	Média	trocar o template

ID	Achado e evidência	Grav.	Correção
D-15	**Chaves de mini-jogo** (24:45) **violam o** `pronto.md:49` que fecha em zero.	Média	admitir o namespace
D-16	**D7 e O2 cobram três registros de voz em mini-jogo**, onde são dois (30:123; `rubrica-oficio.md:48`; 24:70).	Média	exceção
D-17	**`pronto.md` sem seção para copy-revisão e protótipo**, que o incluem (27:53; 28:141); `pronto.md:44` cita `rubrica-atual.md`, inexistente.	Média	criar seções; corrigir a referência
D-18	**O estado degradado (2–4 por aparelho) é o primeiro corte** em telas (26:58) e protótipo (28:126); o QA exige os três cenários (30:115).	Alta	degradado da pico e da decisão entre os intocáveis
D-19	**Sem CAA não há piso de alvo de toque nem verificação** (26:130; D8b só com CAA; `defaults:73` só chega ao D0).	Alta	incluir defaults no 26; linha no pronto
D-20	**"Anos iniciais" é 1º–2º na copy** (24:60) **e 1º–5º nos defaults** (:72,98); o 3º–5º fica sem áudio obrigatório.	Alta	unificar; estender a redundância às decisões do 3º–5º
D-21	**Nenhum requisito de contraste, teclado ou leitor de tela** em design (uma ocorrência, 28:64); DES-11 não entra em prompt de design.	Média	três itens contáveis no 26 e em D4
D-22	**A régua DES-01…14 não entra em nenhum prompt de design** (único include em 40:7); o design cita códigos que nunca viu.	Alta	incluir em 26 e 30
D-23	**"A tela projetada expõe algo indevido?" é opinião com teto amarelo** (30:121), e `atencao` não é despachada. É a única pergunta de privacidade da etapa.	Alta	item falsificável campo a campo; dado identificável reprova
D-24	**A raia "Evidência capturada"** (22:53) **não chega ao inventário** (22:69), **ao fluxo** (23:104) **nem às telas**; D3 só confere o negativo.	Alta	coluna Evidência no inventário; dimensão no QA
D-25	**D6 emite bloqueio contra `telas` por tela ausente do Stitch** (30:117); o Stitch é `off` sem chave (`config.py:31`) e a folha nunca existe.	Alta	condicionar à disponibilidade
D-26	**D6c definida** (30:119) **e ausente do veredito obrigatório** (30:182).	Média	inserir
D-27	**Gate de design falha para o aprovado**: `treat_indefinido_as_blocked=False` (`agents/design:365`); resposta truncada vira aprovado.	Alta	True, ou checagem prévia de envelope
D-28	**QA carrega 39 KB de BNCC** (30:109) para checagem já feita pelo A14.	Média	remover o include; passar `bncc_report`
D-29	**Fallback da extração injeta o protótipo inteiro no prompt do QA** (`artefatos_html.py:36`).	Média	truncar
D-30	**Miro como prova** (30:117) **e "não é achado" quando ausente**; diagrama `jornada-professor` mapeado sem prompt que o produza.	Média	conferir no documento de fluxo
D-31	**Fluxo carrega layout em px e "screenshot"** de ferramenta que não existe (23:46-47,112); jornada tem "Estrutura do board" sem board.	Média	apagar resíduos
D-32	**D0 promete Google Docs sem toolset** (17:114; `config.py:201`).	Média	condicionar

ID	Achado e evidência	Grav.	Correção
D-33	**D9 "condicional" roda sempre** (`agents/design:398`) com o design system inteiro no prompt.	Baixa	checker do bloco 0
D-34	**D0 e D9 negociam com um Gate 0 que não roda** (`17:86,155,160`; `19:194,255`) e reportam a resposta dele; o QA confia (`30:93`).	Alta	RS-n sempre pendente; remover os campos
D-35	**"Priorize para fora"** (`26:58`; `28:126`) **contradiz o pronto que exige zero** (`pronto.md:81-82`).	Média	ajustar os itens do pronto
D-36	**D5 gera N telas vezes M estados no Stitch e a especificação completa num só turno**, com sete insumos.	Média	separar telas-spec e telas-stitch
D-37	**ARASAAC (CC BY-NC-SA) como padrão** (`25:83`); `decisao_humana` não retém nada.	Média	inverter o default

11 Frente Dev, código e governança — 35 achados

ID	Achado e evidência	Grav.	Correção
V-01	**Banca vazia ou ilegível vira aprovado**: `treat_indefinido_as_blocked=False` (`agents/dev:308`); `limpar_degradacao` apaga reprovações anteriores; o PRD sai verde sem dimensão avaliada.	Alta	vazio ou sem envelope é bloqueado
V-02	**A consolidação "determinística" (44) é um LLM** (`agents/dev:110`); ninguém recalcula veredito nem contagem.	Alta	`BancaCheckAgent` que varre os cinco relatórios
V-03	**O gate do PRD concatena dois relatórios e só o último envelope sobrevive** (`checkers.py:531-549`; `callbacks.py:53`); achados de lacuna não chegam ao diagnóstico.	Alta	envelope combinado em código
V-04	**`agentes_degradados` nunca é limpo** (`checkers.py:85-102`); o dossiê chama de provisório o que já passou (visto em exp06ef1b).	Alta	limpar por gate
V-05	**Donos `wireframes`, `copy` e `spec` do prompt 44** (`44:66`) **não existem no roteador** (`agents/dev:149,170`); ticket descartado em silêncio, confirmado na execução real.	Alta	aplicar `_DONOS_ROTEAVEIS`
V-06	**Retrabalho da banca sem posfixo** (`agents/dev:312`): protótipo, links e diagramas ficam da versão anterior.	Alta	passar o posfixo
V-07	**Orçamento de retrabalho esgotado bloqueia sem motivo nem volta** (`checkers.py:696-708`).	Alta	`registrar_degradacao`
V-08	**Envelopes sem leitor**: o 49 se declara bloqueante (`49:254`) sem checker; 34 e 35 sem `status_key`.	Alta	`EnvelopeGate` ao fim do dev
V-09	**A banca julga imersão e acessibilidade sem receber** CAA, ambiente, protótipo, Stitch e QA (`_banca_preambulo.md:15-45`), com "ausência é NOK" (`:7`).	Alta	acrescentar os insumos
V-10	**Nada verifica que as cinco dimensões existem antes do 44** (`agents/dev:291-298`).	Alta	checker de presença

ID	Achado e evidência	Grav.	Correção
V-11	**Frontmatter do PRD não conferido**: `needs_clarification: 2` com zero marcadores no corpo, na execução real.	Alta	parsear o frontmatter em `validar_prd`
V-12	**PED-02 (matriz) e PED-06 (graus) só por LLM**: `scored` e `indicative` têm zero ocorrências no código.	Alta	`validar_matriz`
V-13	**Missão transversal nunca passa no contrato de telemetria** (`rastro.py:698` exige `expNNefNb_`).	Média	aceitar o padrão transversal
V-14	**Regex do campo `dados` casa "Modelo de dados:"** (`rastro.py:696`) e bloqueia.	Média	restringir ao payload
V-15	**"Toda medida tem tabela leitora" conferido como "existe uma tabela"** (`rastro.py:698`).	Média	por linha de evento
V-16	**Identificador inválido bloqueante com regex largo** (`rastro.py:844`).	Média	ancorar ou rebaixar
V-17	**Estrutura do PRD não conferida**: 25 seções, EARS, matriz 21, assets (`rastro.py:767-860`).	Média	regras estruturais
V-18	**Duas versões da plataforma**: `versao-lida.json` (29afc8f) e `criterios-dev.md:9` (ba0de35); sem alerta de envelhecimento em produção.	Alta	ler no start; idade no preâmbulo; falhar o CI
V-19	**Listas fechadas da plataforma hard-coded** (`rastro.py:27-83`), não derivadas das cópias.	Média	derivar ou testar
V-20	**72 ou 73 critérios**: `criterios-dev.md:9` diz 72; a contagem real é 16+14+15+15+13.	Baixa	corrigir; teste de contagem
V-21	**O gabarito do PRD manda imitar `unootube`** (`prd-padrao-ouro.md:124`) **e o proíbe** (`:93`; `47:145`).	Média	apagar a menção
V-22	**Sem temperatura, seed, modelo ou hash de prompt registrados** (`base.py:79`; zero ocorrências). Duas execuções não são comparáveis.	Alta	bloco `execucao` em `estado.json`
V-23	**Tokens nunca contados** (`runner.py:238-306` ignora `usage_metadata`).	Média	somar por agente
V-24	**A banca paralela carrega cerca de 1,2 MB de contexto quase idêntico** (39, 41, 42, 43: 275 a 323 KB; 47: 380 KB).	Média	fatiar a referência de software por papel
V-25	**Sem timeout nem retry na chamada de modelo**; exceção aborta tudo (`runner.py:238,393`).	Alta	retry e checkpoint por etapa
V-26	**O lint de contrato de produto está fora de `STATUS_KEYS` e `GATES`** (`runner.py:34`; `diagnostico.py:22`).	Média	acrescentar
V-27	**`python test_pipeline.py` quebra** (`NameError`, `:1747`) e 18 testes ficam fora do bloco principal.	Média	remover o bloco
V-28	**Sem missão-gabarito nem regressão sobre saída real**; as execuções em `output/` não são usadas por teste.	Alta	fixtures e `esperado.json`
V-29	**`teste_empirico_po_vs_original.py` sem assert e fora do CI.**	Baixa	converter
V-30	**Sem memória entre execuções**: nada agrega `aprendizado.md`; nenhuma métrica ao longo do tempo.	Alta	`_historico.jsonl`
V-31	**Trilha de versão da rubrica inconsistente** (v1.13 a v1.18 por arquivo).	Média	arquivo único de versão
V-32	**Cloud Run com `--allow-unauthenticated`** (`deploy.yml:83`): artefatos, briefings e editor de prompts expostos.	Alta	IAP ou IAM; editor atrás de flag

ID	Achado e evidência	Grav.	Correção
V-33	**`.dockerignore` não exclui `.env`, `.env.yaml`, `.miro_mcp_tokens.json`**; `COPY . .`	Alta	acrescentar
V-34	**Gabarito do PRD pede nomes de pessoas** (`prd-padrao-ouro.md:34`; `49:211`); sem retenção declarada dos artefatos.	Média	papéis; política de retenção
V-35	**Falhas de gravação engolidas** (`artifacts.py:196` em debug; `:336` retorna sempre a pasta).	Média	warning e retorno None

12 Onze pacotes de correção

Cento e dezoito achados não se aplicam um a um. Agrupados por causa comum, viram onze pacotes. Cada pacote diz o que cobre, o que muda, quem decide e como se mede.

Pacote A — Segurança e dados dos próprios artefatos — **decisão: infra**

Cobre: V-32, V-33, V-34, D-23. **O que muda:** `--no-allow-unauthenticated` com IAP ou IAM no deploy; editor de prompts atrás de variável desligada em produção; `.env*` e tokens do Miro no `.dockerignore`; `owners` por papel no gabarito do PRD; política de retenção do bucket declarada; item falsificável de exposição na tela projetada. **Esforço:** um dia. **Indicador:** `docker build` local não contém segredo; URL do app exige login. **Por que primeiro:** é o único pacote em que o risco é externo à qualidade da missão. Um briefing de rede parceira e pareceres com dados de escola estão hoje num endereço aberto.

Pacote B — Gates que mentem para o lado do aprovado — **decisão: nenhuma**

Cobre: P-01, D-27, V-01, V-08, V-10, D-07, D-08, V-03, V-04, V-07, V-26. **O que muda:** relatório vazio ou sem envelope é bloqueado em todo `EnvelopeGateAgent`; `adequacao_status` passa a existir; o one-pager pedagógico e o handoff ganham gate; presença das cinco dimensões antes da consolidação; envelope combinado do PRD montado em código; `agentes_degradados` limpo por gate; orçamento esgotado registrado como degradação; o lint de produto entra no painel. **Esforço:** dois a três dias de Python, com teste para cada caso (o padrão já existe em `test_pipeline.py`). **Indicador:** nenhum status `aprovado` no estado sem envelope parseável correspondente; teste que trunca a resposta de cada gate e exige `bloqueado`.

Pacote C — Roteamento de tickets — **decisão: nenhuma**

Cobre: V-05, V-06, D-09, D-10, D-11, D-12, D-25. **O que muda:** `_DONOS_ROTEAVEIS` aplicado no despacho e dono não roteável registrado; posfixo no retrabalho da banca; ordem de retrabalho com copy-revisão por último; telas consomem a copy revisada; dono `prototipo-navegavel`; decisão explícita sobre `atencao` e `oficio` (recomendação: despachar `oficio` para `jornada`, como o contrato já diz, e registrar `atencao` para humano); D6 condicionado à disponibilidade do Stitch. **Esforço:** um a dois dias. **Indicador:** zero tickets com dono fora do mapa em cinco execuções; nenhum ticket de `oficio` descartado.

Pacote D — Vocabulário e versões com fonte única — **decisão: nenhuma**

Cobre: P-04 a P-08, P-18 a P-24, P-26, D-13 a D-17, D-26, D-31, D-34, V-20, V-21, V-31, E-05. **O que muda:** um `references/_versao-rubrica.md` incluído por todos; contrato de saída com o enum real e namespace de IDs por agente; ID de nó único entre jornada e fluxo; template do fluxo em `flowchart`; seções faltantes do `pronto.md`; resíduos de FigJam

e de Gate 0 apagados; contagens corrigidas (14 e 73); `formato-spec`, `modelo-de-insumo` e `celulas-consumidas` alinhados ao recorte da aula; o script de conferência de referências de E-05 estendido a versões e contagens. **Esforço:** um dia de texto e um script de 80 linhas. **Indicador:** o script devolve zero divergências; teste que proíbe número de versão fora do arquivo único.

Pacote E — Escola pública e idade no design **decisão: produto e pedagogia**

Cobre: D-18, D-19, D-20, D-21, P-10, P-29, N2, e as emendas E-12, E-15, E-16, E-18 da proposta. **O que muda:** estado degradado das telas de pico e decisão entre os intocáveis; piso de alvo de toque independente de CAA, com linha contável; "anos iniciais" com um só significado e redundância texto-ícone-áudio nas decisões do 3º–5º; contraste, foco e "nada só por cor" como itens contáveis; seção de acessibilidade no one-pager com critério na categoria 6; cenário (d) de conectividade intermitente e sem dispositivo do estudante com o teste "a descoberta chega?"; contagem de preparo docente. **Esforço:** dois dias de texto; decisão pedagógica sobre o 3º–5º. **Indicador:** toda missão gerada tem, no inventário, o estado degradado da tela de pico e o cenário (d) preenchido; E-19 mede em campo.

Pacote F — Imersão verificável **decisão: produto**

Cobre: D-01, D-02, D-03, D-04, D-05, D-06, D-22, P-09, P-30, e as emendas E-02, E-10, E-11, E-14 da proposta. **O que muda:** `affordances-por-ambiente.md` (o que cada app real tem, onde, com que gesto e microinteração), incluído no D9 e no D5, ao lado da tabela de ausências preenchida; lint determinístico do HTML do protótipo (placeholders, CDN externo, IDs de tela presentes); O3 como teste sobre duas telas do Stitch ou movido à revisão humana; coluna Tensão e minuto acumulado no inventário; áudio nativo na ficha do ambiente; a régua DES-01…14 incluída no D5 e no QA; critério de gap e spoiler no gate estrutural; guia, voz e minutos até a primeira ação no one-pager. **Esforço:** três dias, sendo um de conferência do design system real. **Indicador:** O3 deixa de ser inaplicável; tickets "reapareceu por realismo" caem; o protótipo passa no lint em toda execução.

Pacote G — Mensurabilidade pedagógica de ponta a ponta **decisão: pedagogia**

Cobre: P-02, P-03, P-14, P-15, D-24, V-12, V-11, V-17, N3, e a emenda E-13 da proposta. **O que muda:** o parecer de adequação entra no gate final e na spec; a matriz habilidade, ação observável, marcador e dado nasce na seção 12 do one-pager e no bloco 11 da spec, e o 16b só copia; novo critério 7.5 ("artefato observável por objetivo, com o que não conta"); coluna Evidência no inventário de telas e dimensão no QA cruzando bloco 9 e telas; `validar_matriz` determinístico (toda habilidade com linha completa; toda medida com grau); frontmatter e estrutura do PRD conferidos; piso de desafio 6.6. **Esforço:** três dias; decisão pedagógica sobre os marcadores ternários. **Indicador:** o mesmo dado pode ser seguido do código BNCC até a coluna da tabela, por máquina, em toda missão gerada.

Pacote H — Confiabilidade, custo e reprodutibilidade **decisão: nenhuma**

Cobre: V-22, V-23, V-25, V-27, V-28, V-29, V-35, V-02. **O que muda:** temperatura e seed fixados; bloco `execucao` (modelo, orçamento de raciocínio, hash de cada prompt, commit) em `estado.json`; tokens somados por agente; retry exponencial por agente e checkpoint por etapa; consolidação da banca recalculada por código; fixtures de missão-gabarito a partir das execuções boas em `output/` com `esperado.json`; bloco principal do teste removido; falhas de gravação visíveis. **Esforço:** três a quatro dias. **Indicador:** duas execuções do mesmo briefing

produzem diagnóstico comparável; custo por missão e por agente aparece no dossiê.

Pacote I — Sincronia com a plataforma **decisão: nenhuma**

Cobre: V-18, V-19, V-13, V-14, V-15, V-16, N1, E-20. **O que muda:** `versao-lida.json` lido no start, idade injetada no preâmbulo da banca, CI falha acima de N dias; listas fechadas derivadas das cópias ou testadas contra elas; regexes de telemetria e PRD ajustados (transversal, campo `dados`, tabela por evento, identificador); DES-14 com severidade declarada e origem registrada; decisão sobre DES-03 reaberta. **Esforço:** dois dias. **Indicador:** zero falsos positivos nos gates determinísticos sobre as fixtures; alerta de deriva visível na UI.

Pacote J — Aprendizado e memória **decisão: produto**

Cobre: P-25, P-26, P-27, V-30, A7, A8, e as emendas E-03, E-07, E-08, E-09, E-17, E-19. **O que muda:** `output/_historico.jsonl` escrito a cada execução (diagnóstico, contagens da banca, rodadas, duração, tokens); `references/pendencias-de-emenda.md` versionado, alimentado pelas propostas do agente 51, com passo humano de aceite no README; catálogo atualizado e no formato que o 51 propõe; C1, C3 e C7 aplicados; aprendizado recebendo todos os relatórios; protocolo de campo. **Esforço:** dois dias mais o ritual humano. **Indicador:** `git log` das três referências vivas deixa de ter um único commit; métrica de rodadas por gate ao longo das execuções.

Pacote K — Contexto e engenharia de prompt **decisão: nenhuma**

Cobre: V-24, D-28, D-29, D-33, D-36, D-35, D-32, P-13, P-16, P-17, P-28, P-12, e E-04. **O que muda:** referência de software fatiada por papel da banca; BNCC fora do QA de design; fallback do protótipo truncado; D9 acionado por checker do bloco 0; D5 separado em spec e Stitch; Google Docs condicionado ao toolset; brief de escopo com chave própria; réguas de tempo subordinadas ao 6.2; bloco morto do 09 removido; etapa `produto` na reexecução; resumo da régua cognitiva no design. **Esforço:** dois dias. **Indicador:** tamanho do prompt expandido de cada agente da banca cai abaixo de 100 KB; nenhuma execução aborta por contexto.

13 Plano consolidado para o padrão ouro

13.1 Sequência

A ordem segue dois critérios: primeiro o que expõe dados ou faz o sistema mentir, depois o que melhora a missão. Tudo o que não exige decisão pedagógica vem antes do que exige.

1. **Semana 1 — parar de mentir e de vazar.** Pacote A (segurança) e Pacote B (gates que falham para o aprovado). Sem isso, qualquer melhoria de critério pode ser aprovada por um gate que não leu nada.
2. **Semana 2 — rubrica v1.19 e roteamento.** Pacotes C e D, mais as Ondas 1 e 2 da proposta (E-01 a E-09). É uma única emenda de texto com um script, e destrava o resto.
3. **Semanas 3 e 4 — imersão, escola pública e mensurabilidade.** Pacotes E, F e G, com as decisões de produto e pedagogia da Onda 3 (E-10 a E-18). É aqui que a missão gerada muda de fato.
4. **Em paralelo, desde a semana 1 — confiabilidade, sincronia, memória e contexto.** Pacotes H, I, J e K, mais E-19. São trabalho de engenharia sem decisão de produto, e o Pacote J é o que permite medir se as semanas 3 e 4 funcionaram.

13.2 Esforço por pacote

Pacote	Tema	Achados	Dias	Decisão
A	Segurança e dados	4	1	infra
B	Gates que mentem	11	2–3	nenhuma
C	Roteamento de tickets	7	1–2	nenhuma
D	Vocabulário e versões	22 + E-05	1	nenhuma
E	Escola pública e idade	7 + 4 emendas	2	produto e pedagogia
F	Imersão verificável	9 + 4 emendas	3	produto
G	Mensurabilidade	9 + E-13	3	pedagogia
H	Confiabilidade e custo	8	3–4	nenhuma
I	Sincronia com a plataforma	8 + E-20	2	nenhuma
J	Aprendizado e memória	6 + 6 emendas	2 + ritual	produto
K	Contexto e prompts	13 + E-04	2	nenhuma
Total		**118**	**22–25**	

Cerca de cinco semanas de uma pessoa, ou duas semanas e meia de duas, com as decisões de produto e pedagogia tomadas em paralelo. Fora E-19 (campo), nada depende de terceiros.

13.3 O que continua deliberadamente fora

- **O framework de seis etapas por idade (A10).** Continua pergunta de campo, e E-19 é o único caminho honesto.
- **A arquitetura de agentes.** Nenhum dos 118 achados pede trocar a esteira; todos pedem que ela faça o que já diz fazer. A separação em três etapas com gates determinísticos está certa; o que falta é fechar as alças abertas.
- **Os tetos numéricos da rubrica de ofício.** Continuam v0.1 até haver dado de campo.

14 Mensurabilidade: o que se pode medir depois dos pacotes

A tabela da reavaliação (Parte I) marcava cinco indicadores instrumentados e seis abertos. Depois dos pacotes, o quadro fica:

O que medir	Indicador	Pacote	Hoje
Gate aprovou sem ler	status aprovado sem envelope parseável	B	possível
Ticket perdido	dono fora do mapa por execução	C	acontece
Deriva de vocabulário	divergências do script de conferência	D	4 conhecidas
Escola pública no wireframe	estado degradado da pico presente	E	primeiro corte
Fidelidade do clone	lint do protótipo; tickets “reapareceu”	F	inaplicável
Rastreabilidade BNCC até o dado	`validar_matriz` por missão	G	só LLM
Reprodutibilidade	bloco `execucao` por artefato	H	inexistente
Custo por missão e por agente	tokens no dossiê	H	inexistente
Envelhecimento da plataforma	idade da cópia na UI e no CI	I	inexistente
Melhoria ao longo do tempo	série do `_historico.jsonl`	J	inexistente
Contexto por agente	KB do prompt expandido	K	até 380 KB

15 Anexo

15.1 Commits entre 20 e 22 de setembro

Commit	Data	Assunto
`ce4dc95`	20/09	relatórios LaTeX de análise de imersão e padrão ouro
`fa39727`	21/09	contrato de produto, one-pager resumido, relatório comparativo, critérios
`702d972`	21/09	fluxo do professor e telas obrigatórias do professor na esteira de design
`c305712`	21/09	validadores sem falso-positivo; formato de slug no núcleo narrativo
`fc44d1d`	21/09	reexecução de etapas a partir de estado salvo
`4afe2b7`	21/09	assinatura de cache da barra lateral
`a44897a`	22/09	modo de correção na mesma sessão
`d68ac1f`	22/09	regras de linguagem simples no one-pager resumido
`f5b379c`	22/09	PRD deixa de acusar caminho divergente em experiência existente

15.2 O que foi reconferido por busca direta neste relatório

Além da Parte I, os seguintes achados da Parte II foram verificados diretamente, não só pelo auditor da frente: P-01 (`adequacao_status` aparece uma única vez no código, como leitura); P-09 (zero ocorrências de spoiler ou gap nos quatro arquivos de critério); P-11 (`tools/bncc.py` emite atenção no EM); P-25 (um único commit nas três referências vivas); D-25 (`config.py:31`, modo `off` sem chave); D-27 e V-01 (`treat_indefinido_as_blocked=False` nas linhas 365 e 308); V-05 (`MAPA_BANCA` e `BANCA_EXTERNO` sem `wireframes`, `copy` e `spec`; `44:66` os autoriza); V-20 (16+14+15+15+13 cabeçalhos); V-22 (zero ocorrências de temperatura ou seed); V-27 (`NameError` na linha 1747); V-32 (`--allow-unauthenticated` na linha 83 do deploy); V-33 (`.dockerignore` sem `.env`; os três arquivos de segredo existem na raiz).

15.3 Changelog v1.19 revisto

Ao changelog da proposta e da Parte I acrescentam-se as linhas dos pacotes B, C e D, que são as que tocam a rubrica: versão única de rubrica; enum real de status no contrato de saída; namespace de IDs por agente; ID único de tela entre jornada e fluxo; contagens 14 e 73; 4.5 nas seis etapas; 7.4 desejável; 7.5 novo (artefato observável); cenário (d) de conectividade; seção de acessibilidade no one-pager; `[RS-n]` sempre pendente; despacho de `oficio` para `jornada`.

Referências

[1] BROWN, E.; CAIRNS, P. *A grounded investigation of game immersion.* In: CHI '04 Extended Abstracts on Human Factors in Computing Systems. ACM, 2004, p. 1297–1300. DOI 10.1145/985921.986048.

[2] CHENG, M.-T.; SHE, H.-C.; ANNETTA, L. A. *Game immersion experience: its hierarchical structure and impact on game-based science learning.* Journal of Computer Assisted Learning, v. 31, n. 3, p. 232–253, 2015. DOI 10.1111/jcal.12066.

[3] HAMARI, J.; SHERNOFF, D. J.; ROWE, E.; COLLER, B.; ASBELL-CLARKE, J.; EDWARDS, T. *Challenging games help students learn: an empirical study on engagement, flow and immersion in game-based learning.* Computers in Human Behavior, v. 54, p. 170–179, 2016. DOI 10.1016/j.chb.2015.07.045.

[4] HUANG, G.; JIA, W.; YU, W. *Media literacy interventions improve resilience to misinformation: a meta-analytic investigation of overall effect and moderating factors.* Communication Research, 2024. DOI 10.1177/00936502241288103.

[5] MISLEVY, R. J.; ALMOND, R. G.; LUKAS, J. F. *A brief introduction to evidence-centered design*. ETS Research Report Series, RR-03-16. Princeton: Educational Testing Service, 2003. DOI 10.1002/j.2333-8504.2003.tb01908.x.

[6] INEP — INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. *Relatório Brasil no PISA 2022*. Brasília: Inep/MEC, 2023.

[7] INEP — INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. *Sistema de Avaliação da Educação Básica — Saeb 2025: resultados*. Brasília: Inep/MEC, 2026.

[8] SINHA, T.; KAPUR, M. *When problem solving followed by instruction works: evidence for productive failure*. Review of Educational Research, v. 91, n. 5, p. 761–798, 2021. DOI 10.3102/00346543211019105.

[9] SUNDARARAJAN, N.; ADESOPE, O. *Keep it coherent: a meta-analysis of the seductive details effect*. Educational Psychology Review, v. 32, p. 707–734, 2020. DOI 10.1007/s10648-020-09522-4.

[10] CETIC.BR — CENTRO REGIONAL DE ESTUDOS PARA O DESENVOLVIMENTO DA SOCIEDADE DA INFORMAÇÃO. *TIC Educação 2024: pesquisa sobre o uso das tecnologias de informação e comunicação nas escolas brasileiras*. São Paulo: NIC.br, 2025.

[11] CETIC.BR — CENTRO REGIONAL DE ESTUDOS PARA O DESENVOLVIMENTO DA SOCIEDADE DA INFORMAÇÃO. *TIC Kids Online Brasil 2024: pesquisa sobre o uso da Internet por crianças e adolescentes no Brasil*. São Paulo: NIC.br, 2024.

Reavaliação conduzida sobre o estado do repositório em 22 de setembro de 2026 (`f5b379c`). Parte I responde à Auditoria de Imersão v1.0 e à Proposta de Emendas v1.0; Parte II é auditoria nova, em três frentes. Nenhum artefato da esteira foi alterado na produção deste documento.