UNOORIA EDUCAÇÃO E TECNOLOGIA

DIRETORIA DE ENGENHARIA DE SOFTWARE E INTELIGÊNCIA ARTIFICIAL

Núcleo de Arquitetura de Plataforma, Compiladores e Orquestração Multiagente

---

RELATÓRIO TÉCNICO-ACADÊMICO DE AUDITORIA COMPARATIVA DE PROMPTS

Avaliação Qualitativa, Empírica e Arquitetural das Revisões de Produto (PO) vs. Baseline Canônica na Esteira de Anos Finais

---

Autor: Comitê de Auditoria de Software e IA (Consolidação de 30 Subagentes de Pesquisa)

Objeto Auditado: Diretório `esteira-anosfinais-formato-produto/` (Downloads) vs. `prompts/produto/` e `prompts/references/`

Stack Tecnológica: Google Agent Development Kit (ADK), LangGraph, PostgreSQL (RLS), Fastify / NestJS, Next.js

Classificação: Documento de Engenharia / Decisão Arquitetural (ADR) / Rigor Acadêmico

São Paulo – Brasil

Setembro de 2026

Sumário

1 Sumário Executivo e Veredito Categórico **2**
1.1 Veredito Categórico da Auditoria . . . 2
1.2 As Três Quebras Catastróficas Identificadas em Runtime . . . 2

2 Matriz Comparativa de Avaliação em 8 Dimensões **2**

3 Análise Ponto a Ponto das 13 Modificações Mapeadas **3**
3.1 M1: Veredito Ternário em P1 e P4 (LIBERADA COM RESSALVAS) . . . 3
3.2 M2: Modificação do Schema do Envelope JSON (`aprovado_com_ressalvas`) . . . 4
3.3 M3: Regra de Parada (*Stopping Rule*) e Human-in-the-Loop em P1/P1b . . . 4
3.4 M4: Desduplicação de Critérios (P3 vs P1) . . . 4
3.5 M5: Operacionalização do Critério 1.6 (Mecânica e Descoberta) . . . 4
3.6 M6: Teste de Piso em Escolas Públicas no Critério 6.3 . . . 5
3.7 M7: Supressão das Fundamentações Cognitivas nos Critérios 6.1, 6.4 e 6.5 . . . 5
3.8 M8: Padronização Terminológica ("Aluno"para "Estudante") . . . 5
3.9 M9: Elevação do Material *Entre Redes* a Fonte Primária . . . 5
3.10 M10: Criação do Prompt P5b (One-Pager Pedagógico Paralelo) . . . 5
3.11 M11: Amputação Estrutural de ‘formato-spec.md‘ . . . 5
3.12 M12: Reversão Temporal e Desatualização de ‘ambientes.md‘ . . . 6
3.13 M13: Supressão de Metadados e Frontmatter YAML . . . 6

4 Evidências Experimentais e Simulação em Runtime **6**
4.1 Experimento 1: Simulação do Envelope Gate (`agents/callbacks.py`) . . . 6
4.2 Experimento 2: Validação da Ficha do Manifesto (`tools/rastro.py`) . . . 7
4.3 Experimento 3: Validação do Carregador de Prompts (`prompts/loader.py`) . . . 7
4.4 Experimento 4: Medições Quantitativas de Contexto e Tokens . . . 7

5 Fundamentação Teórica, Acadêmica e Regulatória **8**
5.1 Teoria da Carga Cognitiva e Design Instrucional . . . 8
5.2 Engenharia de Prompts, Raciocínio em LLMs e Diluição de Atenção . . . 8
5.3 Engenharia de Software: SSOT, Modularidade e Contratos . . . 8
5.4 Conformidade Regulatória: LGPD Art. 14 e Resoluções do CNE . . . 9

6 Plano de Ação de Engenharia e Patches Recomendados **9**
6.1 Frente 1: Patches de Infraestrutura no Código Python . . . 9
6.2 Frente 2: Patches de Conciliação nos Prompts de Produto . . . 9
6.3 Frente 3: Blindagem e Restauração das Referências Técnicas . . . 10

7 Conclusão **10**

1 Sumário Executivo e Veredito Categórico

1.1 Veredito Categórico da Auditoria

CRÍTICO / VIOLAÇÃO GRAVE: REJEIÇÃO TÉCNICA PARCIAL COM ADOÇÃO DE MELHORIAS PEDAGÓGICAS (CHERRY-PICKING)

A substituição integral e desregulada dos prompts e referências canônicas da plataforma pelos arquivos revisados pelo *Product Owner* (PO) em `esteira-anosfinais-formato-produto/` é **CATEGORICAMENTE INVIÁVEL E DEVE SER VETADA**.
A avaliação qualitativa e empírica multidisciplinar calculou uma regressão no escore geral de conformidade sistêmica de **7,94/10** (Baseline Canônica) para **5,62/10** (Versão PO), representando uma queda líquida de **-2,32 pontos**.
Embora as alterações contenham avanços pedagógicos legítimos e bem-vindos (especialmente na operacionalização de critérios de avaliação, testes de piso em escolas públicas e foco nas dificuldades reais dos estudantes), as modificações introduziram **três quebras catastróficas em runtime**, desrespeitaram contratos legais de privacidade de menores (LGPD Art. 14) e amputaram contratos de engenharia que paralisam a esteira de desenvolvimento a jusante (*Design* e *Dev*).

1.2 As Três Quebras Catastróficas Identificadas em Runtime

[1] **Colapso Determinístico de Status por Incompatibilidade de Schema (Runtime Crash):**
O PO alterou a saída do gate P4 para emitir `"status": "aprovado_com_ressalvas"`. O orquestrador determinístico (`agents/callbacks.py:inferir_status`) **não reconhece** esse literal. O sistema sofre queda silenciosa para o analisador heurístico de texto, que também falha diante de `"[AMARELO] LIBERADA COM RESSALVAS"`. O resultado converge para `STATUS_INDEFINIDO`. Como a esteira opera em modo de segurança estrito (`treat_indefinido_as_blocked=`) o componente `EnvelopeGateAgent` coage o veredito para `STATUS_BLOQUEADO`, acionando o bloqueio global da esteira (`pipeline_bloqueado = True`). As etapas subsequentes de Design (D0 a D8) e Dev (V0 a V5) são **imediatamente abortadas sem gerar código ou telas**.

[2] **Amputação da Ficha do Manifesto e Paralisia de Dev (`tools/rastro.py`):**
O PO removeu 73 linhas do arquivo central `formato-spec.md`, expurgando a Ficha do Manifesto em chave-valor do Bloco 0. Ao receber a especificação gerada por P5 nesse formato desidratado, o validador determinístico `ManifestoCheck` (`tools/rastro.py:validar_manifesto`) falha instantaneamente com **10 bloqueios simultâneos** (ausência de `id`, `produto`, `series`, `unidade`, `publico`, `viewport`, `permissoes`, `capabilities`, `secao_ds` e `liberacao`). O PRD de desenvolvimento jamais é redigido.

[3] **Cegueira de Telemetria e Violação Estrutural da LGPD (Artigo 14):**
A versão do PO removeu as salvaguardas de isolamento *multi-tenant* (`ENABLE + FORCE ROW LEVEL SECURITY`), a governança de mídia de menores (destino, retenção temporal, autorização familiar) e o contrato xAPI sem payload genérico `dados`. O validador `TelemetriaCheck` bloqueia o pipeline com **5 achados fatais**. A persistência sem RLS expõe a EdTech a vazamentos graves de dados infantis, violando frontalmente a legislação vigente.

2 Matriz Comparativa de Avaliação em 8 Dimensões

Para mensurar com precisão científica e objetividade o impacto das mudanças propostas pelo PO, estabelecemos uma rubrica de 8 dimensões de qualidade de software, IA generativa e design instru-

cional, cada uma com peso ponderado de acordo com a criticidade de produção.

Dimensão Avaliada	Peso	Antes	Depois	Δ	Síntese do Impacto Observado
D1. Determinismo e Executabilidade	20%	8.5	3.0	**-5.5**	Quebra de enums JSON, colapso de parsers e bloqueio falso no CI.
D2. Alinhamento Curricular e Rigor	15%	6.5	9.0	**+2.5**	Excelente ancoragem pedagógica, Entre Redes e rubricas ricas.
D3. Carga Cognitiva e Faixa Etária	10%	7.5	8.5	**+1.0**	Testes de piso na escola pública e linguagem do estudante.
D4. Contratos de Dados, LGPD e RLS	15%	9.5	2.0	**-7.5**	Desastre: expurgo de RLS, retenção de mídia e xAPI da API.
D5. Orquestração Multiagente e Loops	10%	7.0	7.5	**+0.5**	Stopping rule elegante, mas com bug off-by-one de rodadas.
D6. SSOT e Manutenibilidade	10%	9.0	3.0	**-6.0**	Bifurcação de spec (P5b), perda de YAML e drift de referências.
D7. Eficiência de Tokens e Contexto	10%	7.0	8.0	**+1.0**	Desduplicação de critérios 3.1-3.3 alivia atenção do LLM.
D8. Handoff para Design e Dev	10%	8.5	4.0	**-4.5**	Design e Dev recebem especificações cegas e sem viewport.
ÍNDICE GERAL PONDERADO	**100%**	**7.94**	**5.62**	**-2.32**	**Regressão Global Severa na Qualidade da Esteira**

Tabela 1: Matriz Multidimensional de Avaliação: Baseline Canônica vs. Versão PO.

3 Análise Ponto a Ponto das 13 Modificações Mapeadas

A auditoria decompôs todas as alterações realizadas pelo PO em 13 modificações atômicas independentes (**M1** a **M13**), avaliadas individualmente sob prismas teóricos, psicométricos e de código.

3.1 M1: Veredito Ternário em P1 e P4 (LIBERADA COM RESSALVAS)

Natureza da Modificação: O PO introduziu o terceiro estado `"[AMARELO] LIBERADA COM RESSALVAS"` no P4 e `"[AMARELO] APROVADO COM RESSALVAS"` no P1, quebrando a dicotomia rígida (• Aprovado / • Bloqueado).

Avaliação Conceitual: POSITIVA. De acordo com a teoria matemática de *Three-Way Decisions* de Yao [27], decisões binárias forçadas sob incerteza amplificam perdas bayesianas. Na psicometria clássica, escalas ternárias evitam a perda de informação por compressão e mitigam a fadiga de alertas em esteiras de software.
Avaliação em Código: QUEBRA CRÍTICA. Ao introduzir o veredito sem atualizar a tupla em `agents/callbacks.py`, a execução falha e gera bloqueio falso (*false negative*). Além disso, na literatura de avaliação com LLMs (*LLM-as-a-judge*) [19], escalas ternárias sem calibração rígida induzem ao *Leniency Bias* (viés de complacência), onde o modelo rebaixa falhas que deveriam ser vermelhas para o estado amarelo de conforto.

3.2 M2: Modificação do Schema do Envelope JSON (`aprovado_com_ressalvas`)

Natureza da Modificação: O PO alterou a propriedade de saída do envelope JSON de `"status": "aprovado "bloqueado"` para incluir `"status": "aprovado_com_ressalvas"`.
Avaliação Conceitual: NEGATIVA. Violação frontal do princípio de *Design by Contract* [13]. Modificar o contrato de saída do agente gerador sem migração coordenada no agente validador gera incompatibilidade sintática (*Specification Mismatch*), apontada por estudos recentes [6, 26] como causa primária de falhas em sistemas multiagente.
Evidência Empírica: O teste executado comprovou que `inferir_status()` retorna deterministicamente `"indefinido"`, forçando o bloqueio da esteira pelo `EnvelopeGateAgent`.

3.3 M3: Regra de Parada (*Stopping Rule*) e Human-in-the-Loop em P1/P1b

Natureza da Modificação: Inclusão de regra expressa determinando que, caso a missão persista bloqueada na rodada 4, o agente deve parar e sugerir escalonamento para o PO humano.
Avaliação Conceitual: POSITIVA. Alinha-se perfeitamente aos princípios de arquitetura multiagente reflexiva [11, 19], evitando loops infinitos e custos descontrolados de inferência.
Defeito de Implementação (*Off-by-One*): A instrução no prompt prescreve escalonamento na rodada 4 (*"Se rodada = 4..."*). Contudo, o código do orquestrador (`agents/produto/__init__.py`, linha 185) define formalmente:

```
gate_estrutural_max_rodadas: int = 3
```

Como o código aborta forçadamente na 3ł rodada, a instrução do PO para a rodada 4 constitui **código morto** (*dead instruction*) que jamais será executada em runtime.

3.4 M4: Desduplicação de Critérios (P3 vs P1)

Natureza da Modificação: Remoção dos critérios 3.1, 3.2 e 3.3 de `p3_experiencia_aluno.md`, que repetiam integralmente validações já executadas por P1 (Gate Estrutural).
Avaliação: ALTAMENTE POSITIVA. De acordo com os estudos seminais de Liu et al. (2024) [10] sobre diluição de contexto (*"Lost in the Middle"*), a eliminação de regras redundantes em cadeias de prompts desonera a janela de atenção do transformador, melhora a acurácia de aderência a instruções e reduz custos e latência em inferência.

3.5 M5: Operacionalização do Critério 1.6 (Mecânica e Descoberta)

Natureza da Modificação: Adição de um teste explícito de falsificabilidade (*"Se a mecânica for removida, a descoberta ainda acontece?"*) e mapeamento das 3 armadilhas pedagógicas comuns (leitura passiva, adivinhação aleatória e cosmética digital).
Avaliação: ALTAMENTE POSITIVA. Converte um critério avaliativo vago em uma rubrica objetiva e verificável, em estrita conformidade com a taxonomia revisada de Bloom [1] e os Primeiros Princípios de Instrução de Merrill [12].

3.6 M6: Teste de Piso em Escolas Públicas no Critério 6.3

Natureza da Modificação: Exigência de que o avaliador valide a experiência considerando o cenário real da escola pública brasileira (ruído alto, internet instável de 2 Mbps, turmas numerosas e letramento digital desigual).
Avaliação: ALTAMENTE POSITIVA. Aplicação direta da Teoria da Carga Cognitiva de Sweller [14,20,21]. Elimina hipóteses irreais de laboratórios de informática higienizados e ancora o design da missão na realidade concreta do estudante brasileiro.

3.7 M7: Supressão das Fundamentações Cognitivas nos Critérios 6.1, 6.4 e 6.5

Natureza da Modificação: O PO removeu as referências teóricas a estágios de desenvolvimento infantil (Piaget), exemplos de vocabulário acessível e parâmetros explícitos de limites de palavras por faixa etária.
Avaliação: NEGATIVA. A remoção de âncoras cognitivas concretas descalibra a precisão do LLM como juiz. O modelo perde referências empíricas para distinguir, por exemplo, a capacidade leitora de um estudante de 6ž ano versus um de 9ž ano, aumentando a dispersão das avaliações.

3.8 M8: Padronização Terminológica ("Aluno"para "Estudante")

Natureza da Modificação: Substituição de todas as ocorrências da palavra "aluno"pelo termo "estudante".
Avaliação: POSITIVA. Alinhamento com as diretrizes contemporâneas do Ministério da Educação (MEC) e da BNCC, promovendo postura de protagonismo discente sem qualquer impacto colateral na engenharia.

3.9 M9: Elevação do Material *Entre Redes* a Fonte Primária

Natureza da Modificação: Instrução em P2 e P5 ordenando que o material impresso *Entre Redes* seja considerado a fonte primária de verdade pedagógica, sobrepondo-se a diretrizes gerais.
Avaliação Conceitual: PARCIALMENTE POSITIVA (COM RISCO DE CONFLITO). Excelente para garantir aderência ao livro didático adotado pela rede escolar.
Avaliação de Engenharia: CONFLITO NORMATIVO E DE CÓDIGO. Conforme demonstrado pela auditoria documental, o material *Entre Redes* cobre apenas 29,8% das habilidades da BNCC Computação (Resolução CNE/CEB 1/2022 [4]). Se o P5 omitir os códigos oficiais de computação (`EFnnCOnn`) em favor de códigos disciplinares tradicionais (ex.: `EF02HI08`), o validador `BnccCheckAgent` (`tools/bncc.py`) bloqueia compulsoriamente a esteira com o erro `"sem-codigo"`.

3.10 M10: Criação do Prompt P5b (One-Pager Pedagógico Paralelo)

Natureza da Modificação: O PO introduziu um sexto prompt (`p5b_one_pager_pedagogico.md`) para sintetizar uma visão de produto voltada a educadores.
Avaliação: NEGATIVA. Violação direta do princípio fundamental de engenharia de software **Single Source of Truth (SSOT) / Don't Repeat Yourself (DRY)** [7, 17]. Conforme comprovado por Knight & Leveson [8], especificações paralelas geradas independentemente por LLMs entram em divergência semântica imediata (*spec drift*), confundindo os times de design e desenvolvimento. Ademais, o prompt P5b é um **arquivo órfão**: não foi plugado no arquivo de orquestração do pipeline (`agents/produto/__init__.py`), gerando overhead cognitivo inútil.

3.11 M11: Amputação Estrutural de 'formato-spec.md'

Natureza da Modificação: O PO reduziu o arquivo canônico em 48,6% (-73 linhas líquidas), extirpando:

1. A Ficha do Manifesto em YAML do Bloco 0;
2. As restrições de arquitetura de IA em `apps/api/src/ai` e quotas (ADR-105);
3. A proibição de WebSockets para sincronização de sala (ADR-93/94);
4. Todas as regras de dados de menores (LGPD Art. 14 [2]), RLS e o contrato xAPI sem chave `dados`;
5. Os Blocos 13 (Decisões D0) e 14 (Ambiente Simulado D9).

Avaliação: CATASTRÓFICA (-7.5 pontos em D4 e -4.5 em D8). Conforme demonstrado na Seção 4, essa remoção destrói todos os contratos consumidos por linters, bancos de dados e compiladores de código, paralisando deterministicamente os estágios de Design e Dev.

3.12 M12: Reversão Temporal e Desatualização de 'ambientes.md'

Natureza da Modificação: O arquivo `ambientes.md` entregue pelo PO reverteu melhorias técnicas consolidadas, removendo a referência ao tema escuro obrigatório (ADR-68), as pontes com a biblioteca de componentes `@edu/ui` e classificando erroneamente a plataforma WhatsApp como ambiente nativo de desktop.
Avaliação: NEGATIVA. Configura regressão temporal acidental (trabalho sobre fork desatualizado da esteira).

3.13 M13: Supressão de Metadados e Frontmatter YAML

Natureza da Modificação: Remoção dos cabeçalhos estruturados em YAML que continham metadados de versão, autor, data e histórico de revisão nos arquivos de prompt.
Avaliação: NEGATIVA. Degrada a rastreabilidade e governança de prompts em esteiras autônomas de produção.

4 Evidências Experimentais e Simulação em Runtime

Para afastar qualquer subjetividade analítica, a auditoria submeteu as propostas do PO a baterias de testes empíricos executados diretamente no ambiente de produção do monorepo.

4.1 Experimento 1: Simulação do Envelope Gate (`agents/callbacks.py`)

Executamos o script de simulação estrita `scripts/simular_status_gate.py` simulando a passagem do relatório emitido pelo novo prompt P4.

```
# Entrada:
envelope = {"status": "aprovado_com_ressalvas"}
cabecalho = "Gate Final de Produto - exp-01 v1\n**Veredito: [AMARELO] LIBERADA COM
    RESSALVAS**"

# Execucao:
status_retornado = inferir_status(cabecalho, envelope)
# Retorno exato: 'indefinido'

# Comportamento no EnvelopeGateAgent (treat_indefinido_as_blocked=True):
# status coagido = 'bloqueado'
# state['pipeline_bloqueado'] = True
# Resultado: DesignStage e DevStage PULADOS via skip_if_blocked.
```

Listing 1: Trecho extraído do teste de inferência de status no orquestrador

Constatação Empírica: O pipeline **trava 100% das execuções** em que o P4 emitir aprovação com ressalvas, impedindo a geração da missão.

4.2 Experimento 2: Validação da Ficha do Manifesto (`tools/rastro.py`)

Submetemos uma especificação estruturada estritamente de acordo com o modelo amputado de `formato-spec.md` do PO à ferramenta determinística `validar_manifesto()`.

Resultado do Validador: 10 ACHADOS DE BLOQUEIO FATAL.

a. `id`: ausente ou fora de `exp-NN-<slug>`;

b. `produto`: ausente (Sem ele o CI recusa o build do monorepo – ADR-87);

c. `series`: ausente ou fora do formato `["5EF"]`;

d. `unidade`: ausente ou fora de 1–4 (Sem unidade a grade do LMS não ordena – ADR-69);

e. `publico`: ausente (Incapaz de separar tela de aluno vs professor);

f. `viewport`: ausente (Design e Prototipador D8 não sabem se renderizam mobile ou desktop);

g. `permissoes`: ausente (Iframe bloqueia silenciosamente formulários `<form>`);

h. `capabilities`: ausente (SDK Unooria desativa telemetria e progresso);

i. `secao_ds`: ausente (Storybook não sabe qual Design System instanciar);

j. `liberacao: por-turma`: ausente (A missão não abre para os alunos em sala – ADR-69).

4.3 Experimento 3: Validação do Carregador de Prompts (`prompts/loader.py`)

O script de injeção dinâmica de prompts analisa macros recursivas `<!- include: references/... ->`. A pasta entregue pelo PO em `Downloads` contém apenas 4 referências, tendo descartado 18 referências vitais da plataforma. Ao apontar o carregador para a pasta do PO, o sistema dispara imediatamente:

```
FileNotFoundError: [Errno 2] No such file or directory:
'esteira-anosfinais-formato-produto/references/criterios-gate-final.md'
```

provando que o pacote do PO não é um módulo autocontido e não pode substituir o repositório.

4.4 Experimento 4: Medições Quantitativas de Contexto e Tokens

A Tabela 2 consolida as medições exatas em bytes e estimativas de tokens (caracteres / 4) realizadas em todos os arquivos de produto.

Arquivo / Componente	Bytes Original	Bytes PO	Δ Bytes	Δ Tokens	Variação %
`p1_gate_estrutural.md`	7.151	7.973	+822	+205,5	+11,5%
`p2_avaliacao_pedagogica.md`	6.208	7.112	+904	+226,0	+14,6%
`p3_experiencia_aluno.md`	5.166	5.253	+87	+21,75	+1,7%
`p4_gate_final.md`	5.760	6.840	+1.080	+270,0	+18,7%
`p5_spec_missao.md`	4.908	5.144	+236	+59,0	+4,8%
`p5b_one_pager.md` (NOVO)	0	5.174	+5.174	+1.293,5	Novo
`formato-spec.md` (Ref.)	10.560	5.427	**-5.133**	**-1.283,2**	**-48,6%**
`ambientes.md` (Ref.)	8.358	7.733	-625	-156,2	-7,5%

Tabela 2: Métricas Quantitativas de Bytes e Tokens (Baseline vs Versão PO).

Nota-se o fenômeno inverso: enquanto os prompts individuais aumentaram em prol da riqueza instrucional, o documento mestre de contrato técnico (`formato-spec.md`) perdeu quase metade do seu volume, sofrendo esvaziamento de conteúdo regulatório e de engenharia.

5 Fundamentação Teórica, Acadêmica e Regulatória

A análise técnica deste relatório é sustentada por literatura científica consolidada em Ciência da Computação, Inteligência Artificial, Psicologia Cognitiva e Direito Digital.

5.1 Teoria da Carga Cognitiva e Design Instrucional

A reformulação dos critérios em P3 e P6 realizada pelo PO reflete princípios sólidos da **Cognitive Load Theory (CLT)**, formulada por John Sweller [14, 20–22]. A CLT estabelece que a memória de trabalho humana possui capacidade estritamente limitada para novos elementos de informação. A carga cognitiva divide-se em:

a. **Carga Intrínseca:** Inerente à complexidade pedagógica do conceito que está sendo ensinado (ex.: loops de repetição ou variáveis em Computação);

b. **Carga Extrínseca:** Gerada pelo design deficiente da interface, vocabulário inacessível, instruções ambíguas ou interfaces sobrecarregadas;

c. **Carga Germânica:** Esforço mental direcionado à construção de esquemas mentais duradouros e aprendizagem significativa.

Ao exigir testes de piso na escola pública e eliminar complexidades cosméticas de tela (como preconizado por David Merrill em seus *First Principles of Instruction* [12]), a proposta do PO atua com eficácia na **minimização da carga extrínseca**, liberando largura de banda cognitiva do estudante para o domínio da carga intrínseca pedagógica. Essa ancoragem conecta-se diretamente com os ideais de construcionismo de Seymour Papert [15] e com o desenvolvimento do Pensamento Computacional proposto por Jeannette Wing [25].

5.2 Engenharia de Prompts, Raciocínio em LLMs e Diluição de Atenção

Modelos de linguagem de grande porte (LLMs) operam como aprendizes de poucos disparos (*few-shot learners*) [3] e raciocinadores em cadeia de pensamento (*Chain-of-Thought*) [9, 23]. Contudo, mecanismos de autoatenção sofrem degradação severa com saturação de contexto. Pesquisas fundamentais de Liu et al. (2024, *"Lost in the Middle"*) [10] provam que a acurácia de recuperação e o seguimento de instruções em LLMs de janela longa degradam substancialmente quando informações críticas são posicionadas no meio de contextos extensos ou quando instruções redundantes saturam o espaço de atenção. A desduplicação dos critérios 3.1 a 3.3 em P3 implementada pelo PO encontra respaldo científico direto nesse fenômeno: ao desobstruir o contexto, o modelo base consegue concentrar seu orçamento de atenção nos critérios de experiência específicos da faixa etária.

Por outro lado, o controle estrito de formato de saída e aderência a contratos de dados exige garantias formais, exploradas por Willard & Louf (2023) [24] sob o paradigma de *Constrained Decoding / Guided Generation*. A violação de schemas literais pelo PO sem suporte na infraestrutura quebra o determinismo probabilístico necessário para agentes autônomos confiáveis em arquiteturas colaborativas multiagente [6, 16, 26].

5.3 Engenharia de Software: SSOT, Modularidade e Contratos

Em arquiteturas de software de alta confiabilidade, a especificação formal atua como uma barreira de invariantes. Bertrand Meyer (1992) [13], ao introduzir o *Design by Contract*, formalizou que interfaces entre componentes computacionais devem estabelecer pré-condições, pós-condições e invariantes imutáveis. A tentativa do PO de criar um segundo documento paralelo (`p5b`) viola frontalmente a lei de *Single Source of Truth (SSOT)* consagrada por Hunt & Thomas (1999) [7], a decomposição modular de David Parnas (1972) [17] e os princípios de refatoração segura de Martin

Fowler [5]. O experimento seminal de Knight & Leveson (1986) [8] em programação multiversão provou empiricamente que geradores independentes baseados na mesma especificação cometem falhas correlacionadas. Quando as próprias especificações divergem em semântica, o custo de sincronização e débito técnico cumulativo cresce exponencialmente (Sculley et al., 2015 [18]).

5.4 Conformidade Regulatória: LGPD Art. 14 e Resoluções do CNE

A atuação de plataformas EdTech em território nacional é estritamente balizada pela **Lei Geral de Proteção de Dados (Lei nž 13.709/2018 - LGPD)** [2]. O Artigo 14 impõe regime de tutela qualificada:

> *"O tratamento de dados pessoais de crianças e de adolescentes deverá ser realizado em seu melhor interesse, considerada a legislação específica e nos termos deste artigo."*

O ğ 1ž condiciona a coleta ao consentimento específico e em destaque dado por pelo menos um dos pais ou responsável legal. A remoção, promovida pelo PO em `formato-spec.md`, das cláusulas que governam o destino de mídia, o controle de retenção temporal e o isolamento de texto livre constitui **violação gravíssima de compliance**. Em caso de auditoria da Autoridade Nacional de Proteção de Dados (ANPD) ou do Ministério Público, a plataforma Unooria estaria sujeita a multas pesadas e suspensão do banco de dados escolar.

Adicionalmente, a exclusão da BNCC Computação para adotar exclusivamente o material de uma editora privada confronta a **Resolução CNE/CEB nž 1/2022** [4], que torna obrigatória a inclusão do pensamento computacional, mundo digital e cultura digital em todos os anos da Educação Básica.

6 Plano de Ação de Engenharia e Patches Recomendados

Para extrair o valor pedagógico do trabalho do PO sem expor a plataforma ao colapso operacional, a Diretoria de Engenharia estabelece o seguinte plano de remediação imediata em 3 frentes.

6.1 Frente 1: Patches de Infraestrutura no Código Python

Patch C1: Atualização do Parser de Envelopes em `agents/callbacks.py`

```
# Inclusao de novos literais na linha 63 de agents/callbacks.py:
if status in ("apto_com_ressalvas", "aprovado_com_ressalvas",
    "liberada_com_ressalvas", "ressalvas", "amarelo"):
    return STATUS_APROVADO

# Atualizacao da lista de tokens de aprovacao textual (linha 36):
_APROVADO_TOKENS = (
    "APROVADO", "LIBERADA PARA DESIGN/DEV",
    "LIBERADA COM RESSALVAS", "APTO COM RESSALVAS",
    "APTO PARA CODIFICAR", "APROVADO PARA REVISÃO HUMANA"
)
```

Patch C2: Sincronização do Teto de Rodadas em `agents/produto/__init__.py` Ajustar o parâmetro `gate_estrutural_max_rodadas = 4` para compatibilizar a regra de parada proposta pelo PO no prompt P1.

6.2 Frente 2: Patches de Conciliação nos Prompts de Produto

1. **Adotar integralmente em P1 e P3**: As melhorias de rubrica, falsificabilidade do Critério 1.6 e desduplicação dos critérios 3.1–3.3.

2. **Ajustar a Etapa 6.5 em P4**: Retificar a árvore de decisão para:

Regra Corrigida: • se qualquer F-critério for bloqueio **ou se houver decisões de produto em aberto**; senão • se existir qualquer risco aceito; senão • .

3. **Rejeitar P5b como Prompt Autônomo**: Incorporar as seções pedagógicas do One-Pager como uma seção de visualização gerada a partir da spec única no estágio de Dev, preservando o princípio SSOT.

6.3 Frente 3: Blindagem e Restauração das Referências Técnicas

1. **Restauração Imediata de `formato-spec.md`**: Restaurar integralmente as 73 linhas do arquivo canônico do repositório, mantendo a Ficha do Manifesto em chave-valor, a governança de mídia LGPD Art. 14, o isolamento RLS e o contrato xAPI sem payload `dados`.

2. **Restauração de `ambientes.md`**: Preservar a versão do repositório que contém o suporte a tema escuro (ADR-68) e as pontes com a biblioteca `@edu/ui`.

7 Conclusão

O trabalho de revisão realizado pelo Product Owner evidenciou uma profunda sensibilidade pedagógica e um compromisso louvável com a adequação do produto à realidade da sala de aula brasileira. Suas contribuições nas rubricas avaliativas e no foco na experiência do estudante são de alto valor educacional.

Contudo, a engenharia de prompts em sistemas multiagentes integrados a monorepos complexos exige rigor técnico equivalente ao desenvolvimento de compiladores. Não é possível alterar a sintaxe de saída de um agente sem atualizar os parsers de infraestrutura, nem é admissível desidratar arquivos de especificação técnica sem romper os linters e bancos de dados que deles dependem.

A solução madura de engenharia não reside na rejeição cega do olhar do PO, nem na capitulação técnica da plataforma: reside na **arquitetura de conciliação** proposta neste relatório, que absorve as inovações pedagógicas ao mesmo tempo em que blinda os contratos determinísticos de software e o marco legal da proteção de dados infantis.

Referências

[1] Lorin W. Anderson, David R. Krathwohl, Peter W. Airasian, Kathleen A. Cruikshank, Richard E. Mayer, Paul R. Pintrich, James Raths, and Merlin C. Wittrock. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives*. Longman, New York, NY, 2001.

[2] Brasil. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, 2018.

[3] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020.

[4] Conselho Nacional de Educação. Resolução CNE/CEB nº 1/2022 e parecer CNE/CEB nº 2/2022. Normas sobre Computação na Educação Básica – Complemento à BNCC. Diário Oficial da União, 2022.

[5] Martin Fowler, Kent Beck, John Brant, William Opdyke, and Don Roberts. *Refactoring: Improving the Design of Existing Code*. Addison-Wesley, Boston, MA, 1999.

[6] Sirui Hong, Mingchen Zhuge, Jonathan Chen, Xiawu Zheng, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, et al. MetaGPT: Meta programming for a multi-agent collaborative framework. In *International Conference on Learning Representations (ICLR)*, 2024.

[7] Andrew Hunt and David Thomas. *The Pragmatic Programmer: From Journeyman to Master*. Addison-Wesley, Reading, MA, 1999.

[8] John C. Knight and Nancy G. Leveson. An experimental evaluation of the assumption of independence in multiversion programming. *IEEE Transactions on Software Engineering*, SE-12(1):96–109, 1986.

[9] Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. Large language models are zero-shot reasoners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 35, pages 22199–22213, 2022.

[10] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.

[11] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. Self-refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 46534–46594, 2023.

[12] M. David Merrill. First principles of instruction. *Educational Technology Research and Development*, 50(3):43–59, 2002.

[13] Bertrand Meyer. Applying "design by contract". *Computer*, 25(10):40–51, 1992.

[14] Fred Paas, Alexander Renkl, and John Sweller. Cognitive load theory and instructional design: Recent developments. *Educational Psychologist*, 38(1):1–4, 2003.

[15] Seymour Papert. *Mindstorms: Children, Computers, and Powerful Ideas*. Basic Books, New York, NY, 1980.

[16] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*, pages 1–22. ACM, 2023.

[17] David L. Parnas. On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, 15(12):1053–1058, 1972.

[18] David Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-Francois Crespo, and Dan Dennison. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 28, 2015.

[19] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik R. Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 8634–8652, 2023.

[20] John Sweller. Cognitive load during problem solving: Effects on learning. *Cognitive Science*, 12(2):257–285, 1988.

[21] John Sweller, Paul Ayres, and Slava Kalyuga. *Cognitive Load Theory*. Springer, New York, NY, 2011.

[22] Jeroen J. G. van Merriënboer and John Sweller. Cognitive load theory and complex learning: Recent developments and future directions. *Educational Psychology Review*, 17(2):147–177, 2005.

[23] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 35, pages 24824–24837, 2022.

[24] Brandon T. Willard and Rémi Louf. Efficient guided generation for large language models. *arXiv preprint arXiv:2307.09702*, 2023.

[25] Jeannette M. Wing. Computational thinking. *Communications of the ACM*, 49(3):33–35, 2006.

[26] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Shaokun Zhang, Erkang Zhu, Beibin Li, Li Jiang, Xiaoyun Zhang, and Chi Wang. AutoGen: Enabling next-gen LLM applications via multi-agent conversation. *arXiv preprint arXiv:2308.08155*, 2023.

[27] Yiyu Y. Yao. Three-way decisions with probabilistic rough sets. *Information Sciences*, 180(3):341–353, 2010.