Gerador de Missões Unooria

Guia de funcionamento: o que a esteira faz, por que faz assim,
e como escrever uma entrada que produz uma boa missão

Documentação técnica — repositório `gerador-missoes`

19 de setembro de 2026

Resumo

O gerador transforma uma ideia de missão em um **PRD pronto para codificação** e um **one-pager que o time pedagógico aprova**, passando por 54 agentes organizados em três etapas e sete ciclos de correção automática. Este guia é para quem vai *usar* a ferramenta: explica o que colocar na entrada, o que cada etapa faz, como ler o diagnóstico quando algo trava, e por que o sistema foi desenhado desta forma e não como um único prompt grande. A Seção 2 — com exemplos de briefing bom e ruim — é a que mais muda o resultado na prática.

Sumário

1 O que a esteira faz **3**
1.1 A regra que muda tudo: a esteira não desiste 3

2 Como escrever a entrada **3**
2.1 O que o primeiro agente precisa 3
2.2 Um briefing que funciona 4
2.3 Briefings que produzem missão ruim 4
2.4 Anexos valem mais que adjetivos 5

3 Por que muitos agentes, e não um prompt grande **5**
3.1 Densidade de instrução degrada o cumprimento 5
3.2 O critério de decomposição 5
3.3 Redundância não é cobertura 6
3.4 O contraponto honesto 6

4 As etapas **6**
4.1 Produto (01–16): a missão pode ser construída? 6
4.2 Design (17–32): como isso se constrói 7
4.3 Dev (33–49): isso é implementável? 7
4.4 Transversal (50–51): o que aconteceu 7

5 Os sete ciclos de correção **7**

6 Os portões, e o que fazer quando reprovam **8**

7 Como ler o diagnóstico **9**

8 A régua por idade **9**

9 O identificador da missão **9**

10 Configuração **10**

11 Três recomendações de uso **10**

12 Os agentes, um a um: o que fazem e em que se apoiam **10**
12.1 Produto (01–16) 10
12.2 Design (17–32) 12
12.3 Dev (33–49) e Transversal (50–51) 13
12.4 Refino dos dois entregáveis finais 14
12.5 O que mudou nesta revisão, e por quê 15
12.6 Correções vindas da primeira execução completa 16
12.7 Correções vindas da terceira execução 17
12.8 Identificação no histórico 18

1 O que a esteira faz

Você escreve um briefing de meia página sobre a missão que quer. A esteira devolve:

Artefato	Para quem é
`one-pager-pedagogico.md` (+ `.docx`)	Time pedagógico, coordenação e a professora consultora. Linguagem de sala de aula, zero jargão. É o documento de aprovação.
`PRD.md`	O agente (ou a pessoa) que vai codificar. 25 seções, com contratos de dados, eventos e arquitetura.
`diagnostico-execucao.md`	Você. Diz o que passou, o que passou com ressalva, o que travou e de quem é cada conserto.
`design/09-diagramas.html`	Quem quiser *ver* a missão: jornada e fluxo em diagramas.
`design/08-prototipo.html`	Revisão humana: as telas navegáveis, abre com duplo clique.
`aprendizado.md`	O processo: o que esta execução ensinou e o que propor de mudança nas rubricas.

Mais os documentos intermediários: spec da missão, jornada, fluxo, copy, especificação de telas, camada de acessibilidade, handoff de dev e os relatórios de cada portão.

1.1 A regra que muda tudo: a esteira não desiste

Um portão reprovado **não** interrompe a execução. Todos os documentos são produzidos até o fim; o que deriva de uma etapa reprovada sai marcado `[PROVISÓRIO]`, e o diagnóstico final diz o que é firme e o que é rascunho.

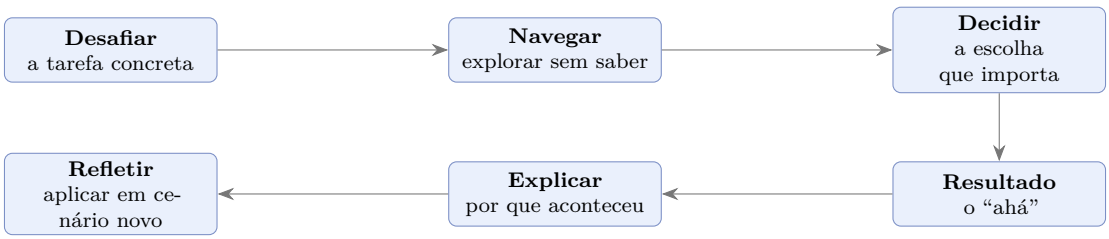
Isso é deliberado. Na versão anterior, a primeira reprovação parava tudo: não saía PRD, não saía one-pager, não saía relatório — e quem precisava entender o erro ficava sem material para analisar. Um sistema que falha sem deixar evidência transfere para a pessoa o trabalho de reconstruir o que aconteceu.

2 Como escrever a entrada

Esta é a seção com maior efeito sobre o resultado. A esteira é boa em *estruturar*, *auditar* e *formalizar*. Ela é ruim em adivinhar o que você não disse — e, por desenho, prefere marcar uma lacuna a inventar conteúdo.

2.1 O que o primeiro agente precisa

O agente 01 (Núcleo Narrativo) produz quatro coisas a partir do seu briefing: a **descoberta central**, a **narrativa**, o **mecanismo das seis etapas** e a **identificação** (ano, bimestre, ambiente). Ele precisa de matéria-prima para as quatro.



*O estudante que vive o Navegar **não pode saber** o que o Resultado vai revelar. Esse é o teste mais duro da esteira.*

Figura 1: O framework de seis etapas que toda missão segue

2.2 Um briefing que funciona

```
Missao para o 5o ano do Fundamental, 3o bimestre, no ambiente do YouTube (unitube).

Tema do bimestre (material Entre Redes anexado): como a recomendacao de
conteudo funciona e por que duas pessoas veem coisas diferentes.

O que quero que a crianca descubra: que o que ela ve no feed nao e "o que
existe", e sim o que o sistema aprendeu que ela costuma assistir.

Ideia de mecanismo: ela monta a playlist de um personagem a partir de um banco
de videos. Depois ve o feed que aquele personagem passa a receber. Dois colegas
com playlists diferentes recebem feeds diferentes, e isso fica visivel na tela.

Restricoes: 50 minutos, aula unica, dois estudantes por tablet.
A professora precisa conseguir pausar a turma antes da revelacao.

Em aberto: nao sei se o banco deve ter 8 ou 12 videos.
```

Por que funciona:

1. **Ano e bimestre explícitos.** O identificador da missão codifica os dois (Seção 9); sem eles o primeiro portão determinístico já reprova.
2. **A descoberta está escrita como descoberta**, não como objetivo de aula. Compare: "a criança vai aprender sobre algoritmos de recomendação" (objetivo) contra "o que ela vê não é o que existe" (descoberta).
3. **Há um mecanismo, não só uma intenção.** "Monta a playlist, vê o feed que resulta, compara com o colega" é uma cadeia de ações. "Trabalhar pensamento crítico sobre algoritmos" não é.
4. **As restrições de sala aparecem.** Tempo, dispositivo compartilhado e controle da professora mudam o desenho, e a esteira audita os três.
5. **A dúvida está declarada.** Dizer "não sei se 8 ou 12" faz a esteira decidir e registrar a decisão. Omitir faria ela decidir sem você saber.

2.3 Briefings que produzem missão ruim

Entrada problemática	O que acontece
"Missão sobre fake news para o Fundamental."	Sem ano, sem bimestre, sem ambiente, sem mecanismo. A esteira inventa os quatro, e o que ela inventa é o mais genérico possível. **Pior caso de uso da ferramenta.**
"O estudante navega por um feed com posts falsos e descobre que foram manipulados."	O briefing **entrega a virada**. A esteira tem um portão dedicado a isso (agente 02) e vai reprovar, mas o estrago já aconteceu: a ideia nasceu sem segredo, e refazer o núcleo custa rodadas.
"Uma missão que desenvolva pensamento crítico e cidadania digital."	Intenção sem mecanismo. O gate estrutural tem um critério só para isso: se você remover a frase, a missão continua igual, então a frase não descreve nada construível.
"O estudante avalia 15 perfis e classifica cada um como confiável ou não."	Passa no teste de decisão simples e reprova no volume: 15 decisões do mesmo tipo excede o teto da faixa. Vira **ressalva** ou reprovação no agente 09.

continuação

Entrada problemática	O que acontece
"Fazer no Roblox, que as crianças amam."	Ambiente fora da lista fechada (Instagram, YouTube, ChatGPT, TikTok, WhatsApp). Reprovação imediata — não existe seção de design system para construir.
"A criança conversa com a IA e reflete sobre o que aprendeu."	Reflexão genérica. O critério 1.6 pede uma *provocação concreta*: uma situação nova em que ela aplica o que viveu. O teste é direto: alguém que não fez a missão consegue responder?
Briefing de oito páginas com todas as telas já desenhadas.	A esteira vira transcritora. Os portões detectam "eco" — quando um agente repete a entrada em vez de construir — mas você terá pago 50 chamadas para formatar o que já tinha.

2.4 Anexos valem mais que adjetivos

Anexe o material do bimestre (o *Entre Redes* em `.docx`). Ele é a fonte primária de código curricular e de contexto: a esteira lê os códigos da BNCC dali e os confere contra o anexo oficial do MEC [2]. Dois parágrafos de material real valem mais que uma página de descrição.

3 Por que muitos agentes, e não um prompt grande

A pergunta aparece sempre, e a resposta não é "porque especialização é boa".

3.1 Densidade de instrução degrada o cumprimento

A etapa de Produto sozinha carrega cerca de 74 mil *tokens* de instrução e 51 critérios tabelados. No *benchmark* IFScale, que mede exatamente isso, os melhores modelos de fronteira chegam a 68% de acurácia quando precisam seguir 500 instruções ao mesmo tempo [4], com viés sistemático em favor das instruções apresentadas primeiro. Liu et al. [7] documentam o efeito irmão em contexto longo: o que está no meio é usado pior que o que está nas pontas.

Há evidência interna, e ela é mais convincente que a externa. O prompt do agente 09 abre justificando a própria existência: *"esta avaliação existe porque a rubrica original errava sistematicamente aqui: os critérios de faixa etária competiam por atenção com ∼30 critérios de outra natureza"*. A versão agregada falhava de modo reprodutível; a decomposta corrigiu.

3.2 O critério de decomposição

Não se divide por etapa cronológica. Divide-se por **decisão encapsulada**, no sentido clássico de Parnas [8]: cada agente responde uma pergunta que pode ser respondida — e errada — independentemente das outras, e emite um envelope JSON que um portão consegue ler.

Agente	A pergunta que ele responde
05 Gate estrutural	A missão tem estrutura construível?
08 Avaliação pedagógica	Cumpre currículo e protege o estudante?
09 Experiência do estudante	Alguém dessa idade consegue viver isso?
29 QA de entregáveis	A construção é fiel ao que foi especificado?

3.3 Redundância não é cobertura

Três critérios do agente 09 eram testes idênticos a três critérios do agente 05 — mesma pergunta, mesmo modo de falha. Foram removidos. Knight e Leveson [6] mostraram, em 27 implementações independentes submetidas a um milhão de testes, que falhas correlacionadas anulam o ganho da redundância. Quando os dois "avaliadores independentes" são prompts diferentes do *mesmo modelo*, sobre o *mesmo texto*, a correlação é ainda maior.

3.4 O contraponto honesto

A literatura recente é cética quanto a sistemas multiagente: sob orçamento fixo de *tokens*, um agente único frequentemente iguala ou supera arquiteturas multiagente [10]. A condição de contorno declarada pelos próprios autores é que o multiagente vence *"quando a utilização efetiva de contexto de um agente único está degradada"* — que é exatamente o regime desta esteira. E Cemri et al. [1], sobre mais de 1.600 execuções anotadas, mostram que decompor cria uma classe nova de falha: contratos de interface. Por isso cada fronteira aqui tem envelope JSON verificado por teste.

4 As etapas

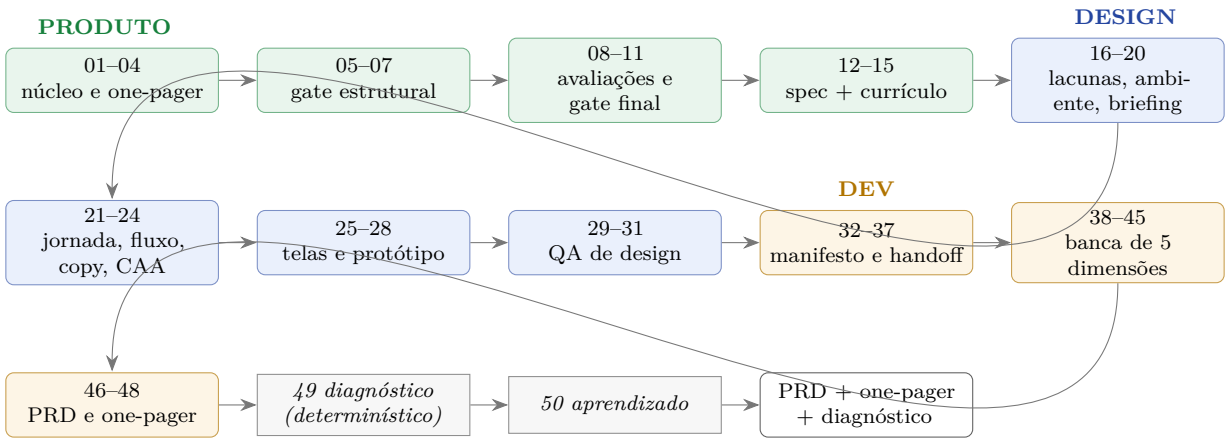


Figura 2: Os agentes da esteira, numerados na ordem de execução

4.1 Produto (01–16): a missão pode ser construída?

Decide *o que* a missão é. Começa pelo núcleo narrativo, passa por um micro-portão que caça *spoiler* e ausência de escolha significativa, completa o one-pager de 18 seções, submete tudo aos 23 critérios do gate estrutural, avalia currículo e faixa etária em paralelo, e fecha com a **spec** — o contrato de 12 blocos contra o qual Design e Dev constroem.

4.2 Design (17–32): como isso se constrói

Fecha as lacunas da spec, decide o ambiente simulado, escreve o briefing de ofício, e então constrói: jornada e fluxo em **diagramas Mermaid**, copy em duas passadas, camada de acessibilidade, especificação de telas e um **protótipo HTML navegável** que abre com duplo clique. Fecha com o QA de entregáveis, que audita fidelidade à spec.

> **Nota sobre ferramentas.** A esteira não usa mais o Figma — não há cliente oficial que o sirva neste ambiente, e board em ferramenta que ninguém abre não é entregável. Jornada e fluxo saem em Mermaid, as telas saem no Stitch e como especificação em Markdown, e o artefato visual é o protótipo HTML.

4.3 Dev (33–49): isso é implementável?

Confere a ficha do manifesto, produz o handoff e o brief de assets, valida o contrato de telemetria, e submete tudo a uma banca de cinco dimensões em paralelo — produto, design, pedagogia, dados/LGPD e arquitetura. Consolida, escreve o PRD e, por último, o one-pager pedagógico.

4.4 Transversal (50–51): o que aconteceu

O diagnóstico determinístico monta o dossiê a partir dos envelopes que os portões gravaram; o agente de aprendizado escreve a leitura em prosa e registra o que a execução ensinou.

5 Os sete ciclos de correção

Quando um portão reprova, quem decide repetir é o **orquestrador**, em código — não uma instrução em linguagem natural dentro do prompt, que o modelo pode ou não seguir.

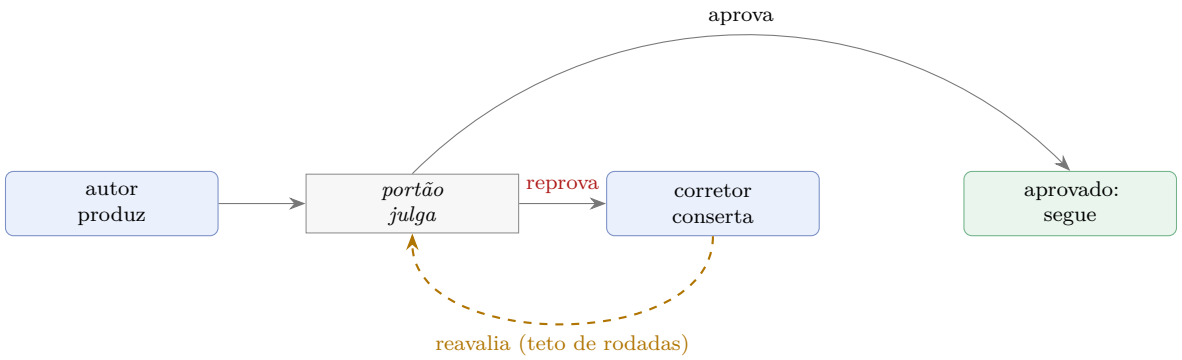


Figura 3: O padrão comum aos sete ciclos: quem julga não conserta, quem conserta não julga

Ciclo	Portão → corretor	O que resolve
Núcleo	micro-gate → 01	*Spoiler*, falta de segredo, escolha sem consequência.
Gate estrutural	05 → 07 revisor	Os 23 critérios de estrutura. O gate escreve o texto de correção pronto para colar.
Spec	currículo + manifesto → 12	Código da BNCC inexistente ou de outro ano; campo do manifesto fora do vocabulário fechado. Conserto mecânico.

QA de design	29 → dono do ticket	Cada achado tem dono declarado; só os endereçados rodam de novo, e o protótipo é refeito depois.
Handoff	telemetria → 33	Contrato de eventos, papéis, canal de sala. O mais barato: a correção vem escrita na mensagem do portão.
Banca	banca → dono do achado	Inclui donos da *etapa anterior*: um erro de jornada detectado em Dev volta para o agente de jornada.
PRD	48 → 47 redator	Consistência interna do entregável final: prefixo de tabela, caminho do módulo, requisito P0 sem rastro, evento sem tabela leitora, tarefa não atômica, identificador inválido.

Dois freios. Cada ciclo tem teto próprio, e existe um orçamento global de reexecuções para a execução inteira (`ORCAMENTO_REEXECUCOES`, padrão 8). Estourado qualquer um dos dois, a esteira para de tentar, marca pendência humana e segue até o fim.
O que não volta. Achado cujo dono está na etapa de *Produto* não reabre a spec: reabri-la invalidaria tudo que o Design construiu sobre ela. Vira pendência nomeada no diagnóstico, para decisão humana.

6 Os portões, e o que fazer quando reprovam

Há dois tipos. **Determinísticos** são funções Python: não gastam *token*, não erram e não mudam de opinião. **Avaliadores** são agentes que aplicam rubrica — e aqui vale saber que avaliadores baseados em modelos de linguagem têm vieses documentados de posição, verbosidade e leniência [11], razão pela qual toda regra que *pode* ser mecânica foi tirada deles.

Portão	**Tipo**	**Reprova quando**
Micro-gate (02)	rubrica	O briefing ou o núcleo entrega a virada; a escolha não muda nada.
Gate estrutural (05)	rubrica	Falta mecanismo, caminho sem tratamento, ambiente fora da lista.
Gate final (10)	rubrica	Os três relatórios avaliaram versões diferentes; correção ficou só no relatório.
Currículo BNCC (13)	**código**	Código inexistente, de outro ano, ou sem letramento digital.
Manifesto (14 e 32)	**código**	Campo do bloco 0 ausente ou fora do vocabulário fechado.
QA de design (29)	rubrica	Construção infiel à spec; diagrama ausente ou inválido.
Telemetria (35)	**código**	Evento fora do contrato real da API.
Rastro de lacunas (37)	**código**	Marcadores de lacuna abertos nos documentos.
Banca (38–44)	rubrica	Qualquer um dos critérios bloqueantes das cinco dimensões.

Pendências e consistência do PRD (48)	**código**	Marcadores que o redator deixou por falta de informação; e o documento se contradizendo: dois caminhos para o mesmo módulo, prefixo de tabela fora do padrão, requisito P0 sem teste nem tarefa, evento sem tabela leitora, tarefa que cobre tudo, identificador inválido em código. Reprovado, devolve ao redator (48b).

7 Como ler o diagnóstico

O `diagnostico-execucao.md` é o primeiro arquivo a abrir. Ele tem sempre a mesma ordem:

1. **Veredito e contagem** — impedimentos, ressalvas, decisões humanas.
2. **Como cada portão se saiu** — tabela com resultado e rodadas gastas.
3. **O que reprovou, na ordem** — a sequência dos fatos.
4. **O que precisa ser consertado, por dono** — agrupado por responsável.
5. **O que só uma pessoa decide** — o que nenhuma rodada resolve.
6. **O que saiu provisório** — os documentos que dependem de algo reprovado.
7. **Documentos ausentes** — sintoma de agente que não produziu nada.
8. **Por onde começar** — a ação que destrava mais coisa de uma vez.

Regra prática: **impedimento** é o que impede construir; **ressalva** é risco aceito e registrado; **decisão humana** é o que a esteira não tem autoridade para resolver — escolha de produto, licença de imagem, validação pedagógica.

8 A régua por idade

Os tetos que a esteira aplica quantas opções o estudante compara numa decisão, quanto dura cada ato, o que se pode pedir que ele entenda vivem num arquivo só: `prompts/references/literatura-cognitiva.md`. Nenhum agente carrega régua própria, e cada número lá é marcado como **dado direto**, **extrapolação** ou **convenção**. A Seção 12 mostra em que cada agente se apoia, e o que mudou na última revisão.

9 O identificador da missão

O código da experiência carrega ano e bimestre:

Código	Significa	Campos que têm de concordar
`exp01ef1b`	1.º ano EF, 1.º bimestre	`series: ["1EF"]` ů `unidade: 1`
`exp05ef3b`	5.º ano EF, 3.º bimestre	`series: ["5EF"]` ů `unidade: 3`
`exp02em2b`	2.º ano EM, 2.º bimestre	`series: ["2EM"]` ů `unidade: 2`

Um portão determinístico confere que `series` e `unidade` concordam com o identificador — divergência trava, porque é ele que nomeia tabela, pasta e *branch*. Missão transversal (sem série) e ferramenta de professor não têm ano nem bimestre: seguem no formato antigo `exp-NN-<slug>`.

10 Configuração

Variável	Padrão	O que faz
GATE_ESTRUTURAL_MAX_RODADAS	3	Rodadas do ciclo gate ↔ revisor.
SPEC_MAX_RODADAS	2	Ciclo spec ↔ currículo e manifesto.
QA_DESIGN_MAX_RODADAS	2	Ciclo QA ↔ retrabalho de design.
HANDOFF_MAX_RODADAS	2	Ciclo handoff ↔ telemetria.
BANCA_MAX_RODADAS	2	Ciclo banca ↔ dono do achado.
PRD_MAX_RODADAS	2	Ciclo redator do PRD ↔ consistência do documento.
ORCAMENTO_REEXECUCOES	8	Teto global de agentes reexecutados.
ESTEIRA_ESTRITA	true	Reprovação marca herança degradada e o PRD sai ; desligado, vira ressalva.
PIPELINE_STAGES	todas	Permite rodar só uma etapa, sobre um estado salvo.

Qualquer teto em 1 desliga o ciclo correspondente: a esteira avalia e reporta, sem corrigir.

11 Três recomendações de uso

Comece pelo diagnóstico, não pelo PRD.
Ele diz em trinta segundos se vale ler o resto.

Trate [PROVISÓRIO] como rascunho, não como entrega.
O marcador existe porque o documento foi construído sobre algo que um portão reprovou.

Rode uma etapa isolada quando estiver iterando.
PIPELINE_STAGES sobre um estado salvo custa minutos em vez de uma execução inteira, e a entrada fica fixa entre tentativas.

12 Os agentes, um a um: o que fazem e em que se apoiam

Esta seção existe por uma razão específica: uma rubrica que não diz de onde tira os números acaba defendida por antiguidade. Cada agente aparece aqui com o que faz, a regra que aplica e a natureza da fundamentação dessa regra. São três naturezas, e confundi-las é o erro que esta revisão veio corrigir:

Evidência
a regra deriva de pesquisa publicada, com citação. Marcada aqui com a fonte.

Contrato
a regra deriva de um documento normativo — a BNCC, a LGPD, o manifesto da plataforma. Não é teoria e não se pesquisa: se confere contra o documento.

Convenção
a equipe escolheu por consistência de produto, sem base empírica. É legítimo, desde que declarado. O que não é legítimo é convenção apresentada como achado.

12.1 Produto (01–16)

Agente	O que faz	Em que se apoia
01 Núcleo narrativo	Descoberta central, narrativa e o mecanismo das seis etapas	*Convenção* — o framework de seis etapas é desenho de produto da Unooria. A exigência de *gap* de informação tem lastro em curiosidade epistêmica: a lacuna percebida entre o que se sabe e o que se quer saber é o que move a busca [12].
02 Micro-gate	Caça *spoiler*, ausência de segredo e escolha sem consequência	*Convenção* derivada de 01. A separação entre quem escreve e quem critica reduz autopreferência, viés documentado em avaliadores baseados em modelos [13].
04 Seções de apoio	Completa o *one-pager* de 18 seções	*Convenção* — formato de produto. A decomposição em relação a 01 é deliberada: densidade de instrução degrada o cumprimento de forma não linear [14].
05 Gate estrutural	23 critérios de estrutura, ambiente, logística e viabilidade	*Convenção* com dois critérios de *evidência*: o teto de decisões e a duração vêm da fonte única (Seção 8). Rubrica analítica com teste prático e contraexemplo é o que sustenta concordância entre avaliadores [15].
07 Revisor	Aplica ao *one-pager* a correção que o gate escreveu	*Convenção*. Existe para separar julgar de consertar — o mesmo motivo de 02.
08 Avaliação pedagógica	Currículo, papel do professor e *guardrails*	*Contrato*: BNCC Computação, anexo do MEC [16]. A regra de que só letramento digital bloqueia é decisão de governança do produto, não achado — e está declarada como tal.
09 Experiência do estudante	Carga cognitiva, faixa etária, linguagem e duração	*Evidência* — é o agente mais ancorado da esteira. Capacidade por idade [17, 18]; duração e atenção na tarefa [20, 21]; redundância e narração [23, 24]. Todos os números vêm da fonte única.
10 Adequação pedagógica	Parecer em seis eixos, com ajustes acionáveis	*Evidência* para a demanda cognitiva [27] e para o raciocínio sobre sistemas invisíveis [28, 29]; *contrato* para a BNCC; *convenção* declarada para o placar de 0 a 18. Não carrega régua numérica própria: defere à fonte única.
11 Gate final	Coerência entre os pareceres e veredito de release	*Convenção*. Existe porque avaliadores paralelos podem julgar versões diferentes do mesmo documento — e isso é falha de sistema multiagente, não de avaliação [36].
13 Spec da missão	Os 12 blocos do contrato de construção	*Contrato* — manifesto da plataforma, RLS, contrato de eventos. Nada aqui é teoria.

Agente	O que faz	Em que se apoia
14 Conformidade BNCC	Código existe, é do ano, e há letramento digital	*Contrato*, verificado em código contra o anexo oficial [16]. Determinístico de propósito: é regra mecânica, e avaliador de modelo tem viés de leniência [13].
15 Ficha do manifesto	Dez campos do bloco 0 contra vocabulário fechado	*Contrato* da plataforma. Roda em Produto, não em Dev, porque o conserto ali custa uma reescrita da *spec* em vez do descarte do Design inteiro.
03 ů 06 ů 10b ů 12 ů 16	Vereditos determinísticos que roteiam o fluxo	*Contrato* interno: leem o envelope JSON e decidem repetir, seguir ou parar. Não julgam mérito — é o que permite que a decisão de repetir seja do orquestrador, não do modelo.

12.2 Design (17–32)

Agente	O que faz	Em que se apoia
17 Fechamento de lacunas	Preenche o que a *spec* não decidiu, com base declarada	*Convenção*. Preenche ausência, nunca altera presença — a regra existe para que o Design não redecida produto.
19 Ambiente simulado	Decide a casca quando a *spec* cala	*Contrato* (lista fechada de cinco seções do *design system*) mais *convenção* para o mini-jogo dos anos iniciais.
21 Briefing de ofício	Arco, pico e beat memorável	*Convenção* de ofício narrativo. É a parte menos fundamentável da esteira, e está declarada assim: são heurísticas de dramaturgia, não achados.
22 Jornada ů 23 Fluxo	Raias por etapa e grafo de estados, em Mermaid	*Convenção*. O diagrama existe porque representação externa reduz a carga de manter a estrutura na cabeça — princípio geral de carga cognitiva [26].
24 ů 27 Copy (duas passadas)	Strings por tela, e revisão dentro da tela construída	*Evidência* para a calibragem de linguagem por faixa (fonte única, ğ5) e *convenção* para o formato de duas passadas.
25 Camada CAA	Símbolos, modos alternativos de resposta e pranchas	*Contrato* de acessibilidade. A regra de que símbolo vem *junto* do texto, nunca no lugar dele, é redundância deliberada e benéfica para quem não decodifica [25].
26 Telas	Especificação por tela e construção no Stitch	*Contrato* (tokens do *design system*) mais *evidência* para o teto de elementos novos por tela [26].

28 Protótipo	HTML navegável com CSS e JS embutidos	*Convenção.* É o artefato que a revisão humana abre; a exigência de arquivo único e offline é operacional.
30 QA de entregáveis	Audita fidelidade da construção à *spec*	*Convenção*, com uma regra de *evidência*: a proibição de reportar número não medido (o *diff* de *strings* só conta se foi medido).
18 ů 20 ů 29 ů 31 ů 32	Determinísticos de extração, artefato e despacho	*Contrato* interno. O despacho de retrabalho reexecuta só quem tem ticket, porque redundância com falhas correlacionadas não aumenta cobertura [35].

12.3 Dev (33–49) e Transversal (50–51)

Agente	**O que faz**	**Em que se apoia**
34 Handoff	Traduz a construção em requisito implementável	*Contrato* da plataforma: assinatura de evento, papéis, canal de sala.
35 Brief de assets	O que produzir, e o que reprova um asset	*Convenção* de produção.
39–43 Banca (5 dimensões)	Produto, design, pedagogia, dados e arquitetura, em paralelo	*Contrato* em quatro das cinco dimensões; *evidência* em pedagogia. A separação em cinco existe porque um avaliador único com 70 critérios erra de forma sistemática [14] — e porque falhas correlacionadas não se compensam [35].
44 Consolidação	Veredito único a partir das cinco dimensões	*Contrato*: regra determinística de bloqueio, sem bom senso.
47 PRD	As 25 seções que alimentam quem codifica	*Contrato* da plataforma e da LGPD (dado de criança e adolescente).
49 One-pager pedagógico	A missão em linguagem de sala de aula, para aprovação humana	*Convenção* de comunicação, com uma regra que vale citar: nenhuma ressalva sobrevivente pode ser omitida, mesmo com veredito verde. Avaliadores tendem à leniência [13]; a regra existe contra isso.
36 ů 38 ů 48 Rastro	Telemetria, lacunas, pendências e consistência interna do PRD, em código	*Contrato.* Determinístico porque é comparação literal contra documento. O 48 também confere o documento contra si mesmo: um PRD sem lacuna nenhuma ainda faz quem codifica escolher ao acaso se nomeia o mesmo diretório de duas formas ou deixa um requisito bloqueante sem tarefa. Reprovado, devolve ao redator (48b) em vez de mandar o defeito para uma pessoa resolver.

50 Diagnóstico	O dossiê da execução, sem modelo de linguagem	*Contrato* interno. Roda sempre, inclusive quando tudo mais falhou — é a peça que sustenta a decisão de não abortar.
51 Aprendizado	A leitura em prosa e a memória do processo	*Convenção.*

12.4 Refino dos dois entregáveis finais

Uma revisão dedicada aos dois documentos que saem no fim — o *one-pager* pedagógico e o PRD — perguntou o que a literatura recomenda acrescentar. A resposta, nos dois casos, foi a mesma: **nada de conteúdo novo**. Os dois já estão acima da média do gênero. O que faltava era **ordem, navegação e verificação**.

One-pager: o problema era onde as coisas estavam. A pesquisa sobre adoção de material didático converge num ponto: o professor decide por praticidade — o material diz concretamente o que fazer, cabe na turma que ele tem, e compensa o esforço [37]. E em adoção de tecnologia escolar, a preocupação mais intensa é *operacional*, não teórica [38]. Três consequências:

- **A decisão pedida subiu para o topo.** Ela aparecia a 80% do documento. Quem lê precisa saber na primeira tela o que está sendo pedido; se parar ali, ainda sabe o que fazer.
- **Entrou "O que sua sala precisa ter"**, em lista fechada — aparelhos, projetor, internet, material impresso, minutos de preparo. Antes isso estava disperso em prosa, e era justamente a pergunta que o professor faz primeiro.
- **As perguntas de aprovação viraram instrumento**, com opção de resposta e assinatura, em vez de convite a opinião livre. Material sem expectativa clara de implementação não é usado.

E um defeito concreto que a execução real expôs: o documento dizia "o protótipo pode ser aberto no navegador" *sem nenhum endereço*, e o teste que deveria pegar isso não bloqueava. O protótipo é o único item que deixa a professora simular a aula antes de aprovar — o teste passou a ser bloqueante. Também saíram as URLs longas de servidor de arquivo coladas no corpo do texto: são ruído de leitura e vencem em poucos dias.

PRD: o problema era que nada verificava o que ele afirmava. Aqui a literatura foi mais direta ainda. Especificação bem escrita ajuda pouco; especificação **verificada contra o repositório** ajuda de forma mensurável [40], e o que reduz alucinação em geração de código é símbolo e caminho verificáveis, não prosa mais detalhada [41]. Somado a isso, documento longo não é vantagem: a recuperação piora no meio de contextos grandes [7].

As 25 seções ficaram como estavam. O que entrou foi um **gate determinístico de consistência interna**, porque o gabarito já exigia essas regras em prosa e ninguém as conferia. Ele barra: mais de um prefixo de tabela no mesmo documento; requisito P0 que não aparece na matriz de rastreabilidade nem em tarefa; evento declarado com leitura em Pub/Sub em vez de tabela própria; tarefa que diz cobrir "todos os requisitos"; nome de módulo que não é identificador válido; e dois caminhos diferentes para o mesmo diretório da experiência.

Nenhum desses é lacuna de informação — são contradições internas. Um PRD pode não ter marcador de pendência nenhum e ainda assim fazer quem codifica escolher um caminho ao acaso, e a partir daí o resto do documento deixa de valer contra o que foi escrito.

12.5 O que mudou nesta revisão, e por quê

A revisão de setembro de 2026 não ajustou números: trocou a fundamentação de quatro critérios, porque a pesquisa mostrou que as fontes citadas não sustentavam o que a rubrica afirmava.

Mudança	**Antes**	**Por quê**
Teto de opções no Ensino Médio	4 a 5 opções	A capacidade visual de trabalho aos 16 anos é 2,72 itens, ainda abaixo do adulto (3,16) [19]. Tratar o Médio como capacidade adulta superestimava.
Fundamentação do teto de opções	*choice overload*	O efeito não replicou (meta-análise de 63 condições, efeito médio nulo), em adultos o ponto de inflexão fica entre 12 e 24 opções, e em crianças não apareceu *nem com 53 opções* [33]. O que sustenta os tetos é span complexo de memória de trabalho [17, 18] — outro construto.
Volume de decisões	obrigatório, com teto por faixa	Vinha de *decision fatigue*, que não sobreviveu à replicação [34]. Virou desejável e está marcado como convenção; o sinal real é monotonia, não esgotamento.
Tetos de duração	12 / 15 / 20 min	Observação de 52 salas mostra queda monotônica com a duração e efeito de série equívoco [20]: a duração importa mais que a idade. A escala foi achatada.
Teto agregado da missão	não existia	Três atos no teto antigo somavam mais que uma aula inteira. E só 64% do tempo de aula é atividade acadêmica no Brasil [22].
Formato da atividade	ignorado no julgamento de duração	Atividade individual ou em pequeno grupo sustenta atenção bem melhor que turma inteira [20].
Justificativa de abstração	Piaget	A parte citada — idades fixas, sem abstração antes dos 11 — é justamente a refutada. Substituída por ciclos de prioridade cognitiva [31] e pela dependência de suporte [32].
Raciocínio sobre sistema invisível	não existia	É o núcleo do letramento digital e não tinha régua. Entrou com três portas: descrever aos 8 anos, explicar aos 10–11, criticar aos 12–13 com apoio [29, 30].

Cenário da escola pública	suposição	Substituído por dados de INEP, CETIC e Saeb. A turma é menor do que se supunha nos anos iniciais; a situação de dispositivo é pior.

12.6 Correções vindas da primeira execução completa

Rodar a esteira inteira sobre um material real expôs três defeitos que nenhum teste unitário pegaria, porque não são erros de código: são lacunas de contrato. Os três foram corrigidos, e valem como princípio, não como conserto pontual.

1. **Ato que só uma pessoa pratica não é lacuna de construção.** Homologar autoria, indexar no material editorial, licenciar um acervo gráfico — nenhum agente produz isso. Os gates de rastro tratavam esses marcadores como impedimento, o que reprovava a missão por algo que nenhuma rodada de correção poderia resolver. Pior: como o texto do marcador não nomeava uma etapa da esteira, o achado caía na etapa padrão de quem o leu, e uma homologação editorial aparecia endereçada ao time de desenvolvimento. Passou a existir a categoria *humano*: severidade *decisão humana*, não bloqueio, e dono correto no dossiê.
2. **O prefixo da tabela é o identificador inteiro, sem separador interno.** Com o identificador novo carregando ano e bimestre, as referências que ainda ensinavam o formato antigo levaram um avaliador a pedir um prefixo híbrido, que não corresponde a nenhum dos dois padrões. A regra passou a estar escrita no gabarito da *spec*, com o contraexemplo.
3. **Insumo incompleto deve produzir pendência nomeada, não reprovação genérica.** Quando o material de origem não traz autoria, revisão ou indexação curricular, isso é uma informação ausente de quem forneceu o insumo — e o relatório precisa dizer exatamente isso, com o dono, em vez de devolver a missão como malfeita. A régua não baixa; o endereço do problema é que muda.

Uma quarta, achada na segunda execução. Citação do formato não é pendência. Um agente escreveu, como afirmação de conformidade, a frase "nenhuma pendência `[ABERTO -- <dono>]` sobrevive nesta spec". O varredor de lacunas leu a citação como uma pendência real e ainda propagou o *placeholder* como se fosse o responsável, produzindo no dossiê a linha sem sentido "comece por: [ABERTO — <dono>]". A guarda contra citação de formato existia, mas não cobria *placeholder* entre sinais de menor e maior — que nunca é dono real.

O efeito medido. As correções foram verificadas rodando a mesma missão duas vezes:

	Antes	**Depois**
Impedimentos	5	**1**
Ressalvas	13	14
Decisões para uma pessoa	1	1

Os quatro que sumiram eram atos humanos — homologar autoria, indexar no material editorial, licenciar acervo — que a esteira cobrava de si mesma. O que sobrou é pendência legítima. Nenhuma das correções baixou a régua: o que mudou foi o endereço do problema, não a exigência.

12.7 Correções vindas da terceira execução

A terceira execução completa não trouxe mais nenhum falso impedimento: os cinco achados que apareceram eram todos defeitos reais do documento final, e vinham do mesmo lugar — o portão de consistência do PRD. Isso expôs um problema estrutural que as execuções anteriores escondiam, porque antes esse portão não existia.

Um portão que julga precisa poder devolver. O PRD é o último documento da esteira, e o seu portão era o único que *detectava sem poder corrigir*: apontava o defeito e seguia para o *one-pager* com o defeito intacto, deixando para uma pessoa o que tem correção certa e mecânica. Todos os outros seis ciclos já devolviam o achado ao autor. O do PRD passou a devolver também, com o mesmo padrão — quem julga não conserta, quem conserta não julga — e teto próprio de rodadas (`PRD_MAX_RODADAS`, padrão 2).

O princípio é geral e vale além deste caso: **gate sem ciclo de volta transfere para a pessoa um trabalho que a máquina sabe fazer**. Um achado determinístico com correção única — prefixo de tabela fora do padrão, identificador inválido, requisito bloqueante sem rastro — não é uma decisão: é uma reescrita. O que deve chegar ao humano é a pendência de insumo e a decisão de escopo, não o erro de contrato que o próprio documento já permite localizar.

Por que o redator errou com a regra escrita no prompt. As três regras violadas estavam, todas, escritas de forma explícita no gabarito do redator, com contraexemplo. Não é caso de instrução ausente, e sim de *densidade de instrução*: o cumprimento de regras cai à medida que o número delas cresce no mesmo prompt, e o PRD é o documento com mais restrições simultâneas da esteira. Acrescentar ênfase ao prompt não resolveria — por isso a resposta foi um verificador determinístico fora do modelo, mais o ciclo que devolve o relatório para a reescrita.

Um achado que não faz sentido é pior que nenhum achado. A quarta execução derrubou os impedimentos de cinco para um, e o que sobrou era falso: o verificador acusava um requisito P0 "sem rastro" que estava declarado, estava na matriz e estava coberto por duas tarefas. A regra contava ocorrências do identificador e exigia três; mas um PRD bem escrito cita o requisito *duas* vezes — na declaração e na matriz — porque é a matriz que nomeia a tarefa. E a cobertura costuma vir por intervalo (`RF-001..RF-014`), que não repete o identificador do meio.

O mais instrutivo é o que essa cegueira *escondia*. Ao ler intervalos, o verificador passou a enxergar cinco tarefas cobrindo os catorze requisitos cada uma — ou seja, o plano de implementação não estava decomposto, que é um defeito bem mais sério do que o falso que ele apontava. A regra de atomicidade existia, mas só reconhecia a ausência de decomposição quando escrita por extenso ("todos os RFs"); escrita como intervalo, passava batido.

Vale como princípio de escrita de verificador determinístico: **contar ocorrências é uma aproximação de rastreabilidade, não rastreabilidade**. O teste certo não é quantas vezes o identificador aparece, e sim se existe uma linha que ligue o requisito a uma tarefa. Trocar a contagem pela relação corrigiu o falso positivo e, no mesmo movimento, apertou a régua em vez de baixá-la: o impedimento inventado virou cinco ressalvas verdadeiras.

Evidência tem que caber no relatório. Um dos achados citava a linha defeituosa cortada em 90 caracteres, e o corte caía justamente antes do identificador do evento: o relatório dizia que havia um evento errado sem dizer qual. O achado passou a nomear o identificador e a carregar a linha inteira. Vale como regra de escrita de diagnóstico: **achado que não carrega a evidência obriga quem lê a refazer a investigação**, e um relatório assim é indistinguível de nenhum relatório.

12.8 Identificação no histórico

Os registros no histórico passaram a começar por ano e bimestre — `2EF-1B ǔ O Detalhe que Muda Tudo`. O prefixo é lido do próprio identificador da missão, que carrega os dois desde a revisão do esquema de código, então não é campo novo a preencher. Quando não há como deduzir (missão transversal, formato legado), o título sai sem prefixo, em vez de inventar um.

Uma consequência de método, e ela vale mais que qualquer número: a fonte única passou a ter uma seção de **registro negativo** — o que não sustenta a régua e não deve voltar. Sem isso, uma fundamentação refutada tende a reaparecer na revisão seguinte, porque o argumento de autoridade sobrevive ao artigo que o derrubou.

Referências

[1] CEMRI, M.; PAN, M. Z.; YANG, S. et al. *Why Do Multi-Agent LLM Systems Fail?* NeurIPS 2025, Datasets and Benchmarks Track. arXiv:2503.13657.

[2] BRASIL. Conselho Nacional de Educação. *Resolução CNE/CEB n.º 1, de 4 de outubro de 2022*: normas sobre Computação na Educação Básica — Complemento à BNCC. Brasília: MEC, 2022.

[3] COWAN, N. The magical number 4 in short-term memory. *Behavioral and Brain Sciences*, v. 24, n. 1, p. 87–114, 2001.

[4] JAROSLAWICZ, D.; WHITING, B.; SHAH, P.; MAAMARI, K. *How Many Instructions Can LLMs Follow at Once?* arXiv:2507.11538, 2025.

[5] JONSSON, A.; SVINGBY, G. The use of scoring rubrics: reliability, validity and educational consequences. *Educational Research Review*, v. 2, n. 2, p. 130–144, 2007.

[6] KNIGHT, J. C.; LEVESON, N. G. An experimental evaluation of the assumption of independence in multiversion programming. *IEEE TSE*, v. SE-12, n. 1, p. 96–109, 1986.

[7] LIU, N. F.; LIN, K.; HEWITT, J. et al. Lost in the middle: how language models use long contexts. *TACL*, v. 12, p. 157–173, 2024.

[8] PARNAS, D. L. On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, v. 15, n. 12, p. 1053–1058, 1972.

[9] SWELLER, J. Cognitive load during problem solving: effects on learning. *Cognitive Science*, v. 12, n. 2, p. 257–285, 1988.

[10] TRAN, D.; KIELA, D. *Single-Agent LLMs Outperform Multi-Agent Systems on Multi-Hop Reasoning Under Equal Thinking Token Budgets*. arXiv:2604.02460, 2026.

[11] ZHENG, L.; CHIANG, W.-L.; SHENG, Y. et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. NeurIPS 2023. arXiv:2306.05685.

[12] LOEWENSTEIN, G. The psychology of curiosity. *Psychological Bulletin*, v. 116, n. 1, p. 75–98, 1994.

[13] ZHENG, L. et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. NeurIPS 2023. arXiv:2306.05685.

[14] JAROSLAWICZ, D. et al. *How Many Instructions Can LLMs Follow at Once?* arXiv:2507.11538, 2025.

[15] JONSSON, A.; SVINGBY, G. The use of scoring rubrics. *Educational Research Review*, v. 2, n. 2, p. 130–144, 2007.

[16] BRASIL. CNE/CEB. *Resolução n.º 1, de 4 de outubro de 2022* — Computação na Educação Básica.

[17] GATHERCOLE, S. et al. The structure of working memory from 4 to 15 years of age. *Developmental Psychology*, v. 40, n. 2, p. 177–190, 2004. DOI 10.1037/0012-1649.40.2.177

[18] COWAN, N. Working memory maturation. *Perspectives on Psychological Science*, v. 11, n. 2, p. 239–264, 2016. DOI 10.1177/1745691615621279

[19] ISBELL, E. et al. *Frontiers in Psychology*, v. 6, 696, 2015. DOI 10.3389/fpsyg.2015.00696

[20] GODWIN, K. et al. Off-task behavior in elementary school children. *Learning and Instruction*, v. 44, p. 128–143, 2016.

[21] BETTS, J. et al. The development of sustained attention in children. *Child Neuropsychology*, v. 12, n. 3, p. 205–221, 2006. DOI 10.1080/09297040500488522

[22] BRUNS, B.; COSTA, L.; CUNHA, N. Through the looking glass. *Economics of Education Review*, v. 64, p. 214–250, 2018. DOI 10.1016/j.econedurev.2018.03.003

[23] MORENO, R.; MAYER, R. *Journal of Educational Psychology*, v. 94, n. 1, p. 156–163, 2002. DOI 10.1037/0022-0663.94.1.156

[24] KALYUGA, S. et al. The expertise reversal effect. *Educational Psychologist*, v. 38, n. 1, p. 23–31, 2003. DOI 10.1207/S15326985EP3801_4

[25] KNOOP-VAN CAMPEN, C. et al. *Dyslexia*, v. 24, n. 2, p. 140–155, 2018. DOI 10.1002/dys.1585

[26] SWELLER, J.; VAN MERRIËNBOER, J.; PAAS, F. Cognitive architecture and instructional design: 20 years later. *Educational Psychology Review*, v. 31, n. 2, p. 261–292, 2019. DOI 10.1007/s10648-019-09465-5

[27] BIGGS, J.; COLLIS, K. *Evaluating the Quality of Learning: the SOLO Taxonomy*. 1982.

[28] OSTERHAUS, C.; KOERBER, S. *Child Development*, v. 92, n. 5, p. 1872–1888, 2021. DOI 10.1111/cdev.13627

[29] STARKS, D.; REICH, J. *Information and Learning Sciences*, v. 125, n. 9, p. 673–692, 2024. DOI 10.1108/ILS-12-2023-0201

[30] ROZENDAAL, E. et al. *International Journal of Advertising*, v. 30, n. 2, p. 329–350. DOI 10.2501/IJA-30-2-329-350

[31] DEMETRIOU, A. et al. *Frontiers in Psychology*, v. 13, 954971, 2022. DOI 10.3389/fpsyg.2022.954971

[32] FISCHER, K. A theory of cognitive development. *Psychological Review*, v. 87, n. 6, p. 477–531, 1980.

[33] CASTELO, N.; KIM, S.; CARLSON, S. *Frontiers in Developmental Psychology*, 2023. DOI 10.3389/fdpys.2023.1317426

[34] HAGGER, M. et al. A multilab preregistered replication of the ego-depletion effect. *Perspectives on Psychological Science*, 2016. DOI 10.1177/1745691616652873

[35] KNIGHT, J.; LEVESON, N. *IEEE TSE*, v. SE-12, n. 1, p. 96–109, 1986.

[36] CEMRI, M. et al. *Why Do Multi-Agent LLM Systems Fail?* NeurIPS 2025. arXiv:2503.13657.

[37] DOYLE, W.; PONDER, G. The practicality ethic in teacher decision-making. *Interchange*, v. 8, n. 3, p. 1–12, 1977.

[38] HALL, G.; HORD, S. *Implementing Change: Patterns, Principles and Potholes* (Concerns-Based Adoption Model). Estágios de preocupação em adoção de tecnologia escolar.

[39] DAVIS, E.; KRAJCIK, J. Designing educative curriculum materials to promote teacher learning. *Educational Researcher*, v. 34, n. 3, 2005. DOI 10.3102/0013189X034003003

[40] *Spec Kit Agents*: grounding e validação contra o repositório em desenvolvimento dirigido por especificação. arXiv:2604.05278.

[41] *De-Hallucinator*: recuperação iterativa de referências de API do próprio projeto para reduzir alucinação em geração de código. arXiv:2401.01701.